

Notas de Cálculo Numérico

Priscila Cardoso Calegari

May 14, 2026

Universidade Federal de Santa Catarina

Neste minicurso vamos apresentar o modelo SIR (Suscetível-Infetado-Removido) para o estudo do espalhamento de uma doença. Vamos estudar os conceitos de ordem de aproximação e verificação de métodos numéricos. Em seguida, apresentaremos o conceito de grafo de infecção. Além disso, vamos apresentar simulações numéricas utilizando grafos com diferentes topologias. Alguns conceitos de programação também serão abordados, como por exemplo, o conceito de algoritmos, comandos de repetição, dados de entrada e saída, visualização de resultados.

Palavras-Chave: Modelo SIR · Grafos · Métodos de aproximação

1	Introdução e Erros	1
1.1	Modelagem matemática	1
1.2	Algoritmos e conceitos básicos de programação	3
1.3	Erros	5
1.4	Aritmética de ponto flutuante	8
1.5	Exercícios	13
2	Equações Algébricas	15
2.1	Motivação	15
2.2	Método da Bissecção e Método da Falsa Posição	18
2.3	Método das Aproximações Sucessivas	21
2.4	Método de Newton e suas variações	24
2.4.1	Método de Newton	24
2.4.2	Método de Newton Modificado	26
2.4.3	Método das Secantes	27
2.4.4	Convergência dos métodos	27
2.4.5	Funções com derivadas nulas	29
2.5	Aproximação de raízes de polinômios	30
2.6	Método de Müller	32
2.7	Exercícios	33
3	Sistemas de Equações Lineares	37
3.1	Motivação	37
3.2	Métodos Diretos	39
3.2.1	Método de Cramer	39
3.2.2	Método para sistemas lineares triangulares	41
3.2.3	Método de Eliminação de Gauss	42
3.2.4	Estratégia de Pivoteamento Parcial	46
3.2.5	Fatoração LU	50
3.2.6	Matrizes esparsas	53
3.2.7	Refinamento da solução	55
3.3	Exercícios	58
3.4	Métodos Iterativos	62
3.4.1	Método de Jacobi	62

3.4.2	Método de Gauss-Seidel	64
3.4.3	Convergência dos métodos iterativos	65
3.4.4	Método SOR (<i>Successive Over Relaxation</i>)	67
3.5	Exercícios	68
4	Sistemas de Equações não Lineares	73
4.1	Motivação	73
4.2	Conceitos fundamentais	74
4.3	Método de Newton	76
4.4	Alternativas ao método de Newton	78
4.5	Exercícios	80
5	Aproximação de funções e dados tabelados	83
5.1	Motivação	83
5.2	Método dos Mínimos Quadrados	84
5.2.1	Regressão linear	86
5.2.2	Caso geral	88
5.2.3	Domínio Contínuo	89
5.2.4	Mínimos quadrados com peso	92
5.2.5	Funções Ortogonais	92
5.2.6	Mínimos Quadrados não lineares	93
5.3	Exercícios	96
5.4	Interpolação polinomial	99
5.5	Exercícios	99
	Referências	99
A	Programas	A.1

LISTA DE FIGURAS

1.1	Etapas da solução de um problema.	2
4.1	Três placas de diferentes tamanhos [1].	74

LISTA DE TABELAS

UNIDADE 1

INTRODUÇÃO E ERROS

Neste capítulo, vamos discutir alguns conceitos envolvidos na etapa de modelagem matemática, principalmente erros e suas medidas. Na Seção 1.1 vamos apresentar as etapas da solução de um problema, que envolvem a modelagem e a sua resolução. Na Seção 1.2, vamos apresentar o conceito de algoritmo, fundamental para o desenvolvimento de métodos numéricos. Na Seção 1.3 temática. Em seguida vamos discutir os tipos de erros envolvidos durante o processo de modelagem e solução de um problema via métodos numéricos. Na Seção 1.4 apresentamos de forma breve a aritmética de ponto flutuante e os erros de arredondamento e truncamento. Finalizamos a primeira parte da disciplina, com uma lista de exercícios envolvendo os conceitos estudados.

1.1 Modelagem matemática

Diversos problemas reais são descritos por modelos matemáticos. De forma bem resumida, um modelo matemático é composto por um conjunto de equações que descrevem (ou representam) um problema ou fenômeno físico. Para apresentar um modelo matemático para um problema, por exemplo o espalhamento de doenças ou previsão do tempo, precisamos discutir alguns conceitos fundamentais.

Vamos começar com as etapas de solução de um problema prático. De forma bem simplificada, vamos apresentar duas etapas descritas em [2] e ilustrada na Figura 1.1.

- **Modelagem Matemática:**

A primeira etapa envolve a Modelagem do problema, ou seja, nosso objetivo é obter um conjunto de equações e relações que represente da maneira mais conveniente o problema de interesse. Inicialmente é necessário equacionar o processo que pretendemos estudar,




Fig. 1.1: Etapas da solução de um problema.

ou seja, decidir quais são as variáveis relevantes e como elas se relacionam, quais são os dados do problema, quais leis regem o fenômeno estudado, etc.

Por exemplo, para representar o movimento de um fluido, em geral são utilizadas como incógnitas (variáveis) as componentes da velocidade e a pressão, em uma região (domínio) considerada. As leis de conservação (massa, quantidade de movimento, energia, etc...), bem como, equações constitutivas são usadas para estabelecer a relação entre as variáveis escolhidas, dentre elas as incógnitas. Como, em geral, nem tudo que influi no fenômeno pode ser considerado, algumas simplificações (hipóteses simplificadoras, por exemplo, considerar alguma das variáveis, com a densidade constante) são consideradas neste estágio. Um outro exemplo, se queremos maximizar o lucro de uma empresa, precisamos definir a função objetivo, ou seja, uma expressão que envolva as variáveis associados aos lucros e aos custos da empresa. A função objetivo é a função a ser otimizada, ou seja, no fornecerá o máximo lucro. Além disso, a empresa possui restrições, por exemplo, pode produzir uma quantidade limitada de um determinado produto. As restrições devem ser satisfeitas e fazem parte do modelo matemático.

- **Solução do Problema:**

Uma vez estabelecido o Modelo Matemático (as equações), o próximo passo é resolver o problema. Nem sempre é possível obtermos soluções por meio de métodos analíticos, onde as soluções são apresentadas por meio de expressões. Por exemplo, para obtermos as raízes de uma equação do segundo grau, podemos utilizar a fórmula de Bhaskara. Entretanto, não temos uma metodologia analítica para se obter as raízes de uma função qualquer. Assim, no contexto da disciplina, vamos apresentar soluções aproximadas, obtidas por meio de métodos numéricos para diversos problemas.

De qualquer forma, nesta etapa podemos obter uma solução “ruim”, seja a metodologia analítica ou numérica. Neste caso, pode ser necessário repensarmos a forma de resolver o problema ou a etapa de modelagem.

Vamos utilizar métodos numéricos para resolver os problemas propostos. Os métodos numéricos podem ser representados por meio de algoritmos. Por isso, na próxima seção vamos apresentar o conceito de algoritmo e os conceitos fundamentais de programação.

1.2 Algoritmos e conceitos básicos de programação

Um algoritmo é um processo sistemático para a resolução de um problema. Em outras palavras, pode ser entendido como um procedimento que descreve, sem ambiguidade, uma sequência de passos a ser executada, para se atingir um objetivo. O desenvolvimento de algoritmos é importante para problemas a serem resolvidos em um computador. Um algoritmo computa uma *saída* (a resposta de um problema), a partir de uma *entrada* (informações/dados inicialmente conhecidos) que permitem determinar a solução do problema [7]. Durante o processo de computação o algoritmo manipula dados gerados a partir de sua entrada, por meio de instruções.

A estrutura básica de um programa (um algoritmo implementado) em diferentes linguagens de programação consiste em:

- **Entrada:** os dados de entrada são inicializados, recebidos por meio dos dispositivos de entrada ou de um arquivo.
- **Saída:** A resposta fornecida pelo algoritmo é transmitida para os arquivos de saída ou salva em um arquivo.
- **Lógica e aritmética:** operações aritméticas e lógicas que resolvem o problema de interesse.
- **Condiciona:** verifica se uma condição é satisfeita antes de executar uma sequência de instruções.
- **Repetição:** executa um bloco de instruções repetidamente.

Para mais detalhes veja bons cursos de Introdução à Programação disponíveis em [4] e [5].

Já estudamos diversos algoritmos desde que iniciamos nossos estudos na escola.

Exemplo 1 O Algoritmo 1 recebe dois números inteiros a e b , com $b \neq 0$ e devolve o quociente da divisão a/b .

Algoritmo 1: Divisão inteira

Recebe a e b

$c \leftarrow 0$

enquanto $a > b$ **faça**

$c \leftarrow c + 1$
 $a \leftarrow a - b$

Devolve c

Vamos simular o Algoritmo 1 para a entrada $a = 13$ e $b = 5$. Começamos com a inicialização da variável $c = 0$. Em seguida, verificamos a condição $a > b$. Neste caso, $13 > 5$ cujo resultado é **verdadeiro**, então atualizamos os valores de c e a , respectivamente, $c = 0 + 1 = 1$ e $a = 13 - 5 = 8$. Retornamos para verificar a condição $a > b$, pois estamos executando um comando de repetição. O valor da variável a foi atualizado, temos $8 > 5$

cujo resultado é **verdadeiro**. Assim, atualizamos os valores de c e a , respectivamente, $c = 1 + 1 = 2$ e $a = 8 - 5 = 3$. Novamente vamos verificar a condição $a > b$, sendo $a = 3$ e $b = 5$, cujo resultado é **falso**. Assim, o algoritmo termina e o valor do quociente da divisão está armazenado na variável c . Note que a variável a fica com o resto da divisão.

Os algoritmos são implementados por meio de uma linguagem de programação, utilizando tipos de dados e operações suportadas pelo computador. Neste texto, os algoritmos serão apresentados por meio de pseudocódigo, para que possam ser implementados na linguagem de sua preferência.

Na descrição dos algoritmos ao longo do texto, são utilizadas as seguintes convenções.

- A linguagem possui uma estrutura de blocos de instruções semelhante ao *Python*. O início e o final de cada bloco são determinados pela indentação. Por exemplo, o bloco iniciado por **enquanto** no Algoritmo 1 inclui as duas linhas seguintes.
- Variáveis simples e vetores armazenam dados. Os elementos de vetores são identificados por índices entre colchetes. Por exemplo, $S[2]$ indica o terceiro elemento do vetor S . Vamos utilizar a indexação começando em zero.
- A atribuição de valores é indicada pelo símbolo $\leftarrow$.
- As sentenças após o símbolo $\#$ indicarão comentários.
- As seguintes declarações são empregadas para representar:
 - Condicional:


```
se ... então
se ... então ... caso contrário
```
 - Repetição:


```
enquanto ... faça
para ... faça
```

Exemplo 2 O Algoritmo 2 recebe uma sequência de números armazenada em um vetor e faz a inversão da ordem dos termos desta sequência.

Algoritmo 2: Inversão de uma sequência

```
Recebe  $S$  de tamanho  $n + 1$ 
para  $i = 0, \dots, \lfloor n/2 \rfloor$  faça
     $\text{temp} \leftarrow S[i]$ 
     $S[i] \leftarrow S[n - i]$ 
     $S[n - i] \leftarrow \text{temp}$ 
```

O algoritmo altera o próprio vetor, então a saída do algoritmo está armazenada no próprio vetor (dado de entrada). A notação $\lfloor x \rfloor$ significa *piso* de x e representa o maior inteiro menor ou igual a x .

Vamos fazer a simulação do algoritmo com a entrada $S = [-1, 2, 0, 3, 7]$. O tamanho do vetor (número de elementos) é 5 e temos $S[0] = -1$, $S[1] = 2$, $S[2] = 0$, $S[3] = 3$ e

$S[4] = 7$. A repetição começa em $i = 0$ e vai até $i = \lfloor 4/2 \rfloor = 2$. Para $i = 0$ temos $\text{temp} = S[0] = -1$, $S[0] = S[4 - 0] = 7$ e $S[4] = \text{temp} = -1$. Assim, após a primeira iteração temos $S = [7, 2, 0, 3, -1]$. Para $i = 1$ temos $\text{temp} = S[1] = 2$, $S[1] = S[4 - 1] = 3$ e $S[3] = \text{temp} = 2$. Assim, após a segunda iteração temos $S = [7, 3, 0, 2, -1]$. Note que S já está invertido, mas mais uma iteração é feita. Para $i = 2$ temos $\text{temp} = S[2] = 0$, $S[2] = S[4 - 2] = 0$ e $S[2] = \text{temp} = 0$. Essa iteração é necessária, caso o tamanho do vetor seja um número par.

Exemplo 3 O Algoritmo 3 recebe um número natural n e calcula a soma dos n termos da Série Harmônica: $\sum_{k=1}^{\infty} \frac{1}{k}$.

Algoritmo 3: Soma de n termos da Série Harmônica

Recebe n # quantidade de termos

$S \leftarrow 0$

para $i = 1, \dots, n$ **faça**

$S \leftarrow S + \frac{1}{i}$

Devolve S

Antes de iniciar, vale ressaltar que estaremos usando o símbolo “.” (ponto) em vez de “,” (vírgula) na representação de números reais.

A Série Harmônica é uma série numérica, ou seja, uma soma infinita de termos de uma sequência de números. Vamos fazer a simulação do algoritmo com a entrada $n = 4$. A variável S é inicializada com zero pois irá armazenar a soma dos n primeiros termos da série. Para $i = 1$ temos $S = 0 + 1/1 = 1$. Para $i = 2$ temos $S = 1 + 1/2 = 1.5$. Para $i = 3$ temos $S = 1.5 + 1/3$. Aqui esbarramos no nosso primeiro problema numérico: Como vamos representar $1/3$? Ao fazermos qualquer tipo de aproximação, estamos incluindo um tipo de erro: o erro de representação do número. Para darmos continuidade na simulação, vamos representar $1/3$ com quatro algarismos, 0.3333 (note que zeros à esquerda não são considerados). Assim temos, $S = 1.5 + 0.3333 = 1.8333$. Para encerrar, com $i = 4$ temos $S = 1.8333 + 1/4 = 2.0833$. Assim, a soma aproximada dos quatro primeiros termos da Série Harmônica é 2.0833.

Como no exemplo anterior, a maioria dos processos de solução de um problema, desde a etapa de modelagem são inseridos erros/incertezas. O conjunto destas incertezas vai afetar o resultado final. É necessário termos conhecimento dos tipos de erros envolvidos e como eles se propagam. Além disso, vamos tratar dos tipos de erros envolvidos na representação dos números e em cálculos aritméticos.

1.3 Erros

A solução obtida por meio de um método numérico, em geral, difere da solução do problema real. Definimos **erro** como a diferença entre a solução exata e a solução aproximada de um problema.

Se v é uma aproximação do valor u , definimos o **erro absoluto**, e como:

$$e = |u - v|. \quad (1.1)$$

Já o **erro relativo**, e_r é dado por,

$$e_r = \frac{|u - v|}{|u|} \quad (1.2)$$

Agora, se $\mathbf{v}, \mathbf{u} \in \mathbb{R}^n$, a medida do erro $\mathbf{e} \in \mathbb{R}^n$ será dada por uma das normas, a norma-2,

$$\|\mathbf{e}\|_2 = \left(\sum_{i=1}^n e_i^2 \right)^{\frac{1}{2}}, \quad (1.3)$$

e a norma ∞ (ou norma do máximo), dada por,

$$\|\mathbf{e}\|_\infty = \max_{1 \leq i \leq n} (|e_i|). \quad (1.4)$$

A partir de agora, vamos descrever brevemente algumas fontes de erros.

- **Erros iniciais:**

Nos erros iniciais são incluídas as incertezas da modelagem matemática, com as hipóteses simplificadoras, as medições de parâmetros, as condições iniciais, etc. São erros que já existem antes mesmo de começarmos o processo de resolução.

A influência das perturbações iniciais dependem da estabilidade do problema. Em alguns casos, a influência deste tipo de erro pode inviabilizar a solução numérica, são problemas conhecidos como mal postos ou mal condicionados, problemas que são sensíveis a pequenas perturbações nos dados de entrada.

- **Erros de truncamento:**

Os erros de truncamento são erros associados a parada de um processo infinito. Por exemplo, para aproximar a exponencial de um número $x \in \mathbb{R}$. Para discutirmos este exemplo, vamos precisar relembrar o conceito da **Série de Taylor** de uma função.

A Série de Taylor de uma função $f(x)$ é a representação de $f(x)$ como a soma infinita de termos calculados a partir das derivadas de $f(x)$ em um ponto x_0 , dada por

$$f(x) = f(x_0) + \sum_{n=1}^{\infty} \frac{f^{(n)}(x_0)}{n!} (x - x_0)^n, \quad (1.5)$$

com $x, x_0 \in \mathbb{R}$, $f^{(n)}$ a n -ésima derivada de $f(x)$. Assim, se x_0 pertence a uma vizinhança de x , ao truncarmos a Série de Taylor, obtemos uma aproximação para $f(x)$. Dado x_0 ,

considere $x = x_0 + h$, ou seja, x está em uma vizinhança de x_0 , de tamanho h . Se truncarmos a Série, no termo K temos a seguinte aproximação,

$$f(x) = f(x_0) + \sum_{n=1}^K \frac{f^{(n)}(x_0)}{n!} (h)^n + O(h^K), \quad (1.6)$$

sendo $O(h^K)$ representa a ordem do erro cometido, ou seja, erro $\leq Ch^K$, com C uma constante e h um número pequeno, pois h representa uma vizinhança.

Exemplo 4 Considere $f(x) = e^x$, com $x = 0.5$. Aproxime o valor de $e^{0.5}$ usando cinco termos da Série de Taylor.

A Série de Taylor de e^x em torno de $x_0 = 0$ é dada por:

$$e^x = 1 + x + \frac{x^2}{2} + \frac{x^3}{3!} + \dots + \frac{x^n}{n!} + \dots = 1 + \sum_{k=1}^{\infty} \frac{x^k}{k!}$$

Note que para chegarmos na expressão acima, estamos considerando $x_0 = 0$ e então $x = h$. Além disso, qualquer derivada de e^x é e^x e quando avaliada em x_0 temos $f^{(n)}(x_0) = 1$.

Para conseguirmos, aproximar o valor de $e^{0.5}$ precisamos “truncar” a soma infinita. Utilizando cinco termos, temos:

$$e^{0.5} \approx 1 + 0.5 + \frac{0.5^2}{2} + \frac{0.5^3}{6} + \frac{0.5^4}{24}$$

Mais uma vez temos um problema com a representação de números reais. Quantos algarismos devemos utilizar para representar um número real? Como o erro na representação influencia na solução aproximada? Para este exemplo, vamos utilizar a precisão fornecida por uma calculadora científica: $e^{0.5} \approx 1.6484375$. Vamos considerar o valor fornecido pela avaliação da função exponencial em uma calculadora científica como o valor exato: $e^{0.5} = 1.6487212707$. Agora, vamos calcular o erro absoluto: erro = $|1.6484375 - 1.6487212707| = 0.0002837707$.

- **Erros de arredondamento:**

Este tipo de erro está associado a representação do sistema de numeração da máquina calculadora. Conforme visto nos exemplos anteriores, precisamos definir a regra de arredondamento na representação de números reais. Por exemplo, considere o número π , como vamos representá-lo? O primeiro passo é definir quantos algarismos serão usados para representá-lo e depois usar uma das regras de arredondamento. Vamos utilizar as seguintes regras de arredondamento:

1. **Corte:** desconsideramos os algarismos a partir da quantidade de algarismos fixada. Por exemplo, o número 1.6666666 representado com 4 algarismos é 1.666.

2. **Arredondamento:** Considere que fixamos n algarismos para representar um número. Se o algarismo $n + 1$ for maior ou igual a 5 somamos 1 ao algarismo n , caso contrário, usamos o corte. Por exemplo, usando o arredondamento, o número 1.666666 é representado com 4 algarismos por 1.667, pois o quinto algarismo é 6.

Para discutir os erros de arredondamento, primeiro vamos apresentar a representação de números inteiros e números reais em máquinas que possuem uma quantidade limitada de algarismos para representar estes números. Na sequência, vamos utilizar estes conceitos para realizar as operações aritméticas com uma quantidade de algarismos fixa.

1.4 Aritmética de ponto flutuante

Os números podem ser representados em diferentes sistemas de numeração. No sistema decimal, trabalhamos com a base 10 e os símbolos: 0, 1, 2, 3, 4, 5, 6, 7, 8, 9. Por exemplo: $1234 = 1 \times 10^3 + 2 \times 10^2 + 3 \times 10^1 + 4 \times 10^0$. Já no sistema binário, utilizamos a base 2 e os símbolos: 0, 1. Por exemplo, o número 13 representado na base binária é: $1101 = 1 \times 2^3 + 1 \times 2^2 + 0 \times 2^1 + 1 \times 2^0$. Como exercício, faça sucessivas divisões pela base e analise o resto destas divisões.

Assim um número inteiro no sistema binário é representado pelos coeficientes de sua expansão binária,

$$N = a_n \times 2^n + a_{n-1} \times 2^{n-1} + \dots + a_1 \times 2^1 + a_0 \times 2^0 \Rightarrow N = (a_n a_{n-1} \dots a_1 a_0)_2.$$

Agora, vamos iniciar a análise da representação de números reais. Lembre-se que estaremos usando o símbolo “.” (ponto) em vez de “,” (vírgula) na representação de números reais. Na base decimal um número real pode ser representado da seguinte maneira:

$$A = a_n \times 10^n + a_{n-1} \times 10^{n-1} + \dots + a_1 \times 10^1 + a_0 \times 10^0 + a_{-1} \times 10^{-1} + \dots + a_{-n} \times 10^{-n} + \dots$$

Por exemplo, o número $13.311 = 1 \times 10^1 + 3 \times 10^0 + 3 \times 10^{-1} + 1 \times 10^{-2} + 1 \times 10^{-3}$.

Dada uma base $b \geq 2$ temos a representação dada por,

$$A = a_n \times b^n + a_{n-1} \times b^{n-1} + \dots + a_1 \times b^1 + a_0 \times b^0 + a_{-1} \times b^{-1} + \dots + a_{-n} \times b^{-n} + \dots, \quad (1.7)$$

com $0 \leq a_i < b$ para todo i . Por exemplo, o número 1001.101 na base $b = 2$ representa,

$$1 \times 2^3 + 0 \times 2^2 + 0 \times 2^1 + 1 \times 2^0 + 1 \times 2^{-1} + 0 \times 2^{-2} + 1 \times 2^{-3} = 9.625.$$

Agora vamos apresentar a **Aritmética de ponto Flutuante**. Ela é usada em cálculos científicos e é uma padronização na representação de números reais. Com ela podemos:

- (i) especificar como representar números reais com precisão simples e precisão dupla; e,
- (ii) padronizar o arredondamento nas operações aritméticas.

A representação em ponto flutuante de um número x , em uma base b , com n algarismos significativos (quantidade de algarismos na mantissa do número) é definida por,

$$fl(x) = \pm(0.d_1d_2 \dots d_n) \times b^e, \quad (1.8)$$

sendo $d_1d_2 \dots d_n$ a mantissa do número (representação fracionária) na base b , com $d_1 \neq 0$, e (número inteiro) o expoente do número, com $e_1 < e < e_2$, e_1 e e_2 , o menor e o maior expoente, respectivamente.

Exemplo 5 Note que, 0.2531×10^{-1} representa o número 0.02531 na base 10 com 4 algarismos significativos. Já o número 0.2531×10^2 , que possui a mesma mantissa do número anterior, representa 25.31 na base 10.

Para representar um sistema de numeração de ponto flutuante, vamos utilizar a seguinte notação: $F(b, n, e, E)$, onde b é a base, n é a quantidade de algarismos significativos. Note que, teremos um sistema limitado, pelo maior número representado e pelo menor número representado pelo sistema.

Exemplo 6 Dado o sistema $F(10, 5, -3, 4)$, o número $x = 279.15$ é representado neste sistema como $x = 0.27915 \times 10^3$.

Qual é o maior número representado neste sistema de numeração? Note que, 0.99999×10^4 representa a maior mantissa com o maior expoente. Uma máquina com este sistema de numeração não representa números maiores que 9999.9 (*overflow*).

Qual o menor número positivo representado neste sistema de numeração? Note que, 0.10000×10^{-3} representa a menor mantissa ($d_1 \neq 0$) com o menor expoente. Números positivos menores que 1×10^{-4} não serão representados neste sistema (*underflow*).

Agora, o que acontece se quisermos representar o número π no sistema apresentado no Exemplo 6?

Dada uma quantidade fixa de algarismos significativos não conseguimos representar todos os números reais em uma máquina.

Uma aproximação do número π será representada por $\pi \approx 3.1415$ usando a regra do corte e $\pi \approx 3.1416$ usando a regra de arredondamento, pois o sexto algarismo (lembre-se que o sistema do exemplo trabalha com cinco algarismos significativos) é igual a 9.

Exemplo 7 O número 0.11100110×2^2 na base 2 com 8 algarismos significativos representa o número 3.59375. Já o número 0.11100111×2^2 representa 3.609375.

Note que no Exemplo 7, o número 0.11100111 é o próximo número a ser representado na máquina, depois do número 0.11100110. Isso significa que os números reais entre 3.59375 e 3.609375 não são representados neste sistema de ponto flutuante.

Na padronização organizada pelo IEEE (*Institute for Electrical and Eletronics Engineers*) estabeleceu-se que:

- Um número real com precisão simples é representado por 32 *bits* (4 *bytes* pois 1 *byte* - 8 *bits*), sendo: 1 *bit* reservado para o sinal, 8 *bits* reservados para o expoente e 23 *bits* reservados para a mantissa.
- Um número real com precisão dupla é representado por 64 *bits*, sendo 1 *bit* para o sinal, 11 *bits* para o expoente e 52 *bits* para a mantissa.

Neste caso, na base 2, um número real com precisão dupla, é representado por:

$$(-1)^s 2^{e-1023} (1 + m),$$

sendo s o bit do sinal, e o expoente e m a mantissa.

- o expoente e com 11 *bits* fornece uma variação de 0 a $2^{11} - 1 = 2047$, que é normalizada de -1023 a 1024 .
- Os 52 *bits* na mantissa equivalem a aproximadamente 16 algarismos (na base decimal) de precisão.
- Em qualquer representação em ponto flutuante temos o menor e o maior número que pode ser representado, indicando *underflow* e *overflow*, respectivamente.

Exemplo 8 Qual número é representado por 1 10000000011 10110011100010...0?

Note que o “três pontinhos” representam uma sequência de 37 zeros. O primeiro 1 se refere ao sinal do número, neste caso $-$. Depois, temos a sequência de 11 *bits* que representa o expoente: $e = 1 \times 2^{10} + 1 \times 2^1 + 1 \times 2^0 = 1027$. Em seguida, os 52 *bits* que representam a mantissa: $m = 1 \times 2^{-1} + 1 \times 2^{-3} + 1 \times 2^{-4} + 1 \times 2^{-7} + 1 \times 2^{-8} + 1 \times 2^{-9} + 1 \times 2^{-13} = 0.7012939453$. Dessa forma, temos $fl(x) = (-1)^1 2^4 (1 + m) = -27.2207031248$.

As operações em aritmética de ponto flutuante devem seguir as regras de arredondamento a cada operação. Vamos exercitar com sistemas de numeração com poucos algarismos significativos para observar o que ocorre com os cálculos feitos em computadores.

Exemplo 9 Represente os números 1.234 e 1.235 com três algarismos significativos.

Utilizando o arredondamento temos $1.234 \approx 1.23$ e $1.235 \approx 1.24$. Utilizando o corte temos $1.234 \approx 1.23$ e $1.235 \approx 1.23$.

Exemplo 10 Realize as operações usando três algarismos significativos.

(a) $(4.26 + 9.25) + 5.04$;

(b) $4.26 + (9.25 + 5.04)$.

Lembre-se que a regra de arredondamento deve ser aplicada a cada operação. No item (a), usando o corte, temos:

$$(4.26 + 9.25) + 5.04 = 13.51 + 5.04 \approx 13.5 + 5.04 = 18.54 \approx 18.5,$$

e, note que, usando o arredondamento, temos o mesmo resultado. Já no item (b), usando o corte, temos:

$$4.26 + (9.25 + 5.04) = 4.26 + 14.29 \approx 4.26 + 14.2 = 18.46 \approx 18.4,$$

e, usando o arredondamento,

$$4.26 + (9.25 + 5.04) = 4.26 + 14.29 \approx 4.26 + 14.3 = 18.56 \approx 18.6.$$

Note que, com a aritmética de ponto flutuante perdemos a propriedade da associatividade. Precisamos estar atentos as quantidades de algarismos significativos que utilizamos nos nossos cálculos. O seguinte resultado, nos apresenta uma estimativa do erro que cometemos na representação de números reais com a aritmética de ponto flutuante.

Lema 1 *O erro na representação de um número $a \neq 0$ em aritmética de ponto flutuante com n algarismos significativos, na base decimal é limitado por,*

$$|a - fl(a)| \leq 5|a|10^{-n}p,$$

com $p = 1$ se feito o arredondamento e $p = 2$ no caso do corte.

demonstração:

Supondo $a = 10^q(0.d_1d_2 \dots d_nd_{n+1} \dots)$, usando o corte para representar a , temos:

$$fl(a) = 10^q(0.d_1d_2 \dots d_n).$$

Assim,

$$\begin{aligned} |a - fl(a)| &= 10^{q-n}(0.d_{n+1} \dots) \\ &= 10^{q-n}(d_{n+1}d_{n+2} \dots) \frac{|a|}{|a|} \\ &= 10^{-n} \frac{0.d_{n+1}d_{n+2} \dots}{0.d_1d_2 \dots} |a| \end{aligned}$$

Note que, $1 \leq d_1 \leq 9$ e $0.d_{n+1}d_{n+2} \dots \leq 1$ temos que quanto menor o denominador da expressão:

$$\frac{0.d_{n+1}d_{n+2} \dots}{0.d_1d_2 \dots} \leq \frac{1}{0.1},$$

menor o resultado.

Portanto,

$$|a - fl(a)| \leq 10^{1-n}|a|,$$

o que mostra o resultado com $p = 2$, já que utilizamos o corte.

□

Vamos encerrar a unidade apresentando o problema de perda de precisão em decorrência do erro de arredondamento, que pode ser evitada por uma reformulação do problema.

Considere o problema de determinar x tal que $ax^2 + bx + c = 0$, com $a \neq 0$. A partir de fórmula de Bhaskara as duas soluções são dadas por,

$$x_1 = \frac{-b + \sqrt{b^2 - 4ac}}{2a} \quad \text{e} \quad x_2 = \frac{-b - \sqrt{b^2 - 4ac}}{2a}.$$

Vamos aplicar a fórmula à equação $x^2 - 100.23x + 1.2371 = 0$, cujas soluções são aproximadamente, $x_{1e} = 100.21765$ e $x_{2e} = 0.012344132$, usando 5 algarismos significativos e a regra do corte para o arredondamento. Note que, nessa equação, b^2 é muito maior do que $4ac$, isso causará uma perda de precisão. Veja na sequência,

$$b^2 - 4ac = (-100.23)^2 - 4 \times 1.2371 = 10046.052 - 4.9484 \approx 10046 - 4.9484 = 10041.051$$

$$\sqrt{b^2 - 4ac} \approx \sqrt{10041} = 100.20479 \approx 100.20.$$

Assim temos,

$$x_1 = \frac{100.23 + 100.20}{2} = 100.215 \approx 100.21, \quad \text{e} \quad x_2 = \frac{100.23 - 100.20}{2} = \frac{0.03}{2} = 0.015.$$

Ao calcular o erro relativo de cada aproximação obtemos,

$$\frac{|x_{1e} - x_1|}{|x_{1e}|} \approx 7.63 \times 10^{-5} \quad \text{e} \quad \frac{|x_{2e} - x_2|}{|x_{2e}|} \approx 0.215.$$

O cálculo de x_1 envolveu a soma de números quase iguais, o que não representou nenhum problema para a aproximação. Já a aproximação de x_{2e} envolveu a subtração de números “quase iguais” (próximo de zero). Isso unido a pequena quantidade de algarismos significativos gerou uma aproximação insatisfatória, com grande erro relativo.

Note que x_1 e x_2 também podem ser determinadas por meio das regras de soma e produto,

$$x_1 + x_2 = -\frac{b}{a} \quad \text{e} \quad x_1 x_2 = \frac{c}{a}.$$

Neste caso, a aproximação para x_{2e} é dada por,

$$x_2 = \frac{1.2371}{100.21} = 0.01234507 \approx 0.012345.$$

Uma aproximação com erro relativo,

$$\frac{|x_{2e} - x_2|}{|x_{2e}|} \approx 7.03 \times 10^{-5}.$$

Assim, concluímos que é importante refletir antes de calcular.

Para finalizar e reforçar, a notação:

- Convencional: 0.3333, 1.345 e 0.002531;

- Fracionária: $\frac{1}{3}$;
- Fatorada: $1.345 = 1 \times 10^0 + 3 \times 10^{-1} + 4 \times 10^{-2} + 5 \times 10^{-3}$;
- Ponto flutuante: 0.1345×10^1 e 0.2531×10^{-2} .

Lembre-se que vamos trabalhar com a notação convencional e de ponto flutuante.

Leitura recomendada:

- Noções de Cálculo Numérico. Capítulo 1 [2].
- Cálculo Numérico Computacional. Capítulo 1 [6].

1.5 Exercícios

- Escreva os seguintes números, na forma normalizada, na base $b = 10$ em aritmética de ponto flutuante de $n = 4$ e $n = 6$ algarismos significativos, $\pm(.d_1d_2\dots d_n) \times b^e$. Use corte e arredondamento e compare os resultados.

(a) -77549	(c) 10.0097
(b) 0.0027823	(d) $\cos(0.7)$
- Considere um sistema de numeração $F(2, 8, -4, 5)$.
 - Escreva o número $(0.10110001) \times 2^3$ e o seu sucessor $(0.10110010) \times 2^3$ na base 10.
 - A representação do número 5.5, neste sistema de numeração, é exata? Justifique.
- Efetue as seguintes operações com aritmética de ponto flutuante, usando 3 algarismos significativos:

(a) $(2.06 - 0.0997) + (5.059 - 0.089)$	(b) $(1/6) \times (0.0027632) - 45.03 + 0.7603$
---	---
- Considere $x = 0.5289$, $y = 0.8012$ e $z = 0.6024$ e operações em ponto flutuante numa mantissa com 4 algarismos significativos (use o arredondamento a cada operação) e verifique se:
 - $x \cdot (y + z) = x \cdot y + x \cdot z$
 - $(x + y) + z = x + (y + z)$
- Um sistema de ponto flutuante pode ser expresso pela função $F(b, n, e_1, e_2)$. Por exemplo, dado o sistema $F(10, 4, -5, 5)$, o número $x = 279.15$ é representado como $x = 0.2791 \times 10^3$, usando corte e $x = 0.2792 \times 10^3$, usando arredondamento. Considere uma máquina com o sistema descrito acima. Pede-se:
 - qual o menor e o maior número (em valor absoluto) representados nesta máquina?

- (b) como será representado o número 73.758 nesta máquina, se for usado o arredondamento? E se for usado o truncamento?
 - (c) se $a = 42450$ e $b = 3$ qual o resultado de $a + b$?
 - (d) qual o resultado da soma $S = 42450 + \sum_{k=1}^{10} 3$, nesta máquina?
 - (e) o mesmo para a soma, $S = \sum_{k=1}^{10} 3 + 42450$
 - (f) o resultado da operação: wz/t pode ser obtido de várias maneiras, bastando modificar a ordem em que os cálculos são efetuados. Para determinarmos valores de w , z e t , uma sequência de cálculos pode ser melhor que outra. Faça uma análise para o caso em que $w = 100$, $z = 3500$ e $t = 7$.
6. Escreva um programa em alguma linguagem de programação para obter o resultado da seguinte operação:

$$S = 10000 - \sum_{k=1}^N x,$$

para:

- (a) $N = 10000$ e $x = 0.1$
 - (b) $N = 80000$ e $x = 0.125$
7. A série de Taylor da função $\ln(x)$ é expressa por

$$\ln(x) = \sum_{k=1}^{\infty} (-1)^{k-1} \frac{(x-1)^k}{k},$$

com raio de convergência $0 < x \leq 2$. Utilizando aritmética de ponto flutuante com 5 algarismos significativos:

- (a) Aproxime os valores de $\ln(1.5)$, $\ln(2)$ e $\ln(3)$, com $N = 10$ e 20 .
 - (b) Observe que a série para $\ln(3)$ é divergente, o cálculo pela série de Taylor fornece valores errados e, em nenhum momento vai convergir para o valor 1.0986122887 com qualquer número de termos da série. Usando a propriedade da função logarítmicas, $\ln(a \cdot b) = \ln(a) + \ln(b)$, faça $\ln(3) = \ln(2 \times 1.5)$ com $n = 20$ (já calculado no item (a)) e compare com o resultado exato.
8. No Cálculo Diferencial e Integral, demonstra-se que a série Harmônica $\sum_{k=1}^{\infty} \frac{1}{k}$ não converge. Construa um programa que efetue uma aproximação da série Harmônica e verifique este resultado computacionalmente.

UNIDADE 2

EQUAÇÕES ALGÉBRICAS

Nesta unidade vamos estudar métodos numéricos para determinar os zeros (ou raízes) de funções. Ou seja, vamos resolver equações algébricas. O problema pode ser formulado da seguinte maneira:

Dada uma função $f(x)$ definida e contínua em um intervalo aberto I , chamaremos de zero ou raiz desta função no intervalo I a todo $\alpha \in \mathbb{R}$ tal que $f(\alpha) = 0$.

Métodos analíticos são conhecidos apenas para alguns polinômios. Para determinar α de uma função qualquer, vamos estudar métodos numéricos que fornecem uma aproximação para a raiz α .

Esta unidade está organizada da seguinte forma. Na Seção 2.1 vamos apresentar um problema prático e um pouco da teoria básica para a aplicação dos métodos numéricos. Na Seção 2.2 vamos estudar o Método da Bisecção e da Falsa posição. Na Seção 2.3, o Método das Aproximações Sucessivas. Já a Seção 2.4 o Método de Newton, a convergência do método e suas variações. A Seção 2.5 apresenta um método que avalia polinômios de uma forma eficiente e a Seção 2.6 apresenta o método de Muller que também aproxima raízes complexas. Uma lista de exercícios, na Seção 2.7, encerra o capítulo.

2.1 Motivação

Nas mais diversas áreas ocorrem situações que envolvem a resolução de uma equação da forma $f(x) = 0$. Burden e Faires [1] apresentam o seguinte problema de motivação. O crescimento de uma população isolada, em um curto período de tempo, é modelado pela

Equação Diferencial Ordinária (EDO),

$$\begin{cases} \frac{dN(t)}{dt} = \lambda N(t), t \in [t_0, t_F], \\ N(t_0) = N_0, \end{cases}$$

sendo $N(t)$ a população no tempo t e λ uma taxa constante de nascimentos. A solução desta equação é $N(t) = N_0 e^{\lambda t}$, onde N_0 é a população no instante de tempo inicial. Se adicionarmos a este modelo uma taxa constante de imigração v , obtemos a EDO,

$$\frac{dN(t)}{dt} = \lambda N(t) + v,$$

cuja solução é $N(t) = N_0 e^{\lambda t} + \frac{v}{\lambda}(e^{\lambda t} - 1)$.

Suponha que uma certa população, inicialmente tenha $N(0) = 1000$ indivíduos e durante um ano 435 indivíduos migraram para a comunidade e que no final deste a população seja $N(1) = 1564$. Para determinar a taxa de nascimento, precisamos resolver a equação

$$1564 = 1000e^{\lambda} + \frac{435}{\lambda}(e^{\lambda} - 1),$$


que pode ser reescrita no formato $f(\lambda) = 0$,

$$1000e^{\lambda} + \frac{435}{\lambda}(e^{\lambda} - 1) - 1564 = 0.$$

Note que não é possível isolar λ nesta equação e também não possuímos uma metodologia analítica para solucioná-la. Entretanto os métodos que estudaremos nesta unidade, fornecerão soluções aproximadas para este tipo de problema.

Problema: Dada $f(x)$, com $x \in \mathbb{R}$, queremos determinar $\tilde{x}$ uma aproximação para α tal que $f(\tilde{x}) \approx 0$.

Vamos começar relembando alguns resultados do Cálculo Diferencial que vão nos auxiliar a determinar um intervalo que contenha uma raiz. O gráfico abaixo ilustra uma função $f(x)$ com duas raízes x_1 e x_2 .



Os métodos numéricos que vamos estudar são **métodos iterativos**. Ou seja, vamos obter uma sequência de aproximações para a solução desejada. O cálculo de uma nova aproximação depende das aproximações anteriores. Dessa forma, devemos fornecer as aproximações iniciais que o método exigir.

Uma **função de iteração** (fórmula de recorrência) que aproxima a solução do problema, será aplicada repetidas vezes, a partir de uma aproximação inicial conhecida e irá gerar uma sequência de aproximações que converge para a solução do problema.

• **Intervalo com uma raiz isolada:**

O primeiro passo para determinar a aproximação de uma raiz é determinar um intervalo que contenha apenas uma raiz. Para isso, vamos utilizar o seguinte resultado.

Teorema 1 (Teorema de Bolzano) *Se $f(x)$ é uma função contínua e troca de sinal no intervalo $[a, b]$, ou seja, $f(a) \cdot f(b) < 0$, então existe pelo menos um $\alpha \in [a, b]$ tal que $f(\alpha) = 0$.*

Note que o teorema apresenta uma condição necessária ($f(x)$ precisa ser contínua e trocar de sinal para que tenha uma raiz) mas não suficiente (podemos ter raízes em um intervalo que não tenha a troca de sinal). O gráfico a seguir apresenta algumas situações de intervalos que contém a troca de sinal, o primeiro com uma única raiz e o segundo com mais de uma raiz. Já o terceiro e o quarto gráfico não apresentam a troca de sinal no intervalo $[a, b]$, sendo que as duas situações podem ocorrer: a existência ou não existência de raízes.

Note que, se $f(x)$ troca de sinal e $f'(x)$ não troca de sinal em $[a, b]$ então α é a única raiz de $f(x)$ no intervalo $[a, b]$. Assim o teorema de Bolzano garante a existência da raiz e a análise do sinal de $f'(x)$, garante a unicidade.


Assim antes de aplicar qualquer método numérico para a aproximar a raiz de uma função $f(x)$, precisamos isolar a raiz:

1. Identificar um intervalo $[a, b]$ que se verifique a troca de sinal de $f(x)$ (Teorema de Bolzano).
2. Analisar o sinal de $f'(x)$ para verificar que a função é estritamente crescente ou estritamente decrescente em $[a, b]$.

Exemplo 11 Considere $f(x) = x \ln(x) - 3.2$, com $x > 0$.

Primeiro, vamos construir uma tabela $x|f(x)$ nos pontos $x = 1, 2, 3, 4$, com três algarismos significativos, para identificar um intervalo que ocorra a troca de sinal:

x	1	2	3	4
$f(x)$	-3.2	-1.81	0.0958	2.34



Pelo Teorema de Bolzano concluímos que existe pelo menos uma raiz real no intervalo $[2, 3]$, pois $f(2) < 0$ e $f(3) > 0$.

Em seguida, vamos analisar o sinal de $f'(x)$ para identificar se $f(x)$ é estritamente crescente ou estritamente decrescente. Como $f'(x) = \ln(x) + 1 > 0$ em $[2, 3]$, ou seja, $f(x)$ é estritamente crescente, existe uma única raiz no intervalo $[2, 3]$.

x	2.2	2.4	2.6	2.8
$f(x)$	-1.46	-1.09	-0.715	-0.317

Assim, concluímos que $f(x)$ possui uma única raiz no intervalo $[2.8, 3]$.

2.2 Método da Bissecção e Método da Falsa Posição


Considere $f(x)$ contínua e suponha $[a, b]$ um intervalo que contenha uma raiz isolada de $f(x)$. Os métodos da Bissecção (Dicotomia) e Falsa Posição são métodos que geram uma sequência de intervalos, cada vez menores, que contenha a raiz. Ou seja, a cada iteração obtemos um intervalo menor (a metade do anterior) que contenha a raiz.

• Método da Bissecção:

Vamos considerar x_m o ponto médio do intervalo $[a, b]$. Obtemos dois novos intervalos

para análise $[a, x_m]$ e $[x_m, b]$. Como $f(x)$ troca de sinal em $[a, b]$ então $f(x)$ trocará de sinal no intervalo $[a, x_m]$ ou no intervalo $[x_m, b]$. Assim, temos um novo intervalo que contém a raiz e este intervalo tem tamanho $|b - a|/2$. O processo iterativo continua neste novo intervalo, onde ocorre a troca de sinal, e terminará quando atingida uma precisão já fixada (tolerância). Para que o processo termine é necessários escolhermos um critério de parada. No método da Bissecção vamos utilizar o seguinte critério: paramos, quando o tamanho do novo intervalo for menor que uma tolerância.

A Figura a seguir ilustra o que ocorre em uma iteração.



Exemplo 12 Use o método da Bissecção (5 iterações) para aproximar a raiz positiva de $f(x) = x^2 - 5$.

Note que $f(x)$ troca de sinal no intervalo $[2, 3]$, pois $f(2) = -1$ e $f(3) = 4$ e $f'(x) = 2x > 0 \forall x \in [2, 3]$. Portanto, $f(x)$ é crescente e possui uma única raiz no intervalo $[2, 3]$. As cinco primeiras iterações são apresentadas na tabela abaixo.

i	a	b	$x = (a + b)/2$	$f(a)$	$f(b)$	$f(x)$
1	2	3	2.5	-1	4	1.25
2	2	2.5	2.25	-1	1.25	0.0625
3	2	2.25	2.125	-1	0.0625	-0.484375
4	2.125	2.25	2.1875	-0.48375	0.0625	-0.21484375
5	2.1875	2.25	2.21875	-0.21484375	0.0625	-0.0771484375

O erro absoluto é $|\sqrt{5} - x| = 0.0173179775$.

- Embora o método seja simples, ele sofre por ser lento.
- Após n iterações o erro é delimitado por $|b - a|/2^n$.

Algoritmo 4: Método da Bissecção

Entrada: $f(x)$, $[a, b]$ e δ (tolerância)

$i \leftarrow 1$

$i_{max} \leftarrow 100$

$x \leftarrow (a + b)/2$

enquanto $(|b - a|/2 > \delta \text{ e } i < i_{max})$ **faça**

se $(f(a) \cdot f(x) > 0)$ **então**

$a \leftarrow x$

senão

$b \leftarrow x$

$x \leftarrow (a + b)/2$

$i \leftarrow i + 1$

Devolve x e $f(x)$


- Método da Falsa Posição:**

Semelhante ao método da Bissecção, a cada iteração determina um intervalo que contenha a raiz. A diferença é: a cada iteração do método, vamos aproximar a raiz de $f(x)$ (representada por α) pela raiz da reta que passa pelos pontos $(a, f(a))$ e $(b, f(b))$. Assim teremos dois intervalos, $[a, x]$ e $[x, b]$. Escolhemos como intervalo para a próxima iteração aquele que contem a raiz α , ou seja, o intervalo que ocorre a troca de sinal da $f(x)$.

Note que, x raiz da reta que passa pelos pontos $(a, f(a))$ e $(b, f(b))$ é dado por,

$$x = \frac{af(b) - bf(a)}{f(b) - f(a)}.$$

A Figura a seguir ilustra o que ocorre em uma iteração do método.



Exemplo 13 Use o método da Falsa Posição (5 iterações) para aproximar a raiz positiva de $f(x) = x^2 - 5$.

i	a	b	$x = \frac{af(b) - bf(a)}{f(b) - f(a)}$	$f(a)$	$f(b)$	$f(x)$
1	2	3	2.2	-1	4	-0.16
2	2.2	3	2.2307692	-0.16	4	-2.36686×10^{-2}
3	2.2307692	3	2.2352941	-2.36686×10^{-2}	4	-3.46021×10^{-3}
4	2.2352941	3	2.2359550	-3.46021×10^{-3}	4	-5.04987×10^{-4}
5	2.2359550	3	2.2360515	-5.04987×10^{-4}	4	-7.36798×10^{-5}

O erro absoluto é $|\sqrt{5} - x| = 3.506995 \times 10^{-7}$.

- Dependendo do comportamento da função $f(x)$ este método pode ser mais rápido que o método da Bissecção.

Algoritmo 5: Método da Falsa Posição

Entrada: $f(x)$, $[a, b]$ e δ (tolerância)

$i \leftarrow 1$

$i_{max} \leftarrow 100$

$x \leftarrow (a * f(b) - b * f(a)) / (f(b) - f(a))$

enquanto $(|f(x)| > \delta \text{ e } i < i_{max})$ **faça**

se $(f(a) \cdot f(x) > 0)$ **então**

$a \leftarrow x$

senão

$b \leftarrow x$

$x \leftarrow (a * f(b) - b * f(a)) / (f(b) - f(a))$

$i \leftarrow i + 1$

Devolve x e $f(x)$

2.3 Método das Aproximações Sucessivas

No Método das Aproximações Sucessivas a sequência de aproximações para a raiz de $f(x)$, α , é obtida por meio de uma fórmula de recorrência:

$$x_n = \phi(x_{n-1}), n = 1, 2, \dots \quad (2.1)$$

sendo x_0 é uma aproximação inicial. A função $\phi(x)$ é uma **função de iteração** (fórmula de recorrência) que tem α como ponto fixo, ou seja, $\phi(\alpha) = \alpha$.

Problema: Como obter a função $\phi(x)$?

Para obtermos uma candidata a função de iteração que tenha α raiz de $f(x)$ como ponto fixo, vamos reescrever a expressão $f(x) = 0$ no formato $x = \phi(x)$.

Exemplo 14 A função quadrática $f(x) = x^2 + 0.96x - 2.08 = 0$ possui duas raízes, uma positiva e outra negativa.

(a) Mostre que $f(x)$ possui uma raiz no intervalo $[0, 2]$.

(b) Obtenha uma função $\phi(x)$.

(c) Utilize a função obtida no item anterior para obter uma sequência de aproximações para a raiz no intervalo $[0, 2]$, partindo de $x_0 = 1.5$.

Solução:

(a) Para isso, precisamos verificar o Teorema de Bolzano e analisar o sinal da derivada no intervalo. De fato, $f(x)$ troca de sinal no intervalo $[0, 2]$, já que $f(0) = -2.08$ e $f(2) = 3.84$. Pelo teorema de Bolzano, existe pelo menos uma raiz no intervalo $[0, 2]$. Agora vamos analisar o sinal de $f'(x)$. Temos que $f'(x) = 2x + 0.96$ e podemos observar que $f'(x) = 2x + 0.96 > 0 \forall x \in [0, 2]$. Assim, $f(x)$ é crescente no intervalo $[0, 2]$ e possui uma raiz no intervalo $[0, 2]$.

(b) Para obter funções candidatas a função de iteração, vamos reescrever $f(x) = 0$ no formato $x = \phi(x)$. Assim,

$$x^2 + 0.96x - 2.08 = 0$$

temos a primeira candidata,

$$0.96x = 2.08 - x^2 \Rightarrow x = \frac{2.08 - x^2}{0.96} = \phi_1(x);$$

a segunda candidata,

$$x^2 = 2.08 - 0.96x \Rightarrow x = \frac{2.08 - 0.96x}{x} = \phi_2(x);$$

a terceira candidata,

$$x^2 = 2.08 - 0.96x \Rightarrow x = \sqrt{2.08 - 0.96x} = \phi_3(x);$$

a quarta candidata,

$$x(x + 0.96) = 2.08 \Rightarrow x = \frac{2.08}{x + 0.96} = \phi_4(x);$$

a quinta candidata,

$$x^2 + 0.96x + x - x - 2.08 = 0 \Rightarrow x = x^2 + 1.96x - 2.08 = \phi_5(x);$$

e a sexta candidata,

$$x^2 + x^2 - x^2 + 0.96x - 2.08 = 0 \Rightarrow x(2x + 0.96) = 2.08 + x^2 \Rightarrow x = \frac{2.08 + x^2}{2x + 0.96} = \phi_6(x).$$

(c) Agora, vamos obter a sequência de aproximações a partir da fórmula de recorrência $x_{n+1} = \phi(x_n)$, para $n = 0, 1, \dots$ e $x_0 = 1.5$.

i	$\phi_1(x)$	$\phi_2(x)$	$\phi_3(x)$	$\phi_4(x)$	$\phi_5(x)$	$\phi_6(x)$
1	-0.1771	0.4267	0.8	0.8455	3.11	1.0934
2	2.1340	3.9150	1.1454	1.1520	13.69	1.0409
3	-2.5770	-0.4287	0.9901	0.9848	212.1	1.04
4	-4.7512	-5.8118	1.0628	1.0695	—	—
5	-21.348	-1.3179	1.0294	1.0249	—	—
6	-472.554	-2.5383	1.0449	1.0479	—	—
7	—	-1.7795	1.0378	1.0359	—	—

Note que as funções de iteração $\phi_1(x)$, $\phi_2(x)$ e $\phi_5(x)$ não convergiram para a raiz 1.04. Já as funções $\phi_3(x)$, $\phi_4(x)$ e $\phi_6(x)$ convergem para a raiz da equação. Por que isso acontece? Como saber se ϕ fornece uma sequência de aproximações convergente?

Teorema 2 *Seja x^* uma raiz de uma função $f(x)$, isolada em um intervalo I e $\phi(x)$ uma função tal que $x^* = \phi(x^*)$. Se:*

1. ϕ e ϕ' são contínuas em I ,
2. $k = \max_{x \in I} |\phi'(x)| < 1$,
3. $x_0 \in I$ e $x_n = \phi(x_{n-1}) \in I, n = 1, 2, \dots$;

então a sequência x_n converge para x^* .

demonstração:

Para mostrar que $x_n \rightarrow x^*$ vamos mostrar que $|x_n - x^*| \rightarrow 0$. Vamos usar o Teorema do valor médio para delimitar o erro $|x_n - x^*|$.

TVM: Se f é contínua em $[a, b]$ e derivável em (a, b) então existe um $c \in (a, b)$ tal que $f(b) - f(a) = f'(c)(b - a)$.

Assim, $x_n - x^* = \phi(x_{n-1}) - \phi(x^*) = \phi'(c_n)(x_{n-1} - x^*)$, com $c_n \in (x_{n-1}, x^*)$ (Pela hipótese 1).

$$|x_n - x^*| = |\phi'(c_n)| |x_{n-1} - x^*|, \text{ como } x^*, x_{n-1} \in I \text{ (pela hipótese 3) então } c_n \in I.$$

Pela hipótese 2 temos que $|\phi'(c_n)| \leq k < 1$.

Assim, $|x_n - x^*| \leq k|x_{n-1} - x^*|, \forall n \geq 1$ então

$$|x_n - x^*| \leq k|x_{n-1} - x^*| \leq k(k|x_{n-2} - x^*|) \leq \dots \leq k^n|x_0 - x^*|.$$

Exemplo 15 *Determine uma aproximação para a raiz da função $f(x) = 2x - \cos(x)$, usando o método do ponto fixo.*

(1) Isolar a raiz: A função tem pelo menos uma raiz em $[0, \pi/2]$, pois $f(0) = -1$ e $f(\pi/2) = \pi$.

$f'(x) = 2 + \sin(x)$ é crescente em $[0, \pi/2]$. Portanto existe única raiz em $[0, \pi/2]$.

(2) Método do ponto fixo: Se $2x - \cos(x) = 0$ então $x = \cos(x)/2$. Assim, $\phi(x) = \cos(x)/2$ é uma candidata a função de iteração.

Condições do Teorema:

(i) $\phi(x) = \cos(x)/2$ e $\phi'(x) = -\sin(x)/2$ são contínuas.

(ii) $k = \max |\phi'(x)| = \sin(x)/2 \leq 0.5 < 1$.

(iii) Com $x_0 = 0$ temos $f(x_0) = -1$, $x_1 = \phi(x_0) = 0.5 \in [0, \pi/2]$ e $f(x_1) = 0.1224174381$. Continuando o procedimento, $x_2 = \phi(x_1) \approx 0.438791 \in [0, \pi/2]$, e assim por diante conforme a tabela a seguir.

(3) Aplicação do método:

n	x_n	$x_{n+1} = \phi(x_n) = \cos(x_n)/2$	$f(x_{n+1})$
0	0	0.5	
1	0.5	0.4387912809451864	
2	0.4387912809451864	0.4526329216602096	
3	0.4526329216602096	0.4496493762136596	
4	0.4496493762136596	0.4502997781314499	
5	0.4502997781314499	0.4501583343696809	

2.4 Método de Newton e suas variações

Nesta Seção vamos estudar o Método de Newton, que aproxima a raiz a partir de uma aproximação linear. O método de Newton pode não funcionar muito bem se $f'(x) \approx 0$. Dessa forma, também vamos estudar algumas variações deste método.

2.4.1 Método de Newton

O método de Newton é um caso particular do método das Aproximações Sucessivas. O método combina duas ideias básicas comuns nas aproximações numéricas: linearização e iteração. Na linearização, substituímos em uma vizinhança de α (raiz, solução de uma equação), um problema complicado por sua aproximação linear, que é mais fácil de ser resolvida.

A ideia é construir uma função de iteração $\phi(x)$ que satisfaça as condições do Teorema do Ponto Fixo. Para isso, vamos linearizar o problema, substituindo a cada iteração, a aproximação da raiz de f pela raiz de uma reta tangente a f .

Algebricamente, para deduzir a $\phi(x)$ do método de Newton, vamos impor que $\phi'(\alpha) = 0$. Como $\phi'(x)$ deve ser contínua, existe I tal que $k = \max_{x \in I} |\phi'(x)| < 1$. De forma geral,

$x = \phi(x)$ equivalente a $f(x) = 0$ será obtida,

$$f(x) = 0 \implies A(x)f(x) = x - x,$$

$$x = x + A(x)f(x) = \phi(x),$$

sendo $A(x)$ contínua e $A(\alpha) \neq 0$.

Agora vamos determinar $A(x)$ de forma que $\phi'(\alpha) = 0$. Derivando $\phi(x)$ obtemos,

$$\phi'(x) = 1 + A'(x)f(x) + A(x)f'(x).$$

Para $x = \alpha$ temos que,

$$\phi'(\alpha) = 1 + A'(\alpha)f(\alpha) + A(\alpha)f'(\alpha) = 0,$$


pois assumimos $\phi'(\alpha) = 0$. Como $f(\alpha) = 0$ e supondo que $f'(\alpha) \neq 0$, obtemos

$$\phi'(\alpha) = 1 + A(\alpha)f'(\alpha) = 0 \implies A(\alpha) = -\frac{1}{f'(\alpha)}.$$

Assim, escolhemos $A(x) = -\frac{1}{f'(x)}$. Portanto, a função de iteração do método de Newton é

$$x_{n+1} = x_n - \frac{f(x_n)}{f'(x_n)}$$

para $n = 0, 1, \dots$ e $x_0 \in I$ uma aproximação inicial.



Considere θ o ângulo entre a reta tangente a $f(x_0)$ e o eixo x , no ponto x_1 . A partir da interpretação geométrica do método, temos

$$\tan(\theta) = f'(x_0) = \frac{f(x_0) - 0}{x_0 - x_1} \implies x_1 = x_0 - \frac{f(x_0)}{f'(x_0)}$$

Assim, obtemos a fórmula de recorrência para o método de Newton,

$$x_{n+1} = x_n - \frac{f(x_n)}{f'(x_n)}, n = 0, 1, 2, \dots,$$

com x_0 uma aproximação inicial.

Exemplo 16 *Determinar uma aproximação para a raiz da função $f(x) = 2x - \cos(x)$, no intervalo $[0, \pi/2]$, usando o método de Newton.*

Solução:

Para a função de iteração do método de Newton precisamos determinar $f'(x)$. Nesse caso, $f'(x) = 2 + \sin(x)$. Assim, partindo de $x_0 = 0$, temos:

Primeira iteração, $x_0 = 0$, $f(x_0) = -1$ e $f'(x_0) = 2$. Portanto,

$$x_1 = x_0 - \frac{f(x_0)}{f'(x_0)} = 0.5.$$

Segunda iteração, $x_1 = 0.5$, $f(x_1) \approx 0.122417$ e $f'(x_1) \approx 2.474255$. Portanto,

$$x_2 = x_1 - \frac{f(x_1)}{f'(x_1)} = 0.450627.$$

Terceira iteração, $x_2 = 0.450627$, $f(x_2) \approx 0.00107905$ e $f'(x_2) \approx 2.43553$. Portanto,

$$x_3 = x_2 - \frac{f(x_2)}{f'(x_2)} = 0.450183.$$

Note que $f(x_3) \approx 8.835361 \times 10^{-8}$.


2.4.2 Método de Newton Modificado

No método de Newton modificado, substituímos a avaliação de $f'(x)$ por $f'(x_0)$ em todas as iterações. Portanto, a função de iteração é dada por,

$$x_{n+1} = x_n - \frac{f(x_n)}{f'(x_0)}, n = 0, 1, 2, \dots$$

e x_0 uma aproximação inicial.

Note que no gráfico todas as retas que fornecem uma aproximação, possuem a mesma inclinação da reta tangente em $f(x_0)$.



2.4.3 Método das Secantes

Uma outra alternativa, para se evitar o cálculo da derivada é utilizar retas secantes como aproximações lineares, no lugar das retas tangentes. Neste caso, vamos precisar de duas aproximações iniciais: x_0 e x_1 .

A ideia é substituir a inclinação da reta tangente pela inclinação da reta secante que passa pelos pontos $(x_0, f(x_0))$ e $(x_1, f(x_1))$, dada por $\frac{f(x_1) - f(x_0)}{x_1 - x_0}$. Assim,

$$x_2 = x_1 - \frac{f(x_1)}{\frac{f(x_1) - f(x_0)}{x_1 - x_0}}.$$

Reescrevendo a expressão obtemos,

$$x_2 = \frac{x_0 f(x_1) - x_1 f(x_0)}{f(x_1) - f(x_0)}.$$

Generalizando, para as próximas iterações,

$$x_{n+1} = \frac{x_{n-1} f(x_n) - x_n f(x_{n-1})}{f(x_n) - f(x_{n-1})}, n = 1, 2, \dots$$

e x_0 e x_1 aproximações iniciais.

2.4.4 Convergência dos métodos

Dizemos que uma sequência x_k converge para α com a ordem de convergência p se $\lim_{k \rightarrow \infty} \frac{e_{k+1}}{e_k^p} = C$, sendo C uma constante independente de k e $e_k = |x_k - \alpha|$, o erro absoluto da aproximação x_k .

Pode-se mostrar que, se a aproximação inicial está próxima da raiz e a função $f(x)$ tem regularidade suficiente (derivadas contínuas), então há garantia de convergência dos métodos de Newton e da Secante.

De forma geral, o método do Ponto Fixo possui convergência linear, $e_{k+1} \leq Ce_k$. Note que,

$$|x_{k+1} - \alpha| = |\phi(x_k) - \phi(\alpha)| = |\phi'(\xi)||x_k - \alpha| \leq k|x_k - \alpha|$$

A convergência do Método de Newton, quando $f'(\alpha) \neq 0$ é quadrática $e_{k+1} \leq Ce_k^2$, ou seja, $|x_{k+1} - \alpha| \leq C|x_k - \alpha|^2$. Neste caso, $p = 2$. Note que, da expansão em série de Taylor, em uma vizinhança de α , temos que,

$$\phi(x_n) = \phi(\alpha) + \phi'(\alpha)(x_n - \alpha) + \frac{\phi''(\alpha)}{2}(x_n - \alpha)^2 + \dots$$

Como $\phi'(\alpha) = 0$ e $|\phi''(x)| \leq M$, obtemos,

$$|\phi(x_n) - \phi(\alpha)| \leq \frac{M}{2}|x_n - \alpha|^2.$$

Assim,

$$|x_{n+1} - \alpha| \leq \frac{M}{2}|x_n - \alpha|^2.$$

Para o método da Secante, $e_{k+1} \leq Ce_k e_{k-1}$, uma convergência mais que linear, chamada superlinear. Neste caso, $1 < p < 2$.

Mais detalhes nas referências da disciplina.

Observações:

- **Crítérios de parada:** são expressões lógicas que em alguma iteração devem resultar no valor lógico *falso*. Como o nome já diz ele deve parar um comando de repetição. É importante incluirmos o número máximo de iterações para garantir que o processo termine, mas se este for o motivo do fim, algo não funcionou. Ou o método não convergiu ou fizemos algum cálculo incorreto.

Como o nosso problema consiste em determinar α tal que $f(\alpha) = 0$, um bom critério pode ser analisar $|f(x)|$, pois quando estivermos mais próximos de α , $|f(x)|$ estará próximo de zero. Assim, consideramos uma tolerância δ (um número suficientemente pequeno, por exemplo, 10^{-6}) e repetimos o processo iterativo *enquanto* $|f(x)| > \delta$.

Outro critério é considerar que a cada iteração estamos cada vez mais próximos de α . Dessa forma, a cada iteração a diferença entre duas aproximações consecutivas é cada vez menor. Ou seja, $|x - x_0|$ está cada vez mais próximo de zero. Assim, *enquanto* $|x - x_0| > \delta$ repetimos o processo.

- **Aproximação inicial x_0 :**

Para os métodos de ponto fixo (Aproximações Sucessivas), de acordo com o Teorema do Ponto Fixo $x_0 \in [a, b]$, sendo $[a, b]$ o intervalo que contém a raiz isolada. Para o

método de Newton, é importante que x_0 esteja próximo de α por conta da aproximação linear feita para a dedução do método. Mas como saber se estamos próximos da solução? Uma sugestão é avaliar $|f(x_0)|$ e verificar se este valor está próximo de zero. Lembre que a convergência do método de Newton é rápida.

2.4.5 Funções com derivadas nulas

O método de Newton possui a restrição de que $f'(\alpha) \neq 0$, onde α é a raiz de $f(x)$. Em particular o Método de Newton e o Método da secante, apresentarão problemas se $f'(\alpha) = 0$ quando $f(\alpha) = 0$.

Dizemos que uma solução α de $f(x) = 0$ é uma **raiz de multiplicidade** m da função f se, para $x \neq \alpha$, podemos escrever $f(x) = (x - \alpha)^m q(x)$, onde $\lim_{x \rightarrow \alpha} q(x) \neq 0$. Uma função tem uma **raiz simples** α no intervalo $[a, b]$ quando $f(\alpha) = 0$, mas $f'(\alpha) \neq 0$ [3].

O método de Newton perde a convergência quadrática quando utilizado para determinar aproximações para raízes com multiplicidade. Para isso, vamos ver algumas estratégias para contornar essa dificuldade, quando $\lim_{n \rightarrow \infty} f'(x_n) = 0$. Já que pelo método de Newton, a sequência de aproximações é dada por

$$x_{n+1} = x_n - \frac{f(x_n)}{f'(x_n)}.$$

- (a) Consideramos a função $g(x) = \frac{f(x)}{f'(x)}$. Se α anula $f(x)$ também anula a função $g(x)$.

Dessa forma, usando o método de Newton, vamos determinar a raiz de $g(x)$,

$$x_{n+1} = x_n - \frac{g(x_n)}{g'(x_n)} = x_n - \frac{\frac{f(x_n)}{f'(x_n)}}{\frac{f'(x_n)^2 - f(x_n)f''(x_n)}{f'(x_n)^2}}.$$

Assim,

$$x_{n+1} = x_n - \frac{f(x_n)f'(x_n)}{f'(x_n)^2 - f(x_n)f''(x_n)}.$$

- (b) Aplicar a Regra de L'Hospital: Sejam $f_1(x)$ e $f_2(x)$ contínuas e deriváveis em um intervalo I com $f_2'(x) \neq 0, \forall x \in I$ e seja $\alpha \in I$ tal que $f_1(\alpha) = f_2(\alpha) = 0$. Supondo que exista $\lim_{x \rightarrow \alpha} \frac{f_1'(x)}{f_2'(x)}$ então

$$\lim_{x \rightarrow \alpha} \frac{f_1(x)}{f_2(x)} = \lim_{x \rightarrow \alpha} \frac{f_1'(x)}{f_2'(x)}.$$

No nosso caso teremos, $\lim_{n \rightarrow \infty} \frac{f(x_n)}{f'(x_n)} = \lim_{n \rightarrow \infty} \frac{f'(x_n)}{f''(x_n)}$

Para mais métodos de aceleração de convergência, veja [1].

2.5 Aproximação de raízes de polinômios

Considere um polinômio de grau m dado por,

$$p_m(x) = a_mx^m + a_{m-1}x^{m-1} + \dots + a_2x^2 + a_1x + a_0,$$

com $a_m, a_{m-1}, \dots, a_2, a_1, a_0 \in \mathbb{R}$ e $a_m \neq 0$. Para utilizar o método de Newton, precisamos avaliar dois polinômios $p_m(x)$ e $p'_m(x)$. A avaliação de um polinômio pode ser feita da seguinte forma. Considere, $p_4(x) = a_4x^4 + a_3x^3 + a_2x^2 + a_1x + a_0$, para avaliar este polinômio neste formato, serão realizadas 14 operações. Se reescrevermos o polinômio no formato, $p_4(x) = (((a_4x + a_3)x + a_2)x + a_1)x + a_0$, reduzimos o número de operações para 8.

O Método de Horner para avaliar polinômios é baseado no seguinte resultado, dado pelo Teorema 2.19 [1]. Defina

$$\begin{aligned} b_n &= a_n \\ b_k &= a_k + b_{k+1}x_0 \quad \text{para } k = n-1, \dots, 0. \end{aligned}$$

Então, $b_0 = p(x_0)$. Além disso, se

$$q(x) = b_nx^{n-1} + b_{n-1}x^{n-2} + \dots + b_2x + b_1,$$

então, podemos reescrever,

$$p(x) = (x - x_0)q(x) + b_0.$$

De fato,

$$\begin{aligned} (x - x_0)q(x) + b_0 &= (x - x_0)(b_nx^{n-1} + \dots + b_2x + b_1) + b_0 \\ &= (b_nx^n + b_{n-1}x^{n-1} + \dots + b_2x^2 + b_1x) - (b_nx_0x^{n-1} + \dots + b_2x_0x + b_1x_0) + b_0 \\ &= b_nx^n + (b_{n-1} - b_nx_0)x^{n-1} + \dots + (b_1 - b_2x_0)x + (b_0 - b_1x_0) \end{aligned}$$

Comparando termo a termo com $p(x)$, temos $b_n = a_n$ e $b_k - b_{k+1}x_0 = a_k$ e quando $x = x_0$ temos $p(x_0) = b_0$.

Outra vantagem da utilização do procedimento de Horner é que, derivando a expressão anterior obtemos, $p'(x) = q(x) + (x - x_0)q'(x)$ e então $p'(x_0) = q(x_0)$.

Assim o método de Newton em conjunto com o método de Horner é dado por:

$$x_{n+1} = x_n - \frac{p(x_n)}{q(x_n)}$$

O Algoritmo 6 apresenta o método de Horner para avaliar um polinômio $p(x)$ e sua derivada em $p'(x)$ em x_0 .

Algoritmo 6: Método de Horner

 Entrada: n (grau do polinômio), $a_0, a_1, \dots, a_n$ (coeficientes) e x_0
 $y \leftarrow a_n$ $z \leftarrow a_n$ **para** $j = n - 1$ *até* 1 **faça** $y \leftarrow x_0 y + a_j$ $z \leftarrow x_0 z + y$ $y \leftarrow x_0 y + a_0$ Saída: $p(x_0) = y$ e $z = p'(x_0)$

Note que no algoritmo, a variável y armazena os coeficientes b_i .

Exemplo 17 Use o método de Horner para avaliar $p(x) = 2x^4 - 3x^2 + 3x - 4$, durante a aplicação do método de Newton, partindo de $x_0 = -2$.

Solução:

Vamos realizar duas iterações do método de Newton para aproximar uma raiz de $p(x)$. Podemos simular o método de Horner construindo uma tabela.

Primeira iteração:

$$x_1 = x_0 - \frac{p(x_0)}{p'(x_0)}.$$

Para isso, vamos usar o método de Horner para avaliar $p(x_0)$ e $p'(x_0)$.

Coef.	x^4	x^3	x^2	x	x^0	
$p(x_0)$	$a_4 = 2$	$a_3 = 0$	$a_2 = -3$	$a_1 = 3$	$a_0 = -4$	
$x_0 = -2$		$b_4 x_0 = -4$	$b_3 x_0 = 8$	$b_2 x_0 = -10$	$b_1 x_0 = 14$	
	$b_4 = 2$	$b_3 = -4$	$b_2 = 5$	$b_1 = -7$	$b_0 = 10$	$p(x_0) = 10$
$p'(x_0)$		2	-4	5	-7	
$x_0 = -2$			-4	16	-42	
		2	-8	21	-49	$p'(x_0) = -49$

Assim,

$$x_1 = -2 - \frac{10}{-49} \approx -1.795918.$$

Segunda iteração:

$$x_2 = x_1 - \frac{p(x_1)}{p'(x_1)}.$$

Para isso, vamos usar o método de Horner para avaliar $p(x_1)$ e $p'(x_2)$.

Coef.	x^4	x^3	x^2	x	x^0	
$p(x_1)$	$a_4 = 2$	$a_3 = 0$	$a_2 = -3$	$a_1 = 3$	$a_0 = -4$	
$x_1 = -1.795918$		$b_4x_1 = -3.591836$	$b_3x_1 = 6.450643$	$b_2x_1 = -6.197072$	$b_1x_1 = 5.741679$	
	$b_4 = 2$	$b_3 = -3.591836$	$b_2 = 3.450643$	$b_1 = -3.197072$	$b_0 = 1.741679$	$p(x_1)$
$p'(x_1)$		2	-3.591836	3.450643	-3.197072	
$x_1 = -1.795918$			-3.591836	12.90128	-29.3667	
		2	-7.183672	16.35192	-32.56638	$p'(x_1)$

Assim,

$$x_2 = -1.795918 - \frac{1.741679}{-32.56638} \approx -1.742437.$$

2.6 Método de Müller

O método de Müller para a determinação de raízes de equações é uma extensão do método da secante e pode ser utilizado para aproximar raízes complexas. A ideia é partir de três aproximações iniciais: x_0, x_1 e x_2 e calcular x_3 como a raiz da parábola que passa pelos pontos $(x_0, f(x_0)), (x_1, f(x_1))$ e $(x_2, f(x_2))$. Para isso, considere a parábola, dada por: $p(x) = a(x - x_2)^2 + b(x - x_2) + c$. As constantes a , b e c são determinadas pelas equações:

$$f(x_0) = a(x_0 - x_2)^2 + b(x_0 - x_2) + c,$$

$$f(x_1) = a(x_1 - x_2)^2 + b(x_1 - x_2) + c,$$

$$f(x_2) = a(x_2 - x_2)^2 + b(x_2 - x_2) + c \implies c = f(x_2).$$

Para determinar a e b , substituímos c nas expressões de $f(x_0)$ e $f(x_1)$ e dividindo as expressões, respectivamente, por $(x_0 - x_2)$ e $(x_1 - x_2)$, obtemos:

$$(A) \quad \frac{f(x_0) - f(x_2)}{x_0 - x_2} = a(x_0 - x_2) + b,$$

$$(B) \quad \frac{f(x_1) - f(x_2)}{x_1 - x_2} = a(x_1 - x_2) + b.$$

Fazendo (A)–(B) obtemos $a = \frac{q_0 - q_1}{x_0 - x_1}$, com $q_0 = \frac{f(x_0) - f(x_2)}{x_0 - x_2}$ e $q_1 = \frac{f(x_1) - f(x_2)}{x_1 - x_2}$.

Substituindo a na equação (A), obtemos $b = \frac{q_0(x_2 - x_1) + q_1(x_0 - x_2)}{x_0 - x_1}$. Note que as raízes de $p(x)$ são dadas por,

$$x - x_2 = \frac{-b \pm \sqrt{b^2 - 4ac}}{2a}.$$

Para evitar possíveis erros de arredondamento racionalizamos o numerador da expressão, ou seja, multiplicamos numerador e denominador por $-b \mp \sqrt{b^2 - 4ac}$. Assim obtemos,

$$\alpha_1 - x_2 = \frac{-2c}{b + \sqrt{b^2 - 4ac}} \text{ e } \alpha_2 - x_2 = \frac{-2c}{b - \sqrt{b^2 - 4ac}}.$$

No Método de Müller a próxima aproximação da raiz é escolhida de acordo com o sinal do coeficiente b . Esta escolha garante que o denominador será maior em magnitude e resultará na aproximação da raiz mais próxima da raiz anterior. Dessa forma,

$$x_3 = x_2 - \frac{2c}{b + \operatorname{sgn}(b)\sqrt{b^2 - 4ac}},$$

sendo $\operatorname{sgn}(b) = b/|b|$. Portanto, a sequência de aproximações é dada por,

$$x_{n+1} = x_n - \frac{2c}{b + \operatorname{sgn}(b)\sqrt{b^2 - 4ac}}, \text{ para } n = 2, 3, \dots,$$

com os coeficientes a , b e c , calculados com $x_2 = x_n$, $x_1 = x_{n-1}$ e $x_0 = x_{n-2}$. Note que são necessárias três aproximações iniciais: x_0 , x_1 e x_2 para que o método possa ser iniciado.

Uma das vantagens do método de Muller é que podemos aproximar raízes complexas.

Leitura recomendada:

- Noções de Cálculo Numérico. Capítulo 2 [2].
- Cálculo Numérico Computacional. Capítulo 3 [6].
- Análise Numérica. Capítulo 2 [1].

2.7 Exercícios

1. Sobre o método da Bissecção, dado o intervalo $[a, b]$:

(a) Mostre que vale a igualdade $|x_n - x_{n-1}| = \frac{b-a}{2^{n+1}}$.

- (b) Mostre que o número de iterações n , para que $|\alpha - x_n| < \epsilon$, deve satisfazer

$$n \geq \frac{\ln((b-a)/\epsilon)}{\ln 2} - 1.$$

2. Dada a função $f(x) = x^3 + 3x - 2$ pede-se:

- (a) Determine um intervalo I que contenha somente a primeira raiz α positiva de $f(x)$. Justifique.

- (b) Faça quatro iterações do método da Bissecção.

- (c) Faça quatro iterações do método da Falsa Posição. E compare os resultados com o item (b).

3. Determine uma aproximação para a raiz α das funções $f(x)$, usando o método da Bissecção, Falsa Posição, Newton, Newton Modificado e Método da Secante. Faça até quatro iterações ou até que $|f(x_n)| < 10^{-4}$.

(a) $f(x) = x^2 + \sin(x) - 5$, $\alpha \in [1.2, 2.4]$.

(b) $f(x) = x^3 - 2x^2 - 20x + 30$, $\alpha \in [1.3, 4.8]$.

(c) $f(x) = xe^{-x} - e^{-3}$, $\alpha \in [4, 5]$.

4. Dada $f(x) = \ln(x) + x - 4$, pede-se:

(a) Mostre que f possui único zero em $I = [2, 4]$.

(b) Considere a fórmula de recorrência

$$x_{n+1} = x_n + cf(x_n).$$

Determine um intervalo para c de forma que a sequência gerada convirja, tomando-se x_0 o extremo mais próximo da raiz.

(c) Utilizando (b) com $c = -1$ e tomando-se x_0 convenientemente, calcule três iterações.

(d) Calcule a raiz real de f com o método de Newton com erro inferior a 0.001.

5. Dada a função

$$f(x) = \frac{5}{x} - 0.6x - 2,$$

pede-se:

(a) Determine um intervalo que contenha apenas uma raiz desta função. Justifique.

(b) A sequência gerada por

$$x_{n+1} = \phi(x_n) = \frac{5}{0.6x_n + 2},$$

converge para a raiz α , escolhendo-se $x_0 \neq \alpha$? Justifique.

(c) Faça três iterações do processo.

6. A função $f(x) = xe^{-x} - e^{-3}$, com $x \in \mathbb{R}$, possui duas raízes reais: $\alpha_1 \in [0.01, 1]$ e $\alpha_2 \in [4, 5]$. Considere as funções $\phi_1(x) = e^{x-3}$ e $\phi_2(x) = \ln(x) + 3$.

(a) ϕ_1 pode ser usada para aproximar α_1 , pelo método das Aproximações Sucessivas, com garantia de convergência? E ϕ_2 ? Justifique.

(b) ϕ_1 pode ser usada para aproximar α_2 , pelo método das Aproximações Sucessivas, com garantia de convergência? E ϕ_2 ? Justifique.

7. Dada a função $f(x) = x^2 - 2$, determine um intervalo $[a, b]$ e uma condição inicial $x_0 \neq \alpha$ de modo que

$$x_{n+1} = x_n - \frac{f(x_n)}{f'(x_n)},$$

convirja para a raiz α de $f(x)$. Justifique.

Faça as iterações, verificando se é possível utilizar a precisão de $\delta = 0.001$.

8. Mostre que a sequência

$$x_{n+1} = \frac{1}{p} \left((p-1)x_n + \frac{a}{x_n^{p-1}} \right),$$

pode ser usada para aproximar $\sqrt[p]{a}$, com $a \geq 0$.

Use esta fórmula de recorrência para a aproximar $\sqrt[3]{8}$.

9. Use o método de Newton para determinar o ponto de máximo global do polinômio

$$p(x) = -2x^4 + 6x^3 - 5x^2 + 14x - 1$$

, sabendo que ele é um ponto crítico de f isolado no intervalo $[1, 3]$.

10. O método de Newton pode ser usado para funções de uma variável complexa a valores complexos $f(z)$, com $z = x + iy$, x e y reais):

- (a) Se for desejável evitar o uso de aritmética complexa, mostre que

$$\begin{cases} x_{n+1} = x_n - \frac{A_n C_n + B_n D_n}{C_n^2 + D_n^2}, \\ y_{n+1} = y_n - \frac{B_n C_n - A_n D_n}{C_n^2 + D_n^2}, \end{cases}$$

com $f(z_n) = A_n + iB_n$ e $f'(z_n) = C_n + iD_n$ a decomposição em partes real e imaginária.

- (b) Use o método de Newton, descrito no item (a), para determinar uma aproximação para a raiz de $p(z) = z^4 - 3z^3 + 20z^2 + 44z + 54$ localizado em uma vizinhança de $z_0 = 2.5 + 4.5i$.

UNIDADE 3

SISTEMAS DE EQUAÇÕES LINEARES


Nesta unidade vamos estudar métodos numéricos para determinar a solução de um sistema de equações lineares, na forma matricial, dado por $A\mathbf{x} = \mathbf{b}$, sendo $\mathbf{x} = (x_1, x_2, \dots, x_n)$ a solução do problema, com $\mathbf{x} \in \mathbb{R}^n$, $\mathbf{b} \in \mathbb{R}^n$ um vetor conhecido (dado do problema) e A uma matriz de coeficientes, $n \times n$. O tema de sistemas lineares é fundamental em diversos problemas de aplicação das diversas áreas da ciência, como engenharias, Física, Economia, Ciências Sociais, entre outras.

Vamos estudar métodos **diretos**, que fornecem uma solução após um número finito de passos e os métodos **iterativos**, que fornecem uma sequência de soluções aproximadas.

Esta unidade está organizada da seguinte forma. Na Seção 3.1 vamos apresentar um problema prático e um pouco da teoria básica para a solução de sistemas de equações lineares. Na Seção 3.2 vamos estudar métodos diretos para resolver o problema. Na Seção 3.4, alguns métodos iterativos, como o de Jacobi, Gauss-Seidel e SOR. Uma lista de exercícios, na Seção 3.3, encerra o capítulo.

3.1 Motivação

Nas mais diversas áreas ocorrem situações que envolvem a solução de um sistema de equações lineares. Vamos considerar a distribuição de temperatura, em regime permanente, em uma barra delgada, isolada termicamente, com 1m de comprimento e temperaturas constantes nas extremidades (esquerda 50°C e direita 0°C). Este problema é modelado por uma Equação Diferencial Parcial (EDP). O primeiro passo para aproximar a solução é discretizarmos o problema, dividindo a barra uniformemente e, conforme a representação abaixo com $N = 10$.



Após aproximarmos as derivadas em cada ponto x_i da barra pelo Método de Diferenças Finitas (baseado na Série de Taylor) e fazendo mais uma simplificação de que a temperatura em cada x_i é a média aritmética da temperaturas vizinhas, o problema discreto é dado pelo sistema de equações,

$$-T_{i-1} + 2T_i - T_{i+1} = 0, \text{ para } i = 1, 2, \dots, N-1,$$

onde T_i representa a temperatura da barra no ponto x_i e N a quantidade de partições da barra. Note que nos pontos x_0 e x_N a temperatura T é conhecida. Se reescrevemos a expressão obtemos,

$$\begin{aligned} 2T_1 - T_2 &= T_0, \\ -T_{i-1} + 2T_i - T_{i+1} &= 0, \quad i = 1, \dots, N-1, \\ -T_{N-2} + 2T_{N-1} &= T_N, \end{aligned}$$

Na forma matricial,

$$\begin{pmatrix} 2 & -1 & 0 & 0 & 0 & 0 & 0 \\ -1 & 2 & -1 & 0 & 0 & 0 & 0 \\ & \ddots & \ddots & & & & \\ & & \ddots & \ddots & & & \\ & & & \ddots & \ddots & & \\ 0 & 0 & 0 & 0 & -1 & 2 & -1 \\ 0 & 0 & 0 & 0 & 0 & -1 & 2 \end{pmatrix} \begin{pmatrix} T_1 \\ T_2 \\ \vdots \\ \vdots \\ T_{N-2} \\ T_{N-1} \end{pmatrix} = \begin{pmatrix} T_0 \\ 0 \\ \vdots \\ \vdots \\ 0 \\ T_N \end{pmatrix}$$

Este é um exemplo em que a matriz possui uma estrutura especial, apenas as três diagonais principais com elementos diferentes de zero. Os demais elementos são todos nulos. Isso define uma matriz esparsa, uma matriz que possui a maioria dos elementos nulos. Em especial a matriz deste exemplo é uma matriz tridiagonal. Na Seção ?? estudaremos estratégias para aproveitar a vantagem de se ter uma matriz esparsa em termos computacionais.

Um sistema linear com n equações e n incógnitas pode ser escrito,

$$\begin{cases} a_{11}x_1 + a_{12}x_2 + \dots + a_{1n}x_n = b_1 \\ a_{21}x_1 + a_{22}x_2 + \dots + a_{2n}x_n = b_2 \\ \vdots \\ a_{n1}x_1 + a_{n2}x_2 + \dots + a_{nn}x_n = b_n \end{cases}$$

Problema: Determinar $\mathbf{x} \in \mathbb{R}^n$, sendo dados $A \in \mathbb{R}^{n \times n}$ (A uma matriz de coeficientes, não singular) e $\mathbf{b} \in \mathbb{R}^n$ tais que $A\mathbf{x} = \mathbf{b}$.

Como A é não singular, isso significa que A possui uma matriz inversa A^{-1} . Assim, tecnicamente, $\mathbf{x} = A^{-1}\mathbf{b}$. Na prática, ou seja computacionalmente, não determinamos A^{-1} , pois é muito caro computacionalmente.

3.2 Métodos Diretos

Métodos diretos fornecem uma solução aproximada após um número finito de passos. Como por exemplo, o Método de Cramer e o Método de Eliminação de Gauss. Teoricamente um método direto deveria fornecer a solução exata do sistema. Entretanto, na prática as soluções conterão erros de arredondamento devido a aritmética de ponto flutuante. Estudaremos estratégias para analisar e controlar este tipo de erro.

3.2.1 Método de Cramer

O método de Cramer é baseado no cálculo de determinantes. A solução do sistema de equações lineares $A\mathbf{x} = \mathbf{b}$ é dado por,

$$x_i = \frac{D_i}{D}, \quad \text{com } i = 1, 2, \dots, n,$$

onde $D = \det(A)$, $D_i = \det(A_i)$ e A_i é a matriz com a i -ésima coluna substituída pelo vetor $\mathbf{b}$.

O determinante de uma matriz $n \times n$ pode ser calculado pela regra de Laplace:

$$\det(A) = \sum_{j=1}^n (-1)^{i+j} a_{ij} \det(A_{ij}),$$

sendo i uma linha qualquer fixada e A_{ij} uma submatriz de A retirando-se a i -ésima linha e a j -ésima coluna. Por exemplo, considere

$$A = \begin{pmatrix} 4 & -1 & 1 \\ 2 & 5 & 2 \\ 1 & 2 & 4 \end{pmatrix}.$$

Ao fixarmos a linha 1, na matriz A , obtemos as seguintes três submatrizes 2×2 ,

$$A = \begin{pmatrix} \color{red}{4} & \color{red}{-1} & \color{red}{1} \\ \color{red}{2} & 5 & 2 \\ \color{red}{1} & 2 & 4 \end{pmatrix} \Rightarrow A_{11} = \begin{pmatrix} 5 & 2 \\ 2 & 4 \end{pmatrix}, \quad A = \begin{pmatrix} \color{red}{4} & \color{red}{-1} & \color{red}{1} \\ 2 & \color{red}{5} & 2 \\ 1 & \color{red}{2} & 4 \end{pmatrix} \Rightarrow A_{12} = \begin{pmatrix} 2 & 2 \\ 1 & 4 \end{pmatrix}, \quad \text{e}$$

$$A = \begin{pmatrix} \color{red}{4} & \color{red}{-1} & \color{red}{1} \\ 2 & 5 & \color{red}{2} \\ 1 & 2 & \color{red}{4} \end{pmatrix} \Rightarrow A_{13} = \begin{pmatrix} 2 & 5 \\ 1 & 2 \end{pmatrix}.$$

Assim, pela regra de Laplace temos,

$$\det(A) = (-1)^{1+1} a_{11} \det(A_{11}) + (-1)^{1+2} a_{12} \det(A_{12}) + (-1)^{1+3} a_{13} \det(A_{13}),$$

ou seja, $\det(A) = (-1)^2(4)(5 \times 4 - 2 \times 2) + (-1)^3(-1)(2 \times 4 - 2 \times 1) + (-1)^4(1)(2 \times 2 - 5 \times 1) = 64 + 6 - 1 = 69$.

Além disso, uma matriz A com $\det(A) \neq 0$ é não singular, ou seja adn=mite inversa. Assim, se $\det(A) \neq 0$, o sistema possui única solução (determinado). Se $\det(A) = 0$ então temos duas possibilidades:

- o sistema não possui solução (sistema inconsistente).
- o sistema possui infinitas soluções (sistemas indeterminado).

Note que, se $D = \det(A) = 0$ e para um $D_i = 0$, $Dx_i = D_i$ é uma expressão válida para qualquer x . Isso indica que x_i é um parâmetro livre e o sistema possuirá infinitas soluções que dependem de x_i . Por outro lado, se $D = 0$ e todo $D_i \neq 0$ temos uma inconsistência, pois não existe x_i tal que $Dx_i = D_i$. Na Seção 3.2.3 vamos discutir uma outra forma de fazer esta análise, já que o cálculo de determinante também é um processo com alto custo computacional.

Agora vamos aplicar o método de Cramer e concluir que ele não deve ser usado para sistemas maiores que 3×3 , por conta do seu custo computacional.

Exemplo 18 Use o método de Cramer para resolver o sistema

$$\begin{cases} x_1 + 2x_2 = 3 \\ 2x_1 - 3x_2 = -1 \end{cases}$$

Solução:

As matriz A e as matrizes auxiliares A_1 e A_2 são dadas por,

$$A = \begin{pmatrix} 1 & 2 \\ 2 & -3 \end{pmatrix}, A_1 = \begin{pmatrix} 3 & 2 \\ -1 & -3 \end{pmatrix} \text{ e } A_2 = \begin{pmatrix} 1 & 3 \\ 2 & -1 \end{pmatrix}.$$

Assim, temos $D = \det(A) = 1 \times (-3) - 2 \times 2 = -7$, $D_1 = \det(A_1) = 3 \times (-3) - 2 \times (-1) = -7$ e $D_2 = \det(A_2) = 1 \times (-1) - 3 \times 2 = -7$. Portanto,

$$x_1 = \frac{D_1}{D} = 1 \text{ e } x_2 = \frac{D_2}{D} = 1,$$

são a solução do sistema.

No exemplo anterior com um sistema com duas incógnitas foi fácil aplicar o método. Entretanto, o método é inviável, se o n (número de incógnitas) é grande. Vamos contar o número de operações (somadas e multiplicações) que o método executa para termos o custo computacional do mesmo.

Considere A_n o número de adições e M_n o número de multiplicações para o cálculo do determinante. Em [2] os autores apresentam as seguintes relações de recorrência $A_n = n - 1 + nA_{n-1}$ e $M_n = n + nM_{n-1}$, com $A_1 = M_1 = 0$. Considere $\Delta_n = A_n + M_n$ o número de operações para o cálculo de um determinante e $S_n = (n + 1)\Delta_n + n$ o número total de operações para a solução do sistema. Note que, precisamos calcular $n + 1$ determinantes e mais n divisões para determinar as n soluções. A Tabela a seguir apresenta o número de operações para diferentes tamanhos de sistema [2].

n	M_n	A_n	Δ_n	S_n
2	2	1	3	11
3	9	5	14	59
4	40	23	63	319
5	205	119	224	1349
$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$
10	5605300	3628799	9234099	101575099
$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$

Note que para um sistema com 10 equações o método executa mais de 100 milhões de operações. Se gastarmos um segundo para realizar cada operação, a solução desse sistema é obtida em aproximadamente 1175 dias. O tempo de computação também é proibitivo com o uso do computador. Assim, vale ressaltar a importância da escolha de um método.

3.2.2 Método para sistemas lineares triangulares

Um sistema linear **triangular superior** é dado por,

$$\left\{ \begin{array}{lcl} a_{11}x_1 + a_{12}x_2 + \dots + a_{1,n-1}x_{n-1} + a_{1n}x_n & = & b_1 \\ & a_{22}x_2 + \dots + a_{2,n-1}x_{n-1} + a_{2n}x_n & = b_2 \\ & & \ddots \\ & & a_{n-1,n-1}x_{n-1} + a_{n-1,n}x_n & = b_{n-1} \\ & & & a_{nn}x_n & = b_n \end{array} \right.$$

Ou seja, os elementos da matriz A , acima da diagonal principal são nulos. Ou seja, $a_{ij} = 0$ quando $i > j$. Admitindo $a_{ii} \neq 0$, para $i = 1 : n$, podemos usar o **método da substituição inversa**, dado por,

$$\begin{aligned} x_n &= b_n/a_{nn} \\ x_{n-1} &= (b_{n-1} - a_{n-1,n}x_n)/a_{n-1,n-1} \\ &\vdots \\ x_1 &= (b_1 - a_{1n}x_n - \dots - a_{13}x_3 - a_{12}x_2)/a_{11} \end{aligned}$$

Algoritmo 7: Método da substituição inversa

Entrada: $A \in \mathbb{R}^{n \times n}$ com $a_{ij} = 0$ (se $i > j$), $a_{ii} \neq 0$, e $\mathbf{b}$

$$x_n \leftarrow \frac{b_n}{a_{nn}}$$

$s \leftarrow 0$

para $k = n - 1$ **até** 1 **faça**

$$\left| \begin{array}{l} s \leftarrow b_k \\ \textbf{para } j = k + 1 \textbf{ até } n \textbf{ faça} \\ \quad s \leftarrow s - a_{kj}x_j \\ \quad x_k \leftarrow \frac{s}{a_{kk}} \end{array} \right.$$

Saída: $\mathbf{x}$

Um sistema linear triangular inferior é dado por,

$$\begin{cases} a_{11}x_1 & & & & = & b_1 \\ a_{21}x_1 & + & a_{22}x_2 & & = & b_2 \\ \vdots & & \vdots & \ddots & & \\ a_{1,n-1}x_1 & + & a_{2,n-1}x_2 & + & \dots & + & a_{n-1,n}x_{n-1} & = & b_{n-1} \\ a_{1,n}x_1 & + & a_{2,n}x_2 & + & \dots & + & a_{n-1,n}x_{n-1} & + & a_{nn}x_n & = & b_n \end{cases}$$

Ou seja, os elementos da matriz A , abaixo da diagonal principal são nulos. Ou seja, $a_{ij} = 0$ quando $i < j$. Admitindo $a_{ii} \neq 0$, para $i = 1 : n$, podemos usar o **método da substituição direta**, dado por,

$$\begin{aligned} x_1 &= b_1/a_{11} \\ x_2 &= (b_2 - a_{21}x_1)/a_{22} \\ &\vdots \\ x_n &= (b_n - a_{1n}x_1 - a_{2n}x_2 - \dots - a_{n-1,n}x_{n-1})/a_{nn} \end{aligned}$$

Algoritmo 8: Método da substituição direta

Entrada: $A \in \mathbb{R}^{n \times n}$ com $a_{ij} = 0$ (se $i < j$), $a_{ii} \neq 0$, e $\mathbf{b}$

$$x_1 \leftarrow \frac{b_1}{a_{11}}$$

$s \leftarrow 0$

para $k = 2$ *até* n **faça**

$s \leftarrow b_k$

para $j = 1$ *até* $k - 1$ **faça**

$s \leftarrow s - a_{kj}x_j$

$x_k \leftarrow \frac{s}{a_{kk}}$

Saída: $\mathbf{x}$

O número de operações para a solução de sistemas triangulares $n \times n$ é aproximadamente n^2 , ou seja, $O(n^2)$.

3.2.3 Método de Eliminação de Gauss

A ideia do método de Eliminação de Gauss é transformar um sistema de equações lineares em um sistema triangular superior por meio de operações elementares.

Propriedade: A solução do sistema $A\mathbf{x} = \mathbf{b}$ não se altera se o submetemos a uma sequência de operações elementares:

- (1) Multiplicar uma equação por uma constante não-nula.
- (2) Somar uma equação multiplicada por uma constante à outra equação.
- (3) Trocar a ordem das equações.

Na forma matricial, o sistema de equações pode ser escrito:

$$\begin{pmatrix} a_{11} & a_{12} & \dots & a_{1,n-1} & a_{1n} \\ a_{21} & a_{22} & \dots & a_{2,n-1} & a_{2n} \\ & & \ddots & & \\ a_{n-1,1} & a_{n-1,2} & \dots & a_{n-1,n-1} & a_{n-1,n} \\ a_{n,1} & a_{n,2} & \dots & a_{n,n-1} & a_{nn} \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \\ \vdots \\ x_{n-1} \\ x_n \end{pmatrix} = \begin{pmatrix} b_1 \\ b_2 \\ \vdots \\ b_{n-1} \\ b_n \end{pmatrix}$$

O **objetivo** do método é transformar um sistema linear em um sistema triangular superior equivalente,

$$\begin{pmatrix} a_{11} & a_{12} & \dots & a_{1,n-1} & a_{1n} \\ & a_{22}^{(1)} & \dots & a_{2,n-1}^{(1)} & a_{2n}^{(1)} \\ & & \ddots & & \vdots \\ & & & a_{nn}^{(n-1)} & \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \\ \vdots \\ x_{n-1} \\ x_n \end{pmatrix} = \begin{pmatrix} b_1 \\ b_2^{(1)} \\ \vdots \\ b_{n-1}^{(n-2)} \\ b_n^{(n-1)} \end{pmatrix} \quad (3.1)$$

onde $^{(k)}$ indica que os elementos a_{ij} e b_i sofreram k alterações por meio de operações elementares.

Vamos apresentar o método utilizando a matriz aumentada. No primeiro passo (**P1**) queremos zerar todos os elementos da primeira coluna de A abaixo da diagonal principal.

$$\left(\begin{array}{cccccc|c} a_{11} & a_{12} & a_{13} & \dots & a_{1,n-1} & a_{1n} & b_1 \\ a_{21} & a_{22} & a_{23} & \dots & a_{2,n-1} & a_{2n} & b_2 \\ a_{31} & a_{32} & a_{33} & \dots & a_{3,n-1} & a_{3n} & b_3 \\ & & \vdots & & & & \vdots \\ a_{n-1,1} & a_{n-1,2} & a_{n-1,3} & \dots & a_{n-1,n-1} & a_{n-1,n} & b_{n-1} \\ a_{n,1} & a_{n,2} & a_{n,3} & \dots & a_{n,n-1} & a_{nn} & b_n \end{array} \right)$$

Operação sobre as linhas i de 2 até n :

$$a_{ij}^{(1)} = a_{ij} - m_{i1} \times a_{1j}, \quad (3.2)$$

onde $m_{i1} = \left(\frac{a_{i1}}{a_{11}} \right)$ é chamado multiplicador. A operação 3.2 faz com que todos os elementos da primeira coluna, abaixo da diagonal principal, sejam nulos. Assim,

$$L_2 \leftarrow L_2 - \frac{a_{21}}{a_{11}} L_1; \quad L_3 \leftarrow L_3 - \frac{a_{31}}{a_{11}} L_1; \quad \dots$$

Assim, obtemos

$$\left(\begin{array}{cccccc|c} a_{11} & a_{12} & a_{13} & \dots & a_{1,n-1} & a_{1n} & b_1 \\ 0 & a_{22}^{(1)} & a_{23}^{(1)} & \dots & a_{2,n-1}^{(1)} & a_{2n}^{(1)} & b_2^{(1)} \\ 0 & a_{32}^{(1)} & a_{33}^{(1)} & \dots & a_{3,n-1}^{(1)} & a_{3n}^{(1)} & b_3^{(1)} \\ & & \vdots & & & & \vdots \\ 0 & a_{n-1,2}^{(1)} & a_{n-1,3}^{(1)} & \dots & a_{n-1,n-1}^{(1)} & a_{n-1,n}^{(1)} & b_{n-1}^{(1)} \\ 0 & a_{n,2}^{(1)} & a_{n,3}^{(1)} & \dots & a_{n,n-1}^{(1)} & a_{nn}^{(1)} & b_n^{(1)} \end{array} \right)$$

No segundo passo (**P2**) queremos zerar todos os elementos da segunda coluna da matriz equivalente a A (ou seja, A após o passo (**P1**)) abaixo da diagonal principal. A operação sobre as linhas i de 3 até n é dada por,

$$a_{ij}^{(2)} = a_{ij}^{(1)} - m_{i2} \times a_{2j}^{(1)}, \quad (3.3)$$

onde $m_{i2} = \left(\frac{a_{i2}}{a_{22}}\right)$. A operação 3.3 faz com que todos os elementos da segunda coluna, abaixo da diagonal principal, sejam nulos. Assim,

$$L_3 \leftarrow L_3 - \frac{a_{32}}{a_{22}}L_2; \quad L_4 \leftarrow L_4 - \frac{a_{42}}{a_{22}}L_2; \quad \dots$$

$$\left(\begin{array}{cccccc|c} a_{11} & a_{12} & a_{13}^{(1)} & \dots & a_{1,n-1} & a_{1n} & b_1 \\ 0 & a_{22}^{(1)} & a_{23}^{(1)} & \dots & a_{2,n-1}^{(1)} & a_{2,n}^{(1)} & b_2^{(1)} \\ 0 & 0 & a_{33}^{(2)} & \dots & a_{3,n-1}^{(2)} & a_{3,n}^{(2)} & b_3^{(2)} \\ & & \vdots & & & & \vdots \\ 0 & 0 & a_{n-1,3}^{(2)} & \dots & a_{n-1,n-1}^{(2)} & a_{n-1,n}^{(2)} & b_{n-1}^{(2)} \\ 0 & 0 & a_{n,3}^{(2)} & \dots & a_{n,n-1}^{(2)} & a_{nn}^{(2)} & b_n^{(2)} \end{array} \right)$$

Aplicando o processo mais $(n-3)$ vezes (para as colunas restantes) obtemos um sistema triangular superior equivalente no formato matriz aumentada que respresenta o sistema dado em 3.1.

$$\left(\begin{array}{cccccc|c} a_{11} & a_{12} & a_{13}^{(1)} & \dots & a_{1,n-1} & a_{1n} & b_1 \\ 0 & a_{22}^{(1)} & a_{23}^{(1)} & \dots & a_{2,n-1}^{(1)} & a_{2,n}^{(1)} & b_2^{(1)} \\ 0 & 0 & a_{33}^{(2)} & \dots & a_{3,n-1}^{(2)} & a_{3,n}^{(2)} & b_3^{(2)} \\ & & \vdots & \ddots & & & \vdots \\ 0 & 0 & 0 & \dots & a_{n-1,n-1}^{(n-2)} & a_{n-1,n}^{(n-2)} & b_{n-1}^{(n-2)} \\ 0 & 0 & 0 & \dots & 0 & a_{nn}^{(n-1)} & b_n^{(n-1)} \end{array} \right) \quad (3.4)$$

O sistema triangular superior equivalente é resolvido pelo método da substituição inversa. Note que a partir da matriz aumentada conseguimos extrair algumas informações quanto a solução do sistema e determinante da matriz A .

O determinante de uma matriz triangular é igual ao produto da diagonal principal, ou seja, $\det(A) = \prod_{i=1}^n a_{ii}$. No método de Eliminação de Gauss realizamos operações elementares sobre as linhas da matriz aumentada para obter um sistema triangular superior equivalente. Destas operações, as únicas que alteram o valor do determinante são as operações: (1) multiplicar uma linha da matriz por uma constante e (3) trocar as linhas da matriz.

Considere duas matrizes A e B , se B é obtida a partir da multiplicação de uma linha (ou uma coluna) de A por um escalar α (operação (1)) então $\det(B) = \alpha \det(A)$. Se B é obtida a partir de A por meio de uma troca de linhas (ou de colunas) (operação (3)) então $\det(B) = -\det(A)$.

O método de Eliminação de Gauss é um método direto e o tipo de erro envolvido é o erro de arredondamento, que pode ser desastroso. O algoritmo 9 apresenta o método de Eliminação de Gauss.

Algoritmo 9: Método de Eliminação de GaussEntrada: $A \in \mathbb{R}^{n \times n}$ e $\mathbf{b}$ **para** $k = 1$ até $n - 1$ **faça** **para** $i = k + 1$ até n **faça**

$$m_{ik} \leftarrow \frac{a_{ik}}{a_{kk}}$$

para $j = k + 1$ até n **faça**

$$a_{ij} \leftarrow a_{ij} - m_{ik}a_{kj}$$

$$b_i \leftarrow b_i - m_{ik}b_k$$

Saída: A triangular superior equivalente e $\mathbf{b}$ modificado

O número de operações do Método de Eliminação de Gauss para um sistema de n equações e n incógnitas é aproximadamente n^3 , ou seja, $O(n^3)$.

Vamos usar o método de Eliminação de Gauss e substituição inversa para resolver os sistemas lineares a seguir,

Exemplo 19 $\begin{cases} 0.004x_1 + 15.73x_2 = 15.77 \\ 0.423x_1 - 24.72x_2 = -20.49 \end{cases}$

Solução:

Vamos trabalhar com a matriz aumentada, $\left(\begin{array}{cc|c} 0.004 & 15.73 & 15.77 \\ 0.423 & -24.72 & -20.49 \end{array} \right)$. Utilizando quatro algarismos significativos e arredondamento. No passo 1, queremos zerar o elemento a_{21} (coluna 1 e abaixo da diagonal). Com esse objetivo definimos a operação $L_2 \rightarrow L_2 - m_{21}L_1$ com $m_{21} = \frac{a_{21}}{a_{11}}$. Assim obtemos, $m_{21} = \frac{0.423}{0.004} = 105.75 \approx 105.8$. Realizando as operações sobre a linha 2, obtemos:

$$a_{22} = -24.72 - 105.8 \times 15.73 = -24.72 - 1664.234 \approx -24.72 - 1664 \approx -1688.72 \approx -1689$$

$$b_2 = -20.49 - 105.8 \times 15.77 = -20.49 - 1668.466 \approx -20.49 - 1668 = -1688.49 \approx -1688$$

e a sequência de matrizes equivalentes,

$$\left(\begin{array}{cc|c} 0.004 & 15.73 & 15.77 \\ 0.423 & -24.72 & -20.49 \end{array} \right) \sim \left(\begin{array}{cc|c} 0.004 & 15.73 & 15.77 \\ 0 & -1689 & -1688 \end{array} \right),$$

O sistema triangular superior equivalente é $\begin{cases} 0.004x_1 + 15.73x_2 = 15.77 \\ -1689x_2 = -1688 \end{cases}$

Utilizando o método da substituição inversa, obtemos:

$$x_2 = \frac{-1688}{-1689} \approx 0.9994 \text{ e } x_1 = \frac{15.77 - 15.73x_2}{0.004} \approx \frac{15.77 - 15.72}{0.004} \approx \frac{0.05}{0.004} = 12.5$$

Note que a solução exata deste sistema é $x_1 = 10$ e $x_2 = 1$. O erro relativo para a solução x_1 é 0.25.

Observe o que ocorre se alterarmos a ordem das equações,

$$\begin{cases} 0.423x_1 - 24.72x_2 = -20.49 \\ 0.004x_1 + 15.73x_2 = 15.77 \end{cases}$$

No passo 1, queremos zerar o elemento a_{21} . Com esse objetivo definimos a operação $L_2 \rightarrow L_2 - m_{21}L_1$ e agora com $m_{21} = \frac{0.004}{0.423} \approx 0.009456$. Realizando as operações sobre a linha 2, obtemos:

$$a_{22} = 15.73 - 0.009456 \times (-24.72) \approx 15.73 + 0.2338 \approx 15.96$$

$$b_2 = 15.77 - 0.009456 \times (-20.49) \approx 15.77 + 0.1938 \approx 15.96$$

e a sequência de matrizes equivalentes,

$$\left(\begin{array}{cc|c} 0.423 & -24.72 & -20.49 \\ 0.004 & 15.73 & 15.77 \end{array} \right) \sim \left(\begin{array}{cc|c} 0.423 & -24.72 & -20.49 \\ 0 & 15.96 & 15.96 \end{array} \right),$$

Utilizando o método da substituição inversa, obtemos:

$$x_2 = \frac{15.96}{15.96} = 1 \quad \text{e} \quad x_1 = \frac{-20.49 + 24.72x_2}{0.423} = \frac{4.23}{0.423} = 10.$$

Esta estratégia é chamada de pivoteamento.

3.2.4 Estratégia de Pivoteamento Parcial

A estratégia de pivoteamento parcial é a troca sistemática de linhas (na matriz aumentada) de forma que o pivô (termo da diagonal) seja o maior elemento (em valor absoluto) em relação aos demais elementos abaixo da diagonal principal, da coluna que estamos eliminando elementos.

Assim, no passo k , devemos encontrar a linha r tal que $|a_{kr}| = \max_{k \leq i \leq n} |a_{ik}|$, com $i \geq k$ e trocar as linhas k e r do sistema aumentado.

Já a estratégia de pivoteamento total é a troca sistemática de linhas e/ou colunas, de modo que o pivô (termo da diagonal) seja o maior elemento (em valor absoluto) da submatriz que ainda atua no processo de eliminação.

Vale observar que: trocas de linhas altera a ordem das equações e uma troca de colunas altera a ordem das incógnitas.

Exemplo 20 Resolver o sistema linear usando o método de Eliminação de Gauss sem e com pivoteamento parcial, com 3 algarismos significativos e arredondamento.

$$\begin{cases} x_1 & + & 4x_2 & + & 52x_3 & = & 57 \\ 27x_1 & + & 110x_2 & - & 3x_3 & = & 134 \\ 22x_1 & + & 2x_2 & + & 14x_3 & = & 38 \end{cases}$$

Solução:

Este sistema possui uma única solução $x_1 = x_2 = x_3 = 1$. Vamos trabalhar com o sistema na forma matricial, matriz aumentada, com três algarismos significativos e usando o arredondamento.

(1) *Eliminação de Gauss sem a técnica de Pivoteamento:*

Passo 1: As operações para “zerar” os elementos da primeira coluna abaixo da diagonal principal são $L_2 \leftarrow L_2 - m_{21}L_1$ e $L_3 \leftarrow L_3 - m_{31}L_1$, com $m_{21} = a_{21}/a_{11} = 27/1 = 27$ e $m_{31} = a_{31}/a_{11} = 22/1 = 22$. Para a linha 2, obtemos:

$$\begin{aligned} a_{22} &= 110 - 27 \times 4 = 110 - 108 = 2, \\ a_{23} &= -3 - 27 \times 52 = -3 - 1404 \approx -3 - 1400 = -1403 \approx -1400, \\ b_2 &= 134 - 27 \times 57 = 134 - 1539 \approx 134 - 1540 = -1406 \approx -1410. \end{aligned}$$

Para a linha 3, obtemos:

$$\begin{aligned} a_{32} &= 2 - 22 \times 4 = 2 - 88 = -86, \\ a_{33} &= 14 - 22 \times 52 = 14 - 1144 \approx 14 - 1140 = -1126 \approx -1130, \\ b_3 &= 38 - 22 \times 57 = 38 - 1254 \approx 38 - 1250 = -1212 \approx -1210. \end{aligned}$$

Passo 2: A operação para “zerar” o elemento da segunda coluna abaixo da diagonal principal é $L_3 \leftarrow L_3 - m_{32}L_2$, com $m_{32} = a_{32}/a_{22} = -86/2 = -43$. Para a linha 3, obtemos:

$$\begin{aligned} a_{33} &= -1130 + 43 \times (-1400) = -1130 - 60200 = -61330 \approx -61300, \\ b_3 &= -1210 + 43 \times (-1410) = -1210 - 60630 \approx -1210 - 60600 = -61810 \approx -61800 \end{aligned}$$

Abaixo a sequência de sistemas equivalentes após cada passo do método:

$$\left(\begin{array}{ccc|c} 1 & 4 & 52 & 57 \\ 27 & 110 & -3 & 134 \\ 22 & 2 & 14 & 38 \end{array} \right) \sim \left(\begin{array}{ccc|c} 1 & 4 & 52 & 57 \\ 0 & 2 & -1400 & -1410 \\ 0 & -86 & -1130 & -1210 \end{array} \right) \sim \left(\begin{array}{ccc|c} 1 & 4 & 52 & 57 \\ 0 & 2 & -1400 & -1410 \\ 0 & 0 & -61300 & -61800 \end{array} \right)$$

O sistema linear triangular superior equivalente é:

$$\begin{cases} x_1 + 4x_2 + 52x_3 = 57 \\ \quad 2x_2 - 1400x_3 = -1410 \\ \quad \quad -61300x_3 = -61800 \end{cases}$$

Usando o método da substituição inversa obtemos:

$$x_3 = \frac{-61800}{-61300} \approx 1.00815 \approx 1.01,$$

$$x_2 = \frac{-1410 + 1400x_3}{2} = \frac{-1410 + 1414}{2} \approx \frac{-1410 + 1410}{2} = 0, \text{ e}$$

$$x_1 = 57 - 52x_3 - 4x_2 = 57 - 52.52 - 0 \approx 57 - 52.5 = 4.5.$$

Portanto a solução aproximada obtida é $x_1 = 4.5$, $x_2 = 0$ e $x_3 = 1.01$.

Neste exemplo de solução, a grande diferença entre solução exata e aproximada se deve aos erros de arredondamento.

Agora, veja a solução do mesmo sistema linear usando a técnica de pivoteamento parcial, com três algarismos significativos e usando o arredondamento.

(2) *Eliminação de Gauss com a técnica de Pivoteamento Parcial:*

Passo 1: O maior elemento da primeira coluna está na linha 2. Assim, vamos fazer a troca de linhas $L_1 \sim L_2$. Agora, as operações para “zerar” os elementos da primeira coluna abaixo da diagonal principal são $L_2 \leftarrow L_2 - m_{21}L_1$ e $L_3 \leftarrow L_3 - m_{31}L_1$, com $m_{21} = a_{21}/a_{11} = 1/27 \approx 0.037037 \approx 0.037$ e $m_{31} = a_{31}/a_{11} = 22/27 \approx 0.81481 \approx 0.815$. Note que os elementos da matriz se referem a matriz após a troca de linhas ser feita. Para a linha 2, obtemos:

$$\begin{aligned} a_{22} &= 4 - 0.037 \times 110 = 4 - 4.0699 \approx 4 - 4.07 = -0.07, \\ a_{23} &= 52 - 0.037 \times (-3) = 52 + 0.111 = 52.111 \approx 52.1, \\ b_2 &= 57 - 0.037 \times 134 = 57 - 4.958 \approx 57 - 4.96 = 52.04 \approx 52. \end{aligned}$$

Já para a linha 3, obtemos:

$$\begin{aligned} a_{32} &= 2 - 0.815 \times 110 = 2 - 89.65 \approx 2 - 89.7 = 87.7, \\ a_{33} &= 14 - 0.815 \times (-3) = 14 + 2.445 \approx 14 + 2.45 = 16.45 \approx 16.5, \\ b_3 &= 38 - 0.815 \times 134 = 38 - 109.21 \approx 38 - 109 = -71. \end{aligned}$$

Passo 2: A primeira etapa é escolher o pivô como o maior elemento (em valor absoluto) na coluna 2 e abaixo da diagonal principal. Neste caso, precisamos fazer a troca de linhas $L_2 \sim L_3$. Assim, a operação para “zerar” o elemento a_{32} é $L_3 \leftarrow L_3 - m_{32}L_2$, com $m_{32} = \frac{a_{32}}{a_{22}} = \frac{-0.07}{-87.7} \approx 0.00079817 \approx 0.000798$. Para a linha 3, obtemos:

$$\begin{aligned} a_{33} &= 52.1 - 0.000798 \times 16.5 = 52.1 - 0.013167 \approx 52.1 - 0.0132 = 52.0868 \approx 52.1, \\ b_3 &= 52 - 0.000798 \times (-71) = 52 + 0.056658 \approx 52 + 0.0567 = 52.0567 \approx 52.1. \end{aligned}$$

A seguir apresentamos a sequência de sistemas equivalentes após cada passo do método:

$$\begin{aligned} \left(\begin{array}{ccc|c} 1 & 4 & 52 & 57 \\ 27 & 110 & -3 & 134 \\ 22 & 2 & 14 & 38 \end{array} \right) &\sim \left(\begin{array}{ccc|c} 27 & 110 & -3 & 134 \\ 1 & 4 & 52 & 57 \\ 22 & 2 & 14 & 38 \end{array} \right) \sim \left(\begin{array}{ccc|c} 27 & 110 & -3 & 134 \\ 0 & -0.07 & 52.1 & 52 \\ 0 & -87.7 & 16.5 & -71 \end{array} \right) \\ &\sim \left(\begin{array}{ccc|c} 27 & 110 & -3 & 134 \\ 0 & -87.7 & 16.5 & -71 \\ 0 & -0.07 & 52.1 & 52 \end{array} \right) \sim \left(\begin{array}{ccc|c} 27 & 110 & -3 & 134 \\ 0 & -87.7 & 16.5 & -71 \\ 0 & 0 & 52.1 & 52.1 \end{array} \right) \end{aligned}$$

O sistema linear triangular superior equivalente é:

$$\begin{cases} 27x_1 + 110x_2 - 3x_3 = 134 \\ -87.7x_2 + 16.5x_3 = -71 \\ 52.1x_3 = 52.1 \end{cases}$$

Usando o método da substituição inversa obtemos:

$$x_3 = \frac{52.1}{52.1} = 1,$$

$$x_2 = \frac{-71 - 16.5x_3}{-87.7} = \frac{-87.5}{-87.7} \approx 0.997719 \approx 0.998, \text{ e}$$

$$x_1 = \frac{134 + 3x_3 - 110x_2}{27} = \frac{134 + 3 - 109.78}{27} \approx \frac{137 - 110}{27} = 1.$$

Portanto a solução aproximada obtida é $x_1 = 1$, $x_2 = 0.998$ e $x_3 = 1$.

Agora, vamos apresentar a técnica de **pivoteamento total**, com a troca sistemática de linha e/ou coluna, de modo que o pivô (termo da diagonal) seja o maior elemento (em valor absoluto) da submatriz que ainda atua no processo de eliminação. Lembre-se que, uma troca de linhas troca a ordem das equações e uma troca de colunas altera a ordem do vetor de incógnitas $\mathbf{x}$.

(3) *Eliminação de Gauss com a técnica de Pivoteamento Total:*

$$\begin{cases} x_1 + 4x_2 + 52x_3 = 57 \\ 27x_1 + 110x_2 - 3x_3 = 134 \\ 22x_1 + 2x_2 + 14x_3 = 38 \end{cases}$$

Passo 1: O maior elemento da matriz em valor absoluto é 110. Assim, vamos trocar as colunas 1 e 2 e as linhas 1 e 2, ou seja, $C_1 \sim C_2$ e $L_1 \sim L_2$. Após a troca de colunas e linhas, faremos as operações: $L_2 \leftarrow L_2 - m_{21}L_1$ e $L_3 \leftarrow L_3 - m_{31}L_1$, com $m_{21} = 4/110 \approx 0.03636 \approx 0.0364$ e $m_{31} = 2/110 \approx 0.01818 \approx 0.0182$. Assim, para a linha 2, obtemos:

$$\begin{aligned} a_{22} &= 1 - 0.0364 \times 27 = 1 - 0.9828 \approx 1 - 0.983 = 0.017, \\ a_{23} &= 52 - 0.0364 \times (-3) = 52 + 0.1092 \approx 52.1, \\ b_2 &= 57 - 0.0364 \times 134 = 57 - 4.8876 \approx 57 - 4.89 = 52.11 \approx 52.1. \end{aligned}$$

Para a linha 3, obtemos:

$$\begin{aligned} a_{32} &= 22 - 0.0182 \times 27 = 22 - 0.4914 \approx 22 - 0.491 = 21.509 \approx 21.5, \\ a_{33} &= 14 - 0.0182 \times (-3) = 14 + 0.0546 = 14.0546 \approx 14.1, \\ b_3 &= 38 - 0.0182 \times 134 = 38 - 2.4388 \approx 38 - 2.44 = 35.56 \approx 35.6. \end{aligned}$$

Passo 2: O maior elemento em valor absoluto dos elementos que ainda atual no processo é $a_{23} = 52.1$. Assim, vamos trocar as colunas 2 e 3, ou seja, $C_2 \sim C_3$. Após a troca de colunas, faremos as operações: $L_3 \leftarrow L_3 - m_{32}L_2$, com $m_{32} = 14.1/52.1 \approx 0.270633 \approx 0.271$. Assim, para a linha 3, obtemos:

$$a_{33} = 21.5 - 0.271 \times 0.017 = 21.5 - 0.004607 \approx 21.5 - 0.00461 \approx 21.495 \approx 21.5,$$

$$b_3 = 35.6 - 0.27 \times 52.1 = 35.6 - 14.067 \approx 35.6 - 14.1 = 21.5.$$

A seguir apresentamos a sequência de matrizes obtida a cada passo.

$$\left(\begin{array}{ccc|c} 1 & 4 & 52 & 57 \\ 27 & 110 & -3 & 134 \\ 22 & 2 & 14 & 38 \end{array} \right) \sim \left(\begin{array}{ccc|c} 4 & 1 & 52 & 57 \\ 110 & 27 & -3 & 134 \\ 2 & 22 & 14 & 38 \end{array} \right) \sim \left(\begin{array}{ccc|c} 110 & 27 & -3 & 134 \\ 4 & 1 & 52 & 57 \\ 2 & 22 & 14 & 38 \end{array} \right) \sim$$

$$\left(\begin{array}{ccc|c} 110 & 27 & -3 & 134 \\ 0 & 0.017 & 52.1 & 52.1 \\ 0 & 21.5 & 14.1 & 35.6 \end{array} \right) \sim \left(\begin{array}{ccc|c} 110 & -3 & 27 & 134 \\ 0 & 52.1 & 0.017 & 52.1 \\ 0 & 14.1 & 21.5 & 35.6 \end{array} \right) \sim \left(\begin{array}{ccc|c} 110 & -3 & 27 & 134 \\ 0 & 52.1 & 0.017 & 52.1 \\ 0 & 0 & 21.5 & 21.5 \end{array} \right)$$

Aqui vale lembrar, que a ordem das incógnitas mudou por conta das trocas de colunas realizadas durante o processo. Assim, o sistema triangular superior equivalente é dado por

$$\begin{cases} 110x_2 - 3x_3 + 27x_1 = 134 \\ 52.1x_3 + 0.017x_1 = 52.1 \\ 21.5x_1 = 21.5 \end{cases}$$

Usando o método da substituição inversa temos:

$$x_1 = \frac{21.5}{21.5} = 1,$$

$$x_3 = \frac{52.1 - 0.017x_1}{52.1} \approx \frac{52.083}{52.1} \approx \frac{52.1}{52.1} = 1, \text{ e}$$

$$x_2 = \frac{134 - 27x_1 + 3x_3}{110} = \frac{110}{110} = 1.$$

Portanto a solução aproximada do sistema é $x_1 = x_2 = x_3 = 1$.

3.2.5 Fatoração LU

O método de Eliminação de Gauss nos fornece uma fatoração de matrizes, ou seja, a matriz A pode ser escrita como o produto de duas matrizes L (triangular inferior) e U (triangular superior), ou seja, $A = LU$.

A matriz U é a matriz triangular superior resultante do método de Eliminação de Gauss. A matriz L é uma matriz triangular inferior, que contém 1 nos elementos da diagonal e os multiplicadores utilizados em cada passo do processo de Eliminação de Gauss, abaixo da diagonal. Se forem realizadas trocas de linhas durante o processo com pivoteamento parcial, teremos uma matriz P , chamada matriz de permutação. A matriz P é a matriz identidade com as mesmas trocas de linha realizadas durante o processo de Eliminação de Gauss.

Assim, a solução do sistema $A\mathbf{x} = \mathbf{b} \Rightarrow LU\mathbf{x} = \mathbf{b}$, implica na resolução de dois sistemas

triangulares: $L\mathbf{y} = \mathbf{b}$ e $U\mathbf{x} = \mathbf{y}$.

Para o sistema triangular inferior, $L\mathbf{y} = \mathbf{b}$ vamos usar o método da substituição direta (Algoritmo 8) e para o sistema triangular superior, o método da Substituição Inversa (Algoritmo 7). A vantagem surge, quando precisamos resolver um sistema linear cuja matriz de coeficientes já possui uma fatoração conhecida, ou seja, um novo sistema linear onde apenas o lado direito $\mathbf{b}$ muda. Um exemplo, aparece na aplicação da técnica de refinamento de solução, que será apresentada na Seção 3.2.7.

O método de Eliminação de Gauss, que fornece a fatoração LU, custa $O(n^3)$ operações e a resolução dos dois sistemas triangulares custa $O(2n^2)$. Uma vez fatorada a matriz, ao troca o lado direito, o “novo” sistema linear é resolvido rapidamente, veja a Tabela a seguir.

N	$n^3/3$	$2n^2$	Redução da resolução do 2º sistema
10	3.3×10^2	2×10^2	40%
100	3.3×10^5	2×10^4	94%

Exemplo 21 Após aplicar o método de Eliminação de Gauss com pivoteamento parcial no sistema de equações

$$\begin{cases} x_1 + 4x_2 + 52x_3 = 57 \\ 27x_1 + 110x_2 - 3x_3 = 134 \\ 22x_1 + 2x_2 + 14x_3 = 38 \end{cases}$$

obtemos o sistema triangular superior equivalente, com os multiplicadores armazenados abaixo da diagonal principal. Durante o processo, foram realizadas as trocas de linhas $L_1 \sim L_2$ e $L_2 \sim L_3$.

$$\left(\begin{array}{ccc|c} 27 & 110 & -3 & 134 \\ \hline \mathbf{0.815} & & & \\ \mathbf{0.037} & \mathbf{0.000798} & & \end{array} \right)$$

(a) Identifique as matrizes P , L e U .

(b) Resolva o sistema usando a fatoração LU.

Solução: (a) Neste exemplo, temos:

$$L = \begin{pmatrix} 1 & 0 & 0 \\ 0.815 & 1 & 0 \\ 0.037 & 0.000798 & 1 \end{pmatrix}, U = \begin{pmatrix} 27 & 110 & -3 \\ 0 & -87.7 & 16.5 \\ 0 & 0 & 52.1 \end{pmatrix} \text{ e } P = \begin{pmatrix} 0 & 1 & 0 \\ 0 & 0 & 1 \\ 1 & 0 & 0 \end{pmatrix}$$

Assim, $PA = LU$.

(b) A partir da fatoração LU, vamos resolver o sistema linear $A\mathbf{x} = \mathbf{b}$, a partir dos sistemas triangulares, obtidos da seguinte forma,

$$A\mathbf{x} = \mathbf{b} \Rightarrow PA\mathbf{x} = P\mathbf{b} \Rightarrow LU\mathbf{x} = P\mathbf{b} \Rightarrow \begin{cases} L\mathbf{y} = P\mathbf{b} \\ U\mathbf{x} = \mathbf{y} \end{cases}$$

Dessa forma, do exemplo anterior temos:

$A = \begin{pmatrix} 1 & 4 & 52 \\ 27 & 110 & -3 \\ 22 & 2 & 14 \end{pmatrix}$, $\mathbf{b} = \begin{pmatrix} 57 \\ 134 \\ 38 \end{pmatrix}$ e a fatoração LU dada pelas matrizes L , U e P , apresentadas no item (a).

O primeiro passo é fazer a troca de linhas no vetor $\mathbf{b}$, dada por $P\mathbf{b} = \begin{pmatrix} 134 \\ 38 \\ 57 \end{pmatrix}$. O primeiro sistema triangular a ser resolvido é $L\mathbf{y} = P\mathbf{b}$, ou seja,

$$\begin{cases} y_1 & & & = & 134 \\ 0.815y_1 & + & y_2 & & = & 38 \\ 0.037y_1 & + & 0.000798y_2 & + & y_3 & = & 57 \end{cases}$$

Aplicando o método da substituição direta obtemos:

$$y_1 = 134,$$

$$y_2 = 38 - 0.815y_1 = 38 - 109.21 \approx 38 - 109 = -71, \text{ e}$$

$$y_3 = 57 - 0.000798y_2 - 0.037y_1 = 57 + 0.0567 - 4.96 \approx 57.1 - 4.96 \approx 52.1.$$

O segundo sistema triangular a ser resolvido é $U\mathbf{x} = \mathbf{y}$, ou seja,

$$\begin{cases} 27x_1 & + & 110x_2 & - & 3x_3 & = & 134 \\ & & -87.7x_2 & + & 16.5x_3 & = & -71 \\ & & & & 52.1x_3 & = & 52.1 \end{cases}$$

Aplicando o método da substituição inversa obtemos:

$$x_3 = \frac{52.1}{52.1} = 1,$$

$$x_2 = \frac{-71 - 16.5x_3}{-87.7} = \frac{-87.5}{-87.7} \approx 0.99771 \approx 0.998, \text{ e}$$

$$x_1 = \frac{134 + 3x_3 - 110x_2}{27} = \frac{137 - 109.78}{27} \approx \frac{137 - 110}{27} = 1.$$

Portanto, $\mathbf{x} = (1, 0.998, 1)$.

3.2.6 Matrizes esparsas

Uma matriz é chamada **esparsa** quando a quantidade de elementos não-nulos é pequena quando comparada com o número total de elementos da matriz. Por exemplo, a matriz

$$A = \begin{pmatrix} 1 & 2 & 0 & 0 & -1 & 0 & 0 \\ 0 & 1 & 3 & 0 & 0 & 0 & 0 \\ -2 & 0 & 2 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 2 & -1 & 0 & 5 \\ 0 & 1 & 0 & 0 & 4 & 0 & 0 \\ 0 & 0 & 0 & 7 & 0 & -1 & 0 \\ 0 & 0 & 0 & 0 & 0 & 1 & 2 \end{pmatrix}$$

possui 16 elementos não nulos e 49 elementos nulos. Se, além de esparsa, a matriz tem os elementos não nulos concentrados em torno da diagonal, ela é chamada matriz de **banda**. Uma matriz A é de **banda** $p + q + 1$, se $a_{ij} = 0$ se $i > j + q$ ou $i < j - p$. Casos especiais das matrizes de banda, são as matrizes pentadiagonais, como

$$B = \begin{pmatrix} 1 & 2 & -1 & 0 & 0 & 0 & 0 \\ 2 & 1 & 2 & -1 & 0 & 0 & 0 \\ -1 & 2 & 1 & 2 & -1 & 0 & 0 \\ 0 & -1 & 2 & 1 & 2 & -1 & 0 \\ 0 & 0 & -1 & 2 & 1 & 2 & -1 \\ 0 & 0 & 0 & -1 & 2 & 1 & 2 \\ 0 & 0 & 0 & 0 & -1 & 2 & 1 \end{pmatrix},$$

com $p = q = 2$ e as matrizes tridiagonais onde $p = q = 1$. O exemplo de motivação, sobre a distribuição de temperatura em uma barra, é um sistema tridiagonal, como o sistema dado por,

$$\begin{pmatrix} 2 & -1 & 0 & 0 & 0 & 0 & 0 \\ -1 & 2 & -1 & 0 & 0 & 0 & 0 \\ & \ddots & \ddots & & & & \\ & & \ddots & \ddots & & & \\ & & & \ddots & \ddots & & \\ 0 & 0 & 0 & 0 & -1 & 2 & -1 \\ 0 & 0 & 0 & 0 & 0 & -1 & 2 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \\ \vdots \\ \vdots \\ x_{n-1} \\ x_n \end{pmatrix} = \begin{pmatrix} 1 \\ 0 \\ \vdots \\ \vdots \\ 0 \\ 0 \end{pmatrix}$$

Métodos para sistemas lineares que possuem matrizes esparsas precisam ser implementados de forma que economizem tempo e espaço. Observe, que podemos tirar proveito da estrutura do sistema para economizar no custo do método e no armazenamento da matriz. Considere um sistema tridiagonal geral, dado por,

$$\left(\begin{array}{ccc|c} d_1 & c_1 & & b_1 \\ a_2 & d_2 & c_2 & b_2 \\ & \ddots & \ddots & \vdots \\ & & a_{n-1} & d_{n-1} & c_{n-1} & b_{n-1} \\ & & & a_n & d_n & b_n \end{array} \right)$$

O Algoritmo 10 apresenta o método de Eliminação de Gauss, para um sistema tridiagonal, onde armazenamos os elementos não nulos da matriz de coeficientes em três vetores: $\mathbf{d}$, $\mathbf{a}$ e $\mathbf{c}$, um para cada diagonal.

Algoritmo 10: Método de Eliminação de Gauss para Sistema Triadiagonal

Entrada: Matriz tridiagonal armazenada em três vetores: **d**, **a** e **c** e lado direito **b**

para $k = 1$ *até* $n - 1$ **faça**

$$\left[\begin{array}{l} d_{k+1} \leftarrow d_{k+1} - \frac{a_{k+1}}{d_k} c_k \\ b_{k+1} \leftarrow b_{k+1} - \frac{a_{k+1}}{d_k} b_k \end{array} \right.$$

$$x_n \leftarrow \frac{b_n}{d_n}$$

para $k = n - 1$ *até* 1 **faça**

$$\left[x_k \leftarrow \frac{b_k - c_k x_{k+1}}{d_k} \right.$$

Saída: **x**

Exemplo 22 Resolva o sistema linear tridiagonal usando o método de Eliminação de Gauss que tire proveito da estrutura da matriz.

$$\left\{ \begin{array}{cccccc} 2x_1 & - & x_2 & & & = & -1 \\ x_1 & + & 3x_2 & - & 2x_3 & & = & 12 \\ & & x_2 & - & 4x_3 & + & x_4 & = & 8 \\ & & & & x_3 & + & 2x_4 & = & 1 \end{array} \right.$$

Solução:

Vamos utilizar quatro algarismos significativos e corte, a cada operação. A matriz aumentada associada ao sistema é dada por,

$$\left(\begin{array}{cccc|c} 2 & -1 & 0 & 0 & -1 \\ 1 & 3 & -2 & 0 & 12 \\ 0 & 1 & -4 & 1 & 8 \\ 0 & 0 & 1 & 2 & 1 \end{array} \right)$$

Passo 1: Note que não são necessárias trocas de linhas e que só temos um elemento a_{21} para zerar. Assim, faremos uma única operação sobre a linha 2: $L_2 \leftarrow L_2 - m_{21}L_1$, com $m_{21} = \frac{1}{2} = 0.5$. Assim temos, $a_{22} = 3 - 0.5 \times (-1) = 3.5$ e $b_2 = 12 - 0.5 \times (-1) = 12.5$. Note que, a_{23} não será alterado pois, $-2 - 0.5 \times 0 = -2$ e que as linhas 3 e 4 já estão prontas, conforme a primeira matriz na sequência a seguir.

Passo 2: Mais uma vez não são necessárias trocas de linhas e só temos o elemento a_{32} para zerar. Assim, faremos uma única operação sobre a linha 3: $L_3 \leftarrow L_3 - m_{32}L_2$, com $m_{32} = \frac{1}{3.5} = 0.2857$. Assim temos, $a_{33} = -4 - 0.2857 \times (-2) = -4 + 0.5714 = -3.428$ e $b_3 = 8 - 0.2857 \times 12.5 = 8 - 3.571 = 4.429$.

Passo 3: Novamente, não são necessárias trocas de linhas e só temos o elemento a_{43} para zerar. Assim, faremos uma única operação sobre a linha 4: $L_4 \leftarrow L_4 - m_{43}L_3$, com $m_{43} = \frac{1}{-3.428} = -0.2917$. Assim temos, $a_{44} = 2 + 0.2917 \times 1 = 2.291$ e $b_4 = 1 + 0.2917 \times 4.429 = 1 + 1.291 = 4.429$.

$$\left(\begin{array}{cccc|c} 2 & -1 & 0 & 0 & -1 \\ \hline 0.5 & 3.5 & -2 & 0 & 12.5 \\ 0 & 1 & -4 & 1 & 8 \\ 0 & 0 & 1 & 2 & 1 \end{array} \right) \sim \left(\begin{array}{cccc|c} 2 & -1 & 0 & 0 & -1 \\ \hline 0.5 & 3.5 & -2 & 0 & 12.5 \\ 0 & 0.2857 & -3.428 & 1 & 4.429 \\ 0 & 0 & 1 & 2 & 1 \end{array} \right)$$

$$\left(\begin{array}{cccc|c} 2 & -1 & 0 & 0 & -1 \\ \hline 0.5 & 3.5 & -2 & 0 & 12.5 \\ 0 & 0.2857 & -3.428 & 1 & 4.429 \\ 0 & 0 & -0.2917 & 2.291 & 2.291 \end{array} \right)$$

O qual resulta no sistema triangular superior equivalente,

$$\begin{cases} 2x_1 - x_2 & = -1 \\ 3.5x_2 - 2x_3 & = 12.5 \\ -3.428x_3 + x_4 & = 4.429 \\ 2.291x_4 & = 2.291 \end{cases}$$

O qual, aplicando o método da substituição inversa obtemos,

$$x_4 = \frac{2.291}{2.291} = 1,$$

$$x_3 = \frac{4.429 - x_4}{-3.428} = -1,$$

$$x_2 = \frac{12.5 + 2x_3}{3.5} = \frac{10.5}{3.5} = 3, \text{ e}$$

$$x_1 = \frac{-1 + x_2}{2} = 1.$$

Portanto a solução aproximada obtida é $x_1 = 1, x_2 = 3, x_3 = -1$ e $x_4 = 1$.

3.2.7 Refinamento da solução

O Refinamento da solução é uma técnica iterativa para melhorar a solução do método de Eliminação de Gauss, ao se trabalhar com a aritmética de ponto flutuante. Já vimos que os erros de arredondamento podem comprometer a solução aproximada obtida por um método direto.

Considere o problema $A\mathbf{x} = \mathbf{b}$, com $\mathbf{x} = \tilde{\mathbf{x}} + \mathbf{e}$, com $\tilde{\mathbf{x}}$ uma solução aproximada e $\mathbf{e}$ um erro associado. O problema pode ser reescrito na forma residual,

$$A\mathbf{x} = \mathbf{b} \Rightarrow A(\tilde{\mathbf{x}} + \mathbf{e}) = \mathbf{b} \Rightarrow A\mathbf{e} = \mathbf{r}, \text{ sendo } \mathbf{r} = \mathbf{b} - A\tilde{\mathbf{x}},$$

sendo $\mathbf{r}$ o resíduo e o problema residual, dado por,

$$A\mathbf{e} = \mathbf{r}. \quad (3.5)$$

Assim, podemos corrigir a solução aproximada. A nova solução aproximada é $\tilde{\mathbf{x}} = \mathbf{x} + \mathbf{e}$.

A técnica de refinamento da solução, com a solução do problema residual (3.5) é uma das bases do Método *Multigrid*. Vale destacar, que o cálculo do resíduo deve ser feito em dupla precisão, ou seja, com o dobro de algarismos significativos utilizado para a obtenção da solução aproximada. O Algoritmo 11 apresenta a estratégia de refinamento da solução.

Algoritmo 11: Refinamento da Solução

Entrada: A , $\mathbf{b}$ e $\mathbf{x}$

$\delta \leftarrow 10^{-6}$

$emax \leftarrow 1$

$k \leftarrow 1$

$kmax \leftarrow 50$

enquanto $emax > \delta$ e $k < kmax$ **faça**

$\mathbf{r} \leftarrow \mathbf{b} - A\mathbf{x}$

 Resolve $A\mathbf{e} = \mathbf{r}$

$\mathbf{x} \leftarrow \mathbf{x} + \mathbf{e}$

$emax \leftarrow \|\mathbf{e}\|_\infty$

$k \leftarrow k + 1$

Saída: $\mathbf{x}$

No Exemplo 20 obtivemos a solução aproximada $\mathbf{x} = (1, 0.998, 1)$. Vamos fazer uma etapa do refinamento. A matriz de coeficientes A e o lado direito $\mathbf{b}$ são dados por,

$$A = \begin{pmatrix} 1 & 4 & 52 \\ 27 & 110 & -3 \\ 22 & 2 & 14 \end{pmatrix} \text{ e } \mathbf{b} = \begin{pmatrix} 57 \\ 134 \\ 38 \end{pmatrix}$$

Para isso, vamos calcular o resíduo com precisão dupla, nesse caso 6 algarismos significativos. Assim obtemos,

$$\mathbf{r} = \mathbf{b} - A\mathbf{x} = \begin{pmatrix} 57 \\ 134 \\ 38 \end{pmatrix} - \begin{pmatrix} 1 & 4 & 52 \\ 27 & 110 & -3 \\ 22 & 2 & 14 \end{pmatrix} \begin{pmatrix} 1 \\ 0.998 \\ 1 \end{pmatrix} = \begin{pmatrix} 57 - 1 - 3.992 - 52 \\ 134 - 27 - 109.78 + 3 \\ 38 - 22 - 1.996 - 14 \end{pmatrix}.$$

Além disso, temos a fatoração LU fornecida pelo exemplo 20,

$$\mathbf{r} = \begin{pmatrix} 0.008 \\ 0.22 \\ 0.004 \end{pmatrix}, P = \begin{pmatrix} 0 & 1 & 0 \\ 0 & 0 & 1 \\ 1 & 0 & 0 \end{pmatrix}, L = \begin{pmatrix} 1 & 0 & 0 \\ 0.815 & 1 & 0 \\ 0.037 & 0.000798 & 1 \end{pmatrix}, U = \begin{pmatrix} 27 & 110 & -3 \\ 0 & -87.7 & 16.5 \\ 0 & 0 & 52.1 \end{pmatrix}$$

Agora, vamos resolver o problema residual $A\mathbf{e} = \mathbf{r}$. Lembrando que o Método de Eliminação de Gauss teve trocas de linhas, então temos $PA\mathbf{e} = P\mathbf{r}$, que resulta em dois sistemas triangulares: $L\mathbf{y} = P\mathbf{r}$ e $U\mathbf{e} = \mathbf{y}$.

(1) Sistema triangular inferior: $L\mathbf{y} = P\mathbf{r}$.

$$\begin{cases} y_1 & = 0.22 \\ 0.815y_1 + y_2 & = 0.004 \\ 0.037y_1 + 0.000798y_2 + y_3 & = 0.008 \end{cases}$$

Solução via método da substituição direta:

$$y_1 = 0.22,$$

$$y_2 = 0.004 - 0.815y_1 = 0.004 - 0.179 = -0.175$$

$$y_3 = 0.008 - 0.000798y_2 - 0.037y_1 = 0.008 + 0.000140 - 0.00814 = 0$$

(2) Sistema triangular superior: $U\mathbf{e} = \mathbf{y}$

$$\begin{cases} 27e_1 + 110e_2 - 3e_3 = 0.22 \\ -87.7e_2 + 16.5e_3 = -0.175 \\ 52.1e_3 = 0 \end{cases}$$

Solução via método da substituição inversa:

$$e_3 = \frac{0}{52.1} = 0.,$$

$$e_2 = \frac{0.008 - 16.5e_3}{-87.7} = \frac{0.008 - 0.070}{-87.7} = 0.000707,$$

$$e_3 = \frac{0.22 + 3e_3 - 100e_2}{27} = \frac{0.22 +}{27}$$

Agora, o último passo é corrigir a solução,

$$\mathbf{x} = \mathbf{x}^{(0)} + \mathbf{e} = \begin{pmatrix} 1 \\ 0.998 \\ 1 \end{pmatrix} + \begin{pmatrix} e_1 \\ e_2 \\ e_3 \end{pmatrix} = \begin{pmatrix} x_1 \\ x_2 \\ x_3 \end{pmatrix}.$$

Assim, a solução aproximada após uma etapa de refinamento é $x_1 =$, $x_2 =$ e $x_3 =$.

Leitura recomendada:

- Noções de Cálculo Numérico. Capítulo 3 [2].
- Cálculo Numérico Computacional. Capítulo 2 [6].
- Análise Numérica. Capítulo 6 [1].
- Métodos Numéricos. Capítulo 2 [3]

3.3 Exercícios

1. [3] Resolva os sistemas abaixo, com e sem pivoteamento, usando quatro algarismos significativos e arredondamento. Qual técnica forneceu os melhores resultados?

$$(a) \begin{cases} 58.09x_1 + 1.003x_2 = 68.12 \\ 321.8x_1 + 5.550x_2 = 377.3 \end{cases} \quad (b) \begin{cases} 321.8x_1 + 5.550x_2 = 377.3 \\ 110.3x_1 + 5809x_2 = 6812 \end{cases}$$

2. [1] Use o método de Eliminação de Gauss com substituição inversa e aritmética de arredondamento de dois algarismos significativos para resolver os seguintes sistemas. Não reordene as equações. A solução exata de cada sistema é $x_1 = 1, x_2 = -1$ e $x_3 = 3$.

$$(a) \begin{cases} 4x_1 - x_2 + x_3 = 8 \\ 2x_1 + 5x_2 + 2x_3 = 3 \\ x_1 + 2x_2 + 4x_3 = 11 \end{cases} \quad (b) \begin{cases} 4x_1 + x_2 + 2x_3 = 9 \\ 2x_1 + 4x_2 - x_3 = -5 \\ x_1 + x_2 - 3x_3 = -9 \end{cases}$$

3. [1] Dado o sistema linear

$$\begin{cases} 2x_1 - 6\alpha x_2 = 3 \\ 3\alpha x_1 - x_2 = \frac{3}{2} \end{cases}$$

- (a) Determine o(s) valor(es) de α para o(s) qual(is) o sistema não possui solução.
 (b) Determine o(s) valor(es) de α para o(s) qual(is) o sistema possui um número infinito de soluções.
 (c) Supondo que exista uma única solução para determinado α , determine a solução.
4. [1] O método de Eliminação de Gauss utiliza-se de três operações elementares para criar uma sequência de sistemas lineares equivalentes com a mesma solução do sistema original e cada um mais fácil de resolver que o anterior. Como esta sequência de sistemas impacta o custo de determinar a solução? Existe algum tipo de erro envolvido durante o processo?
5. [3] Resolva o sistema linear abaixo usando o Método de Eliminação de Gauss e a decomposição LU.

$$\begin{cases} 7x_1 + 2x_2 - 5x_3 = -18 \\ x_1 + 5x_2 - 3x_3 = -40 \\ 2x_1 - x_2 - 9x_3 = -26 \end{cases}$$

6. Seja $L \in \mathbb{R}^{n \times n}$ uma matriz triangular inferior e $\mathbf{b} \in \mathbb{R}^n$ e o seguinte problema: *determinar $\mathbf{x}$ tal que $L\mathbf{x} = \mathbf{b}$* . Contabilize o número de operações que o algoritmo da substituição direta executa para resolver um sistema linear $n \times n$.

7. Considere o sistema linear,

$$\begin{cases} x_1 + x_2 + 4x_3 + x_4 = 2 \\ \quad \quad x_2 + 2x_3 + 4x_4 = 9 \\ 2x_1 + 4x_2 - x_3 = 2 \\ 5x_1 + x_2 + x_3 + 2x_4 = 0 \end{cases}$$

- (a) Obtenha a decomposição LU da matriz associada aos sistema de equações lineares.
- (b) Resolva o sistema linear.
8. Seja $A\mathbf{x} = \mathbf{b}$ um sistema de equações lineares $n \times n$, sendo A uma matriz tridiagonal, ou seja, $a_{ij} = 0$ se $|i - j| > 1$.

- (a) Escreva um algoritmo para resolver este sistema de equações por meio do método de Eliminação de Gauss, tirando proveito da estrutura esparsa da matriz.
- (b) Escolha um valor de n e teste o seu algoritmo com o sistema:

$$\begin{cases} 2x_1 - x_2 = 1, \\ -x_{i-1} + 2x_i - x_{i+1} = 0, & \text{para } i = 2, \dots, n-1, \\ -x_{n-1} + 2x_n = 0. \end{cases}$$

- (c) Contabilize o número de operações que o algoritmo executa para resolver um sistema tridiagonal $n \times n$.
9. Resolva o sistema linear abaixo, utilizando o método de Eliminação de Gauss com pivoteamento e trabalhando com três algarismos significativos,

$$\begin{pmatrix} 3.2 & 1.0 & 2.0 & 0.0 \\ -1.0 & 0.0 & 1.5 & -2.4 \\ 4.1 & 2.5 & 0.0 & 1.0 \\ 3.6 & 0.0 & 0.0 & 2.8 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \\ x_3 \\ x_4 \end{pmatrix} = \begin{pmatrix} 8.2 \\ 2.84 \\ 1.0 \\ 4.72 \end{pmatrix}$$

sabendo-se que o resultado da triangularização da matriz de coeficientes é

$$\left(\begin{array}{cccc} 4.1 & & 2.5 & 0.0 & 1.0 \\ - & - & - & - & - \\ 0.78 & | & -2.2 & 0.0 & 1.92 \\ & - & - & - & - \\ 0.878 & & -0.277 & | & 2.0 & -1.61 \\ & - & - & - & - & - \\ -0.244 & & 0.432 & & 0.75 & -0.42 \end{array} \right)$$

com $p_1 = 3$, $p_2 = 4$ e $p_3 = 3$, ou seja, no passo 1 foi feita a troca de linhas $L_1 \sim L_3$, no passo 2, a troca $L_2 \sim L_4$ e nenhuma troca no passo 3.

10. Considere o sistema linear: $Ax = b$, sendo

$$A = \begin{pmatrix} 1 & 2 & 1 \\ 2 & 3 & 1 \\ 3 & 5 & 2 \end{pmatrix} \quad \text{e} \quad b = \begin{pmatrix} 3 \\ 5 \\ 1 \end{pmatrix}.$$

Verifique usando eliminação de Gauss, com a estratégia de pivoteamento, que este sistema não admite solução.

11. Resolva o sistema

$$\begin{pmatrix} -12 & 27 & 6 \\ 22 & -15 & 35 \\ 32 & 5 & -4 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \\ x_3 \end{pmatrix} = \begin{pmatrix} 116 \\ -41 \\ -61.4 \end{pmatrix}$$

e efetue duas etapas de refinamento de solução. Trabalhe com três algarismos significativos. Não esqueça do cálculo do resíduo com dupla precisão. O resultado da triangularização deste sistema pelo método de Eliminação de Gauss com pivoteamento é

$$\left(\begin{array}{ccc|ccc} 32 & & & 5 & & -4 & -61.4 \\ - & - & - & & & & \\ -0.375 & & & 28.9 & & 4.5 & 93 \\ & - & - & - & - & & \\ 0.688 & & & -0.637 & & 40.7 & 60.4 \end{array} \right)$$

com $p_1 = 3$ e $p_2 = 3$, ou seja, no passo 1 foi feita a troca de linhas $L_1 \sim L_3$ e no passo 2, a troca $L_2 \sim L_3$.

12. [1] Suponha que em um sistema biológico existam n espécies de animais e m fontes de alimentos. Represente a população da j -ésima espécie por x_j , para cada $j = 1, \dots, n$; represente o fornecimento diário disponível do i -ésimo alimento por b_i e a quantidade do i -ésimo alimento consumido em média por um membro da j -ésima espécie por a_{ij} . O sistema linear

$$\begin{array}{ccccccccc} a_{11}x_1 & + & a_{12}x_2 & + & \dots & + & a_{1n}x_n & = & b_1 \\ a_{21}x_1 & + & a_{22}x_2 & + & \dots & + & a_{2n}x_n & = & b_1 \\ \vdots & & \vdots & & & & \vdots & & \vdots \\ a_{m1}x_1 & + & a_{m2}x_2 & + & \dots & + & a_{mn}x_n & = & b_m \end{array}$$


representa o equilíbrio no qual existe um fornecimento diário de alimento para satisfazer exatamente a média diária de consumo de cada espécie.

(a) Faça $A = [a_{ij}] = \begin{pmatrix} 1 & 2 & 0 & 3 \\ 1 & 0 & 2 & 2 \\ 0 & 0 & 1 & 1 \end{pmatrix}$, $\mathbf{x} = [x_j] = (1000, 500, 350, 400)$ e $\mathbf{b} = [b_j] = (3500, 2700, 900)$. Haverá comida suficiente para satisfazer a média diária de consumo?

(b) Se a espécie 1 for extinta, qual é o número de indivíduos de cada uma das espécies remanescentes que poderia ser sustentado?

(c) Se a espécie 2 for extinta, qual é o aumento de indivíduos de cada uma das espécies remanescentes que poderia ser sustentado?

13. [1] O circuito a seguir tem quatro resistências e duas fontes de voltagem. As resistências são R_1, R_2, R_3 e R_4 ohms, as fontes de voltagem E_1 e E_2 volts e as correntes



são i_1, i_2 e i_3 amperes.

Usando as Leis de Kirchhoff, obtemos o sistema linear,

$$\begin{array}{rccccccc} (R_1 + R_4)i_1 & + & R_2i_2 & & & = & E_1 + E_2 \\ (R_1 + R_4)i_1 & & & + & R_3i_3 & = & E_1 \\ i_1 & - & i_2 & - & i_3 & = & 0 \end{array}$$

- Usando a Eliminação de Gauss sem pivoteamento e corte, como regra de arredondamento, com três algarismos significativos, determine i_1, i_2 e i_3 quando $E_1 = 12$ volts, $E_2 = 10$ volts, $R_1 = 2$ ohms, $R_2 = 2$ ohms, $R_3 = 4$ ohms e $R_4 = 1$ ohm.
- Se as resistências forem trocadas para $R_1 = 0.001$ ohm, $R_2 = 3.333$ ohms, $R_3 = 4.002$ ohms e $R_4 = 0.012$ ohm, determine as correntes i_1, i_2 e i_3 usando eliminação de Gauss e corte, como regra de arredondamento, com três algarismos significativos.
- A estratégia de pivoteamento parcial melhora a resposta do item anterior?

3.4 Métodos Iterativos

Nesta seção continuamos estudando métodos para a solução de sistemas lineares. Os métodos iterativos geram uma sequência de soluções aproximadas cuja convergência depende da matriz de coeficientes associada ao sistema.

Dado $A\mathbf{x} = \mathbf{b}$, o objetivo dos métodos iterativos é construir uma sequência de aproximações $\mathbf{x}^k$ para $\mathbf{x}^*$, solução do sistema linear, tal que $\mathbf{x}^k \rightarrow \mathbf{x}^*$ quando $k \rightarrow \infty$.

Os métodos iterativos são convenientes para sistemas de grande porte e esparsos, como o exemplo 3.1, que possui uma matriz de coeficientes tridiagonal, dada por

$$A = \begin{pmatrix} 2 & -1 & 0 & 0 & 0 & 0 & 0 \\ -1 & 2 & -1 & 0 & 0 & 0 & 0 \\ & & \ddots & \ddots & & & \\ \vdots & & \ddots & \ddots & & & \vdots \\ & & & & \ddots & \ddots & \\ 0 & 0 & 0 & 0 & -1 & 2 & -1 \\ 0 & 0 & 0 & 0 & 0 & -1 & 2 \end{pmatrix}.$$

Na Seção 3.4.1 apresentamos o método de Jacobi, na Seção 3.4.2, o método de Gauss-Seidel e na Seção 3.4.4 o método SOR. Os fórmulas de iteração de cada método são obtidas a partir do sistema de equações,

$$\begin{cases} a_{11}x_1 + a_{12}x_2 + \dots + a_{1n}x_n = b_1 \\ a_{21}x_1 + a_{22}x_2 + \dots + a_{2n}x_n = b_2 \\ \vdots \\ a_{n1}x_1 + a_{n2}x_2 + \dots + a_{nn}x_n = b_n \end{cases} \quad (3.6)$$

3.4.1 Método de Jacobi

A partir de uma solução inicial $\mathbf{x}^0$ e supondo $a_{ii} \neq 0$ para todo i , o **método de Jacobi** é um processo iterativo. A fórmula de iteração é obtida a partir de (3.6), ao isolarmos cada uma das incógnitas em uma das equações. Por exemplo, na primeira equação isolamos x_1 , na segunda equação isolamos x_2 e assim sucessivamente, obtendo,

$$\begin{aligned} x_1^{(k+1)} &= \frac{1}{a_{11}} \left(b_1 - a_{12}x_2^{(k)} - a_{13}x_3^{(k)} - \dots - a_{1n}x_n^{(k)} \right) \\ x_2^{(k+1)} &= \frac{1}{a_{22}} \left(b_2 - a_{21}x_1^{(k)} - a_{23}x_3^{(k)} - \dots - a_{2n}x_n^{(k)} \right) \\ &\vdots \\ x_n^{(k+1)} &= \frac{1}{a_{nn}} \left(b_n - a_{n1}x_1^{(k)} - a_{n3}x_3^{(k)} - \dots - a_{n,n-1}x_{n,n-1}^{(k)} \right) \end{aligned} \quad (3.7)$$

para $k = 0, 1, \dots$. O índice k indica a iteração. A solução aproximada de cada iteração $\mathbf{x}^{(k+1)}$, em (3.7) depende apenas da solução na iteração anterior k . De uma forma compacta, temos,

$$x_1^{(k)} = \frac{b_1 - \sum_{j=2}^n a_{1j}x_j^{(k-1)}}{a_{11}}, \dots, x_i^{(k)} = \frac{b_i - \sum_{j=1, j \neq i}^n a_{ij}x_j^{(k-1)}}{a_{ii}}, \dots, x_n = \frac{b_n - \sum_{j=1}^{n-1} a_{nj}x_j^{(k-1)}}{a_{nn}}. \quad (3.8)$$

para $k = 1, 2, \dots$

Exemplo 23 Resolva o sistema abaixo com o método de Jacobi, fazendo duas iterações, partindo da aproximação inicial $\mathbf{x}^0 = (0, 0, 0, 0)$. A solução exata é $\mathbf{x} = (1, 2, -1, 1)$:

$$\begin{cases} 10x_1 - x_2 + 2x_3 = 6 \\ -x_1 + 11x_2 - x_3 + 3x_4 = 25 \\ 2x_1 - x_2 + 10x_3 - x_4 = -11 \\ 3x_2 - x_3 + 8x_4 = 15 \end{cases}$$

Solução.

O Algoritmo 12 apresenta a estrutura do processo iterativo do Método de Jacobi.

Algoritmo 12: Método de Jacobi

Entrada: A , $\mathbf{b}$ e $\mathbf{x}^{(0)}$
 δ (tolerância)
 $k \leftarrow 1$
 $k_{max} \leftarrow 100$
 $r_{max} \leftarrow 1$
enquanto ($r_{max} > \delta$ e $k < k_{max}$) **faça**
 para $i = 1$ **até** n **faça**
 $x_i \leftarrow \frac{b_i - \sum_{j=1, j \neq i}^n a_{ij}x_j^{(0)}}{a_{ii}}$
 $\mathbf{x}^{(0)} \leftarrow \mathbf{x}$
 $r_{max} \leftarrow \|\mathbf{b} - A\mathbf{x}\|_{\infty}$.
 $k \leftarrow k + 1$
Devolve $\mathbf{x}$

Algumas observações sobre o Algoritmo 12:

- O algoritmo trabalha com duas aproximações: a atual $\mathbf{x}$ e a anterior $\mathbf{x}^{(0)}$.
- O método de Jacobi apresenta vantagem quando se trata de programação paralela.
- O critério de parada é baseado no resíduo ou na diferença entre duas iterações. Ou seja, $\|\mathbf{b} - A\mathbf{x}^{(k)}\|_{\infty}$ ou $\|\mathbf{x}^{(k+1)} - \mathbf{x}^{(k)}\|_{\infty}$, respectivamente.
- Na prática, é difícil usarmos uma implementação geral, escrita na forma matricial. Isso porque para matrizes esparsas precisamos estar atentos a implementação, para que não tenhamos desperdício de espaço, armazenando uma matriz com muitos zeros e de tempo, fazendo contas com zeros.

3.4.2 Método de Gauss-Seidel

A partir de uma solução inicial $\mathbf{x}^0$ e supondo $a_{ii} \neq 0$ para todo i , o **método de Gauss-Seidel** é um processo iterativo muito parecido com o método de Jacobi. A fórmula de iteração também é obtida a partir de (3.6), ao isolarmos cada uma das incógnitas em uma das equações, obtendo,

$$\begin{aligned} x_1^{(k+1)} &= \frac{1}{a_{11}} \left(b_1 - a_{12}x_2^{(k)} - a_{13}x_3^{(k)} - \dots - a_{1n}x_n^{(k)} \right) \\ x_2^{(k+1)} &= \frac{1}{a_{22}} \left(b_2 - a_{21}x_1^{(k+1)} - a_{23}x_3^{(k)} - \dots - a_{2n}x_n^{(k)} \right) \\ &\vdots \\ x_n^{(k+1)} &= \frac{1}{a_{nn}} \left(b_n - a_{n1}x_1^{(k+1)} - a_{n3}x_3^{(k+1)} - \dots - a_{n,n-1}x_{n,n-1}^{(k+1)} \right) \end{aligned} \quad (3.9)$$

para $k = 0, 1, \dots$. A principal diferença é que a solução aproximada de cada iteração $\mathbf{x}^{(k+1)}$, utiliza a aproximação da iteração anterior k e já utiliza as componentes já atualizadas na própria iteração $k + 1$. De uma forma compacta, temos,

$$x_1^{(k)} = \frac{b_1 - \sum_{j=2}^n a_{1j}x_j^{(k-1)}}{a_{11}}, \dots, x_i^{(k)} = \frac{b_i - \sum_{j=1, j \neq i}^n a_{ij}x_j^{(k-1)}}{a_{ii}}, \dots, x_n = \frac{b_n - \sum_{j=1}^{n-1} a_{nj}x_j^{(k-1)}}{a_{nn}}. \quad (3.10)$$

com $k = 1, 2, \dots$. Note que:

- As componentes da solução atualizada já são utilizadas no cálculo da próxima componente da solução.
- Em geral, o método de Gauss-Seidel converge mais rápido.

Exemplo 24 Considere o sistema

$$\begin{cases} 10x_1 - x_2 + 2x_3 = 6 \\ -x_1 + 11x_2 - x_3 + 3x_4 = 25 \\ 2x_1 - x_2 + 10x_3 - x_4 = -11 \\ 3x_2 - x_3 + 8x_4 = 15 \end{cases}$$

Faça duas iterações do método de Gauss-Seidel, partindo da solução inicial $\mathbf{x}^{(0)} = (0, 0, 0, 0)$. Compare os resultados com a solução exata $\mathbf{x} = (1, 2, -1, 1)$ e com a solução obtida pelo método de Jacobi no exemplo 23.

Solução.

O Algoritmo 13 apresenta a estrutura do processo iterativo do Método de Gauss-Seidel.

Algoritmo 13: Método de Gauss-Seidel

Entrada: A , $\mathbf{b}$ e $\mathbf{x}^{(0)}$
 δ (tolerância)
 $k \leftarrow 1$
 $k_{max} \leftarrow 100$
 $r_{max} \leftarrow 1$
enquanto ($r_{max} > \delta$ e $k < k_{max}$) **faça**
 para $i = 1$ **até** n **faça**
 $x_i \leftarrow \frac{b_i - \sum_{j=1}^{i-1} a_{ij}x_j - \sum_{j=i+1}^n a_{ij}x_j^{(0)}}{a_{ii}}$
 $\mathbf{x}^{(0)} \leftarrow \mathbf{x}$
 $r_{max} \leftarrow \|\mathbf{b} - A\mathbf{x}\|_{\infty}$.
 $k \leftarrow k + 1$
 Devolve $\mathbf{x}$

3.4.3 Convergência dos métodos iterativos

Considere a decomposição $A = L + D + U$, sendo:

- L a parte estritamente triangular inferior de A , com $l_{ij} = a_{ij}$ se $i > j$ e $l_{ij} = 0$ se $i \leq j$;
- D é uma matriz diagonal com $d_{ii} = a_{ii}, \forall i$, e;
- U a parte estritamente triangular superior de A , com $u_{ij} = 0$ se $i \geq j$ e $u_{ij} = a_{ij}$ se $i < j$.

O método de Jacobi, na forma matricial é dado por:

$$D\mathbf{x}^{(k+1)} = \mathbf{b} - (L + U)\mathbf{x}^{(k)} \implies \mathbf{x}^{(k+1)} = D^{-1}(\mathbf{b} - (L + U)\mathbf{x}^{(k)})$$

O método de Gauss-Seidel, na forma matricial é dado por:

$$(L + D)\mathbf{x}^{(k+1)} = \mathbf{b} - U\mathbf{x}^{(k)} \implies \mathbf{x}^{(k+1)} = (L + D)^{-1}(\mathbf{b} - (L + U)\mathbf{x}^{(k)})$$

A análise da convergência é feita reescrevendo as fórmulas de iteração no formato: $\mathbf{x}^{(k+1)} = B\mathbf{x}^{(k)} + \mathbf{c}$, onde B é chamada matriz de iteração.

A matriz de iteração do método de Jacobi é $B_J = -D^{-1}(L + U)$ e o vetor $\mathbf{c} = D^{-1}\mathbf{b}$. A matriz de iteração do método de Gauss-Seidel é $B_{GS} = -(L + D)^{-1}U$ e o vetor $\mathbf{c} = (L + D)^{-1}\mathbf{b}$.

Após k iterações obtemos $\mathbf{x}^{(k)} = B^k\mathbf{x}^{(0)} + \tilde{\mathbf{c}}$. Por exemplo, $\mathbf{x}^{(1)} = B\mathbf{x}^{(0)} + \mathbf{c}$ e $\mathbf{x}^{(2)} = B\mathbf{x}^{(1)} + \mathbf{c}$. Portanto, $\mathbf{x}^{(2)} = B(B\mathbf{x}^{(0)} + \mathbf{c}) + \mathbf{c} = B^2\mathbf{x}^{(0)} + B\mathbf{c} + \mathbf{c}$, com $\tilde{\mathbf{c}} = B\mathbf{c} + \mathbf{c}$.

A análise da convergência é feita reescrevendo: $\mathbf{x}^{(k+1)} = B\mathbf{x}^{(k)} + \mathbf{c}$ onde B é a matriz de iteração, sendo $B^J = D^{-1}(L + U)$ e $B^{GS} = (L + D)^{-1}U$. Após k iterações obtemos $\mathbf{x}^{(k)} = B^k\mathbf{x}^{(0)} + d$.

A convergência é estudada por meio da análise dos autovalores da matriz de iteração B . Os autovalores λ da matriz B são obtidos a partir de $B\mathbf{u} = \lambda\mathbf{u}$, onde $\mathbf{u}$ são os autovetores de B .

Teorema 3 O método iterativo $\mathbf{x}^{(k+1)} = B\mathbf{x}^k + \mathbf{c}$ converge se e somente se os autovalores de B satisfazem $\max_{1 \leq i \leq n} |\lambda_i| < 1$

Ou seja, se o raio espectral da matriz de iteração, $\rho(B) := \max_{1 \leq i \leq n} |\lambda_i| < 1$.

Os critérios de convergência para se verificar na prática são: Critério das Linhas e Critério de Sassenfeld, que são condições suficientes para garantir a convergência.

- **Critério das linhas:** $\sum_{j=1, j \neq i}^n |a_{ij}| < |a_{ii}|$, ou seja, se a matriz A for estritamente diagonal dominante, podemos garantir a convergência do método iterativo.

- **Critério de Sassenfeld:**

Sejam $\beta_1 = \frac{\sum_{j=2}^n |a_{1j}|}{|a_{11}|}$ e $\beta_i = \frac{\sum_{j=2}^{i-1} |a_{ij}| \beta_j + \sum_{j=i+1}^n |a_{ij}|}{|a_{ii}|}$ para $i = 2, 3, \dots, n$.

Por indução, mostra-se que $\mathbf{e}^{(k+1)} \leq \beta \mathbf{e}^{(k)}$, com $\beta = \max_{1 \leq i \leq n} \beta_i$, onde $\mathbf{e}$ é solução do problema residual $A\mathbf{e} = \mathbf{r}$.


Temos que $\mathbf{e}^{(k+1)} \leq \beta \mathbf{e}^{(k)} \leq \beta(\beta \mathbf{e}^{(k-1)}) = \beta^2 \mathbf{e}^{(k-1)} \leq \dots \leq \beta^{k+1} \mathbf{e}^{(0)}$.

Assim, $\lim_{k \rightarrow \infty} \|\mathbf{e}^{(k)}\| \leq \|\mathbf{e}^{(0)}\| \lim_{k \rightarrow \infty} \beta^k = 0$ somente se $\beta < 1$.

Se $\beta < 1$ então os métodos de Jacobi e Gauss-Seidel convergem para qualquer $\mathbf{x}^{(0)}$.

- Além disso, quanto menor β mais rápida a convergência.

Na representação a seguir temos os seguintes subconjuntos: SLD (Sistemas lineares determinados), SC (Sistemas lineares que convergem), CS (Sistemas lineares que satisfazem o critério de Sassenfeld) e CL (Sistemas lineares que satisfazem o critério das linhas).



Note que temos sistemas lineares que convergem e que não satisfazem nenhuma das condições suficientes que garantem a convergência.

3.4.4 Método SOR (*Successive Over Relaxation*)

A **Relaxação Sucessiva** é uma técnica de aceleração de convergência dos métodos iterativos estudados. A aproximação $\mathbf{x}^{(k+1)}$ é uma média ponderada entre $\mathbf{x}^{(k)}$ (aproximação da iteração anterior) e a aproximação que seria obtida pelo método de Gauss-Seidel. Para cada componente de $\mathbf{x}$ temos

$$x_i^{(k+1)} = (1 - \omega)x_i^{(k)} + \frac{\omega}{a_{ii}}(b_i - \sum_{j=1}^{i-1} a_{ij}x_j^{(k+1)} - \sum_{j=i+1}^n a_{ij}x_j^{(k)}), \quad (3.11)$$

onde ω é o parâmetro de relaxação e sua escolha varia de $0 < \omega < 2$ (o método só converge nesse intervalo). Se $\omega = 1$ temos o método de Gauss-Seidel. Para alguns problemas é possível determinar ω ótimo.

Exemplo 25 Considere o sistema de equações,

$$\begin{array}{rcccccl} 2x_1 & - & x_2 & & & = & 1 \\ -x_1 & + & 2x_2 & - & x_3 & = & 0 \\ & & -x_2 & + & 2x_3 & - & x_4 = 0 \\ & & & & -x_3 & + & 2x_4 = 1 \end{array}$$

Faça duas iterações do método SOR com $\omega = 1.3$, partido de $\mathbf{x}^{(0)} = (0, 0, 0, 0)$. A solução exata é $\mathbf{x} = (1, 1, 1, 1)$.

Solução.

O Algoritmo 14 apresenta a estrutura do processo iterativo do Método SOR.

Algoritmo 14: Método SOR

Entrada: A , $\mathbf{b}$ e $\mathbf{x}^{(0)}$

δ (tolerância)

$k \leftarrow 1$

$k_{max} \leftarrow 100$

$r_{max} \leftarrow 1$

enquanto ($r_{max} > \delta$ e $k < k_{max}$) **faça**

para $i = 1$ até n **faça**

$x_i \leftarrow (1 - \omega)x_i^{(0)} + \frac{\omega}{a_{ii}}(b_i - \sum_{j=1}^{i-1} a_{ij}x_j - \sum_{j=i+1}^n a_{ij}x_j^{(0)})$

$\mathbf{x}^{(0)} \leftarrow \mathbf{x}$

$r_{max} \leftarrow \|\mathbf{b} - A\mathbf{x}\|_\infty$.

$k \leftarrow k + 1$

Devolve $\mathbf{x}$

Comentários finais sobre métodos para sistemas lineares:

- Existem muitos outros métodos iterativos, como por exemplo, Gradientes Conjugados, Multigrid, com vantagens e desvantagens como os apresentados nesta unidade. A decisão de qual utilizar, depende do problema a ser resolvido.
- A utilização de métodos diretos, como Eliminação de Gauss, pode ser catastrófica se o sistema for mal condicionado, por conta dos erros de arredondamento.
- Para os métodos iterativos que satisfazem algum critério de convergência, a convergência é garantida para qualquer aproximação inicial e a influência dos erros de arredondamento é pequena.
- Métodos iterativos são recomendados para sistemas lineares esparsos, pois grande parte dos coeficientes da matriz será nulo.
- O método de Eliminação de Gauss tem a vantagem de fornecer o determinante da matriz de coeficientes. Com isso podemos saber se o sistema é determinado ou não.

3.5 Exercícios

1. Considere o seguinte sistema linear

$$\begin{cases} 2x_1 + 3x_2 & = 1 \\ x_1 + 2x_2 & = 2 \\ 2x_1 + x_2 + x_3 + 2x_4 & = 3 \\ 3x_1 - x_2 + x_4 & = 4 \end{cases}$$

que possui única solução $\mathbf{x} = (\tilde{x}_1, \tilde{x}_2, \tilde{x}_3, \tilde{x}_4)$.

- (a) O sistema satisfaz o critério de Sassenfeld?
- (b) Faça três iterações do Método de Jacobi e do Método de Gauss-Seidel.

2. O sistema linear $A\mathbf{x} = \mathbf{b}$ onde

$$A = \begin{pmatrix} 6 & 0.2 & -0.1 \\ 1 & 2 & 0.1 \\ -2 & 2 & 4 \end{pmatrix} \text{ e } \mathbf{b} = \begin{pmatrix} 1 \\ 0 \\ 0 \end{pmatrix}$$

- (a) satisfaz o Critério da Linhas?
- (b) satisfaz o Critério de Sassenfeld?

3. Quantas operações são realizadas em cada iteração dos métodos de Jacobi, Gauss-Seidel e SOR quando:

- (a) A é uma matriz $n \times n$?
- (b) A é uma matriz de banda $p + q + 1$?
- (c) Em quais condições os métodos iterativos serão competitivos com o Método de Eliminação Gaussiana?

4. Considere o sistema linear,

$$\begin{cases} x_1 + x_2 + 4x_3 + x_4 = 2 \\ + 2x_3 + 4x_4 = 9 \\ 2x_1 + 4x_2 - x_3 = 2 \\ 5x_1 + x_2 + x_3 + 2x_4 = 0 \end{cases}$$

- (a) Monte o esquema iterativo para o método de Gauss Seidel de forma que a convergência seja garantida.
- (b) Faça três iterações do método de Gauss Seidel e calcule $\max_{1 \leq i \leq n} |x_i^{(k+1)} - x_i^{(k)}|$ a cada iteração.

5. Resolva o sistema definido por

$$\begin{cases} -2(1+h^2)x_1 + x_2 = 1, \\ x_{i-1} - 2(1+h^2)x_i + x_{i+1} = 0, \quad \text{para } i = 2, \dots, n-1, \\ x_{n-1} - 2(1+h^2)x_n = 0. \end{cases}$$

com $N = 5$ e $h = 0.1$, usando Jacobi e Gauss-Seidel. Implemente este problema e compare os resultados dos métodos de Jacobi, Gauss-Seidel e SOR (com valores de $\omega = 0.2i$, $i = 1, 2, \dots, 9$) para $n = 30$ e tolerância 10^{-4} .

6. Considere o sistema linear $A\mathbf{x} = \mathbf{b}$, sendo

$$A = \begin{pmatrix} k & 3 & 1 \\ k & 7 & 1 \\ 1 & 6 & 8 \end{pmatrix} \quad \text{e} \quad \mathbf{b} = \begin{pmatrix} 1 \\ 2 \\ 3 \end{pmatrix}$$

- (a) Usando o critério das linhas, verifique quais os valores positivos de k podemos garantir convergência.
- (b) Com base no item anterior, escolha o menor inteiro positivo k e faça três iterações do método de Gauss-Seidel.
- (c) Faça três iterações do método SOR com $w = 1.6$ e compare com os resultados obtidos em (b).

7. Considere o sistema linear,

$$\begin{aligned} x_1 + 3x_2 - x_3 &= -2 \\ 5x_1 + 2x_2 + 2x_3 &= 3 \\ 6x_2 + 8x_3 &= -6 \end{aligned}$$

- (a) É possível garantir a convergência do método iterativo de Gauss-Seidel, quando o aplicamos neste sistema linear? Justifique.
- (b) Faça duas iterações do método de Gauss-Seidel, partindo da aproximação inicial $\mathbf{x}^{(0)} = (0.7, -1.6, 0.6)^T$.
- (c) Qual a diferença entre os métodos iterativos de Jacobi, Gauss-Seidel e SOR?

8. Deseja-se resolver o sistema linear

$$\begin{pmatrix} 4 & 1 & 2 \\ 2 & -3 & 1 \\ -1 & 1 & -2 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \\ x_3 \end{pmatrix} = \begin{pmatrix} 7 \\ 0 \\ 1 \end{pmatrix}$$

pelo método de Gauss-Seidel. Sabe-se que a solução está no cubo $[-3, 3] \times [-3, 3] \times [-3, 3]$. Escolha uma aproximação inicial e apresente o número de iterações necessárias para se ter certeza que o erro será menor que 0.01.

9. Uma barra linear de um metro de comprimento é mantida a 0 graus em um extremo e a 128 graus no outro. Desejamos determinar a temperatura na barra a cada 20 cm. Denominando $T_0 = 0$ a temperatura de um extremo e $T_5 = 128$ a temperatura no outro extremo e de T_1, T_2, T_3 e T_4 as temperaturas nos pontos interiores e sabendo que a temperatura em cada ponto interior é igual à média aritmética de seus dois pontos vizinhos:

(a) Mostre que o sistema linear obtido é

$$\begin{pmatrix} 2 & -1 & 0 & 0 \\ -1 & 2 & -1 & 0 \\ 0 & -1 & 2 & -1 \\ 0 & 0 & -1 & 2 \end{pmatrix} \begin{pmatrix} T_1 \\ T_2 \\ T_3 \\ T_4 \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \\ 0 \\ 128 \end{pmatrix}$$

- (b) Verifique se é possível garantir a convergência do método de Gauss-Seidel. Justifique!
- (c) Calcule 2 iterações pelo método de Gauss-Seidel para a solução deste sistema a partir da aproximação inicial nula.

10. Considere o sistema linear $A\mathbf{x} = \mathbf{b}$, com

$$A = \begin{pmatrix} 5 & -1 & 1 & w \\ -1 & 7 & 1 & -2 \\ 0 & -2 & 5 & 0 \\ w & -1 & 0 & 2 \end{pmatrix}, \quad \mathbf{b} = \begin{pmatrix} 2 \\ -6 \\ 7 \\ 1 \end{pmatrix}$$

- (a) Para quais valores de w a matriz A satisfaz o critério das linhas?
- (b) Calcule duas iterações do método de Gauss-Seidel, com $w = 1$ e partindo da aproximação inicial nula. A convergência do método é garantida?
- (c) Compare a solução aproximada (obtida no item anterior) com a solução exata $\mathbf{x} = (0, -1, 1, 0)^T$.

11. Considere a tabela,

	1	3	
2	x	y	3
5	w	z	0
	7	1	

Use o método de Gauss-Seidel para determinar x, y, z, w tais que cada posição da tabela que contenha uma incógnita seja a média aritmética das quatro posições vizinhas (considerando apenas vizinhas horizontais e verticais). Use como chute inicial $x^0 = (0, 0, 0, 0)$.

12. Considere o sistema linear:

$$\begin{array}{cccccccl} -x_1 & + & 2x_2 & - & x_3 & & = & 1 \\ 2x_1 & - & x_2 & & & & = & 1 \\ & - & x_2 & + & 2x_3 & - & x_4 & = & 1 \\ & & & - & x_3 & + & 2x_4 & = & 1 \end{array}$$

- (a) O sistema satisfaz o critério das linhas?
- (b) O sistema satisfaz o critério de Sassenfeld?
- (c) O sistema obtido trocando-se as duas primeiras equações satisfaz o critério de Sassenfeld?

UNIDADE 4

SISTEMAS DE EQUAÇÕES NÃO LINEARES

Nesta unidade vamos estudar métodos numéricos para a aproximação de sistemas de equações não lineares. Os sistemas de equações não lineares são sistemas de equações acopladas entre si da forma:

$$\begin{cases} f_1(x_1, x_2, \dots, x_n) = 0 \\ f_2(x_1, x_2, \dots, x_n) = 0 \\ \vdots \\ f_n(x_1, x_2, \dots, x_n) = 0 \end{cases} \quad (4.1)$$

sendo $f_1, f_2, \dots, f_n$ funções não lineares e $x_1, x_2, \dots, x_n$ as incógnitas.

Exemplo 26 O sistema de equações,

$$\begin{cases} x_1^2 + x_2^2 - 2 = 0 \\ x_1^2 - \frac{x_2^2}{9} - 1 = 0 \end{cases}$$

Neste sistema temos, $f_1(x_1, x_2) = x_1^2 + x_2^2 - 2$ e $f_2(x_1, x_2) = x_1^2 - x_2^2/9 - 1$. Não conseguimos representá-lo no formato $A\mathbf{x} = \mathbf{b}$. Este é um sistema não linear que admite quatro soluções, que são os pontos onde as curvas se intersectam.

A Seção 4.1 apresenta um problema de aplicação. A Seção 4.2 apresenta a notação e alguns operadores diferenciais. Na Seção 4.3 apresentamos o método de Newton para sistemas não lineares. A Seção 4.4 apresenta métodos alternativos ao método de Newton. A unidade encerra com uma lista de exercícios.

4.1 Motivação

Assim como sistemas de equações lineares aparecem em modelos matemáticos de diversas áreas, também encontramos sistemas de equações lineares em diferentes problemas de

aplicação. Em [1] os autores apresentam o seguinte problema de motivação.

A pressão total necessária para afundar um objeto grande e pesado em um solo macio, homogêneo e assentado sobre um solo com uma base dura, pode ser prevista pela pressão total necessária para afundar objetos menores o mesmo solo. Especificamente, a pressão total p para afundar uma placa circular de raio r até uma profundidade d no solo macio, em que o solo duro fica a uma profundidade $D > d$ abaixo da superfície, pode ser aproximada por uma equação da forma

$$p = k_1 e^{k_2 r} + k_3 r, \quad (4.2)$$

sendo k_1 , k_2 e k_3 constantes, dependendo de d e da consistência do solo, mas que não dependem do raio da placa. Existem três constantes desconhecidas nessa equação, de modo que se afundam três pequenas placas, de raios distintos, na mesma profundidade. Isso permitirá a determinação do tamanho mínimo da placa necessária para sustentar uma carga maior. As cargas necessárias para estes afundamentos são apresentadas na Figura 4.1. Conhecendo a massa e o raio de cada uma das três placas, obtemos três




Fig. 4.1: Três placas de diferentes tamanhos [1].

equações,

$$\begin{aligned} k_1 e^{k_2 r_1} + k_3 r_1 &= m_1 \\ k_1 e^{k_2 r_2} + k_3 r_2 &= m_2 \\ k_1 e^{k_2 r_3} + k_3 r_3 &= m_3 \end{aligned} \quad (4.3)$$

com as três incógnitas k_1 , k_2 e k_3 .

Em geral um sistema de equações não lineares é evitado, quando se é possível linearizar o problema. Quando isso não é possível, o resolvemos numericamente. Os métodos numéricos são extensões dos métodos estudados na Unidade 2, métodos que aproximam a solução de uma equação algébrica.

4.2 Conceitos fundamentais

Na equação (4.1), cada $f_i : \mathbb{R}^n \rightarrow \mathbb{R}$, $\mathbf{x} \in \mathbb{R}^n$ e $\mathbf{F} : \mathbb{R}^n \rightarrow \mathbb{R}^n$. Na notação vetorial $\mathbf{x}$ é um vetor de n componentes e $\mathbf{F}(\mathbf{x})$ é uma função vetorial de variável vetorial, isto é,

$\mathbf{x} = (x_1, x_2, \dots, x_n)$ e $\mathbf{F}(\mathbf{x}) = (f_1(\mathbf{x}), f_2(\mathbf{x}), \dots, f_n(\mathbf{x}))$. O sistema será representado por $\mathbf{F}(\mathbf{x}) = \mathbf{0}$. No caso de sistemas lineares: $\mathbf{F}(\mathbf{x}) = A\mathbf{x} - \mathbf{b}$, com $A \in \mathbb{R}^{n \times n}$.

O **vetor gradiente** (vetor de derivadas parciais) de $f_i(x_1, x_2, \dots, x_n)$ é dado por $\nabla f_i(\mathbf{x}) = \left(\frac{\partial f_i}{\partial x_1}, \dots, \frac{\partial f_i}{\partial x_n} \right)^T$.

A derivada de uma função vetorial com variáveis vetoriais, é uma matriz que contém todas as derivadas parciais de todas as componentes da função $\mathbf{F}(\mathbf{x})$. Essa matriz é chamada **matriz Jacobiana**, denotada por,

$$\mathbf{J}(\mathbf{x}) = \begin{pmatrix} \nabla f_1^T \\ \vdots \\ \nabla f_n^T \end{pmatrix}$$

Exemplo 27 Determine a matriz Jacobiana do sistema de equações

$$\begin{cases} x_1^3 - 3x_1x_2^2 = -1 \\ 3x_1^2x_2 - x_2^3 = 0 \end{cases}$$

Solução. Primeiro vamos identificar a $\mathbf{F}(\mathbf{x})$ associada ao sistema, ou seja, $\mathbf{F}(\mathbf{x}) = \mathbf{0}$. Temos,

$$\mathbf{F}(\mathbf{x}) = \begin{pmatrix} x_1^3 - 3x_1x_2^2 + 1 \\ 3x_1^2x_2 - x_2^3 \end{pmatrix}$$

com $\mathbf{x} = (x_1, x_2)$, $f_1(x_1, x_2) = x_1^3 - 3x_1x_2^2 + 1$ e $f_2(x_1, x_2) = 3x_1^2x_2 - x_2^3$. Agora vamos determinar a matriz Jacobiana,

$$\mathbf{J}(\mathbf{x}) = \begin{pmatrix} \frac{\partial f_1}{\partial x_1} & \frac{\partial f_1}{\partial x_2} \\ \frac{\partial f_2}{\partial x_1} & \frac{\partial f_2}{\partial x_2} \end{pmatrix} = \begin{pmatrix} 3x_1^2 - 3x_2^2 & -6x_1x_2 \\ 6x_1x_2 & 3x_1^2 - 3x_2^2 \end{pmatrix}$$

Suponha que $\mathbf{F}$ está definida em um conjunto aberto $D \subset \mathbb{R}^n$ e que $\mathbf{F}$ possui derivadas contínuas. Também suponha que existe $\mathbf{x}^* \in D$ tal que $\mathbf{F}(\mathbf{x}^*) = \mathbf{0}$. Podemos generalizar o método das Aproximações Sucessivas, que se baseia no conceito do Ponto Fixo, conforme visto na Seção 2.3. O procedimento é similar ao proposto no problema de determinar a solução de uma equação com uma variável (equação algébrica). A ideia é transformar o problema original $\mathbf{F}(\mathbf{x}) = \mathbf{0}$ em um problema de ponto fixo $\mathbf{G}(\mathbf{x}) = \mathbf{x}$ pode ser feito em uma função $G : D \subset \mathbb{R}^n \rightarrow \mathbb{R}^n$. Existe um resultado equivalente ao Teorema 2 para sistemas de equações não lineares que garantem a convergência do método do Ponto Fixo: *Supondo que $\mathbf{G}$ tem derivadas parciais contínuas e $k < 1$, $\left| \frac{\partial g_i(x)}{\partial x_j} \right| \leq \frac{k}{n}$, $x \in D$, a sequência de aproximações $\mathbf{x}^k = \mathbf{G}(\mathbf{x}^{k-1})$, com $k \geq 1$ converge para o ponto fixo $\mathbf{x}^*$*

O problema continua o mesmo: Determinar $\mathbf{G}$ que satisfaça as condições do Teorema.

4.3 Método de Newton

A ideia é estender o método de Newton para sistemas de equações não lineares. A ideia continua sendo: Construir um modelo linear local para um sistema não linear.

A série de Taylor é muito usada para aproximar funções. No caso escalar (uma equação não linear) onde $f(x)$ e x são números reais, a série de Taylor em torno de x_k é dada por

$$f(x_{k+1}) = f(x_k) + f'(x_k)(x_{k+1} - x_k) + \frac{f''(x_k)}{2!}(x - x_k)^2 + \dots + \frac{f^n(x_k)}{n!}(x - x_k)^n + E,$$

com $E = \frac{f^{n+1}(c)}{(n+1)!}(x - x_k)^{n+1}$ e $c \in [x, x_k]$. Para o erro usaremos a notação $E = O(\Delta x^{n+1})$, ou seja, $E \leq C\Delta x^{n+1}$, com C uma constante e $\Delta x = x_{k+1} - x_k$, o tamanho da vizinhança de x_{k+1} .

Para a aproximação linear do problema $f(x) = 0$ usamos os dois primeiros termos da série. Assim,

$$f(x) \approx f(x_k) + f'(x_k)(x_{k+1} - x_k) = 0$$

Supondo que conhecemos x_k , determinamos x_{k+1} por meio do método de Newton para uma equação,

$$x_{k+1} = x_k - \frac{f(x_k)}{f'(x_k)}.$$

Usando a mesma ideia para um sistema de equações não lineares, obtemos uma aproximação linear para cada componente $f_i(\mathbf{x})$, com a série de Taylor,

$$f_i(\mathbf{x}^{k+1}) \approx f_i(\mathbf{x}^k) + \nabla f_i(\mathbf{x}^k)^T (\mathbf{x}^{k+1} - \mathbf{x}^k).$$

Na forma vetorial,

$$\mathbf{F}(\mathbf{x}^{k+1}) \approx \mathbf{F}(\mathbf{x}^k) + J(\mathbf{x}^k)(\mathbf{x}^{k+1} - \mathbf{x}^k)$$

Assim, a aproximação $\mathbf{x}^{k+1}$ será o zero do modelo linear local,

$$\begin{aligned} \mathbf{F}(\mathbf{x}^k) + J(\mathbf{x}^k)(\mathbf{x}^{k+1} - \mathbf{x}^k) &= \mathbf{0} \\ J(\mathbf{x}^k)(\mathbf{x}^{k+1} - \mathbf{x}^k) &= -\mathbf{F}(\mathbf{x}^k). \end{aligned}$$

A iteração do método de Newton é definida por,

$$\mathbf{x}^{k+1} = \mathbf{x}^k - [J(\mathbf{x}^k)]^{-1} \mathbf{F}(\mathbf{x}^k). \quad (4.4)$$

Se $\Delta \mathbf{x} = \mathbf{x}^{(k+1)} - \mathbf{x}^{(k)}$ então temos $\Delta \mathbf{x} = -J(\mathbf{x}^{(k)})^{-1} \mathbf{F}(\mathbf{x}^{(k)})$, que é a solução do sistema linear $J(\mathbf{x}^k) \Delta \mathbf{x}^k = -\mathbf{F}(\mathbf{x}^k)$. Assim temos $\mathbf{x}^{k+1} = \mathbf{x}^k + \Delta \mathbf{x}$.

Dessa forma cada iteração do método de Newton requer:

- (a) A avaliação da matriz Jacobiana $J(\mathbf{x}^k)$ e $\mathbf{F}(\mathbf{x}^k)$.
- (b) A resolução de um sistema linear $J(\mathbf{x}^k) \Delta \mathbf{x}^k = -\mathbf{F}(\mathbf{x}^k)$.

(c) A atualização da solução: $\mathbf{x}^{k+1} = \mathbf{x}^k + \Delta \mathbf{x}$.

Exemplo 28 Considere o sistema de equações

$$\begin{cases} 2x_1^3 - x_2^2 = 1 \\ x_1x_2^3 - x_2 = 4 \end{cases}$$

Utilize o método de Newton para resolver o sistema não linear, partindo da aproximação inicial $\mathbf{x}^{(0)} = (1.2, 1.7)$.

Solução. Primeiro, vamos escrever o sistema no formato $\mathbf{F}(\mathbf{x}) = \mathbf{0}$. Neste caso, temos $f_1(x_1, x_2) = 2x_1^3 - x_2^2 - 1$ e $f_2(x_1, x_2) = x_1x_2^3 - x_2 - 4$, com $\mathbf{x} = (x_1, x_2)$ e então,

$$\mathbf{F}(\mathbf{x}) = \begin{pmatrix} 2x_1^3 - x_2^2 - 1 \\ x_1x_2^3 - x_2 - 4 \end{pmatrix}$$

Vamos determinar a matriz Jacobiana,

$$J(\mathbf{x}) = \begin{pmatrix} \frac{\partial f_1}{\partial x_1} & \frac{\partial f_1}{\partial x_2} \\ \frac{\partial f_2}{\partial x_1} & \frac{\partial f_2}{\partial x_2} \end{pmatrix} = \begin{pmatrix} 6x_1^2 & -2x_2 \\ x_2^3 & 3x_1x_2^2 - 1 \end{pmatrix}$$

Agora vamos fazer uma iteração do método de Newton, usando 6 algarismos significativos. A cada iteração precisamos realizar os passos (a), (b) e (c) descritos acima.

Primeira iteração:

(a) Avaliar $\mathbf{F}(\mathbf{x}^{(0)})$ e $J(\mathbf{x}^{(0)})$, com $\mathbf{x}^{(0)} = (1.2, 1.7)$. Temos,

$$\mathbf{F}(\mathbf{x}^{(0)}) = \begin{pmatrix} 2x_1^3 - x_2^2 - 1 \\ x_1x_2^3 - x_2 - 4 \end{pmatrix} = \begin{pmatrix} 2 \times 1.2^3 - 1.7^2 - 1 \\ 1.2 \times 1.7^3 - 1.7 - 4 \end{pmatrix} = \begin{pmatrix} -0.434 \\ 0.1956 \end{pmatrix} \text{ e}$$

$$J(\mathbf{x}^{(0)}) = \begin{pmatrix} 6x_1^2 & -2x_2 \\ x_2^3 & 3x_1x_2^2 - 1 \end{pmatrix} = \begin{pmatrix} 6 \times 1.2^2 & -2 \times 1.7 \\ 1.7^3 & 3 \times 1.2 \times 1.7^2 - 1 \end{pmatrix} = \begin{pmatrix} 8.64 & -3.4 \\ 4.913 & 9.404 \end{pmatrix}$$

(b) Resolver o sistema $J(\mathbf{x}^{(0)})\Delta \mathbf{x} = -\mathbf{F}(\mathbf{x}^{(0)})$. Neste caso,

$$\begin{pmatrix} 8.64 & -3.4 \\ 4.913 & 9.404 \end{pmatrix} \begin{pmatrix} \Delta x_1 \\ \Delta x_2 \end{pmatrix} = \begin{pmatrix} 0.434 \\ -0.1956 \end{pmatrix}$$

Usando o método de Eliminação de Gauss,

$$\left(\begin{array}{cc|c} 8.64 & -3.4 & 0.434 \\ 4.913 & 9.404 & -0.1956 \end{array} \right) \sim \left(\begin{array}{cc|c} 8.64 & -3.4 & 0.434 \\ 0.568634 & 11.3374 & -0.442387 \end{array} \right)$$

Com um passo do método de Eliminação de Gauss: $L_2 \leftarrow L_2 - m_{21}L_1$, com $m_{21} = \frac{4.913}{8.64} \approx 0.568634$ (armazenada na posição a_{21} da matriz aumentada) e os demais elementos da segunda linha da matriz aumentada: $a_{22} = 9.404 - 0.568634 \times (-3.4) \approx 11.3374$ e $b_2 = -0.1956 - 0.568634 \times 0.434 \approx -0.442387$. Resolvendo o sistema triangular superior:

$$\Delta x_2 = \frac{-0.442387}{11.3374} \approx -0.0390201,$$

$$\Delta x_1 = \frac{0.434 + 3.4 \times (-0.0390201)}{8.64} \approx \frac{0.301332}{8.64} \approx 0.0348764.$$

(c) Atualizar a solução: $\mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} + \Delta \mathbf{x}$.

Dessa forma, $\mathbf{x}^{(1)} = \mathbf{x}^{(0)} + \mathbf{s}$. Portanto,

$$x_1^{(1)} = x_1^{(0)} + s_1 = 1.2 + 0.0348764 \approx 1.23488$$

$$x_2^{(1)} = x_2^{(0)} + s_2 = 1.7 - 0.0390201 \approx 1.66098$$

Ao avaliar, $\mathbf{F}(\mathbf{x}^{(1)})$ temos uma medida de quão próximo da solução estamos,

$$\mathbf{F}(\mathbf{x}^{(1)}) = \begin{pmatrix} 2x_1^3 - x_2^2 - 1 \\ x_1x_2^3 - x_2 - 4 \end{pmatrix} = \begin{pmatrix} 2 \times 1.23488^3 - 1.66098^2 - 1 \\ 1.23488 \times 1.66098^3 - 1.66098 - 4 \end{pmatrix} = \begin{pmatrix} 0.00735313 \\ -0.00226311 \end{pmatrix}$$

Segunda iteração:

4.4 Alternativas ao método de Newton

A generalização do método de **Newton Modificado** para sistemas de equações não lineares é dada por:

$$\mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} - [J(\mathbf{x}^{(0)})]^{-1} \mathbf{F}(\mathbf{x})^{(k)},$$

sendo $J(\mathbf{x}^{(0)})$ a matriz Jacobiana avaliada na aproximação inicial $\mathbf{x}^{(0)}$. Note que a matriz Jacobiana permanece a mesma em todas as iterações. Neste caso, pode ser vantajoso usar a fatoração LU e resolver dois sistemas triangulares a cada iteração. Isso, por que a cada iteração teremos um sistema linear para ser resolvido com a mesma matriz de coeficientes.

Exemplo 29 Considere o sistema de equações

$$\begin{cases} 2x_1^3 - x_2^2 = 1 \\ x_1x_2^3 - x_2 = 4 \end{cases}$$

Utilize o método de Newton Modificado para resolver o sistema não linear, partindo da aproximação inicial $\mathbf{x}^{(0)} = (1.2, 1.7)$.

Solução.

Vimos que o método de Newton contém as seguintes etapas:

- Escolha da aproximação inicial $\mathbf{x}^{(0)}$.
- Cálculo da matriz Jacobiana $J(\mathbf{x}^{(k)})$.
- Solução de um sistema linear $J(\mathbf{x}^{(k)})\mathbf{s} = -\mathbf{F}(\mathbf{x}^{(k)})$.

A seguir apresentamos alguns comentários a respeito destes três pontos.

Sobre a escolha da aproximação inicial:

• Método de Newton Amortecido: A ideia é que uma nova aproximação não forneça resultados piores que os anteriores. Se isso ocorrer, determina-se i tal que,

$$\mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} + \frac{\mathbf{s}}{2^i}, \text{ com } \|\mathbf{F}(\mathbf{x}^{(k+1)})\| \leq \|\mathbf{F}(\mathbf{x}^{(k)})\|.$$

Para mais detalhes veja [3].

Sobre a matriz Jacobiana:

• Método de Newton Discreto: A ideia é aproximar as derivadas parciais numericamente usando o Método de Diferenças Finitas. O Método de Diferenças Finitas são aproximações para as derivadas com base na série de Taylor. Neste caso, para a primeira derivada temos:

$$\frac{\partial f_i}{\partial x_j} \approx \frac{f_i(x_1, \dots, x_j + h, \dots, x_n) - f_i(x_1, \dots, x_j - h, \dots, x_n)}{2h}.$$

• Métodos Quase Newton: A ideia é substituir a matriz Jacobiana por uma matriz J_k . Pode ser considerada uma generalização do método da Secante. Um deles é método de Broyden. A partir de duas aproximações $\mathbf{x}^{(k+1)}$ e $\mathbf{x}^{(k)}$, substituímos a matriz Jacobiana por uma matriz J_k que satisfaça,

$$J_k(\mathbf{x}^{(k+1)} - \mathbf{x}^{(k)}) = \mathbf{F}(\mathbf{x}^{(k+1)}) - \mathbf{F}(\mathbf{x}^{(k)}).$$

Neste caso, a iteração do método de Broyden é dada por,

$$\mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} - J_k^{-1} \mathbf{F}(\mathbf{x}^{(k)}).$$

Uma aproximação para J_k é dada pela fórmula de recorrência,

$$J_{k+1} = J_k + \left(\frac{\mathbf{y} - J_k \mathbf{s}}{\mathbf{s}^T \mathbf{s}} \right) \mathbf{s}^T,$$

sendo $\mathbf{s} = \mathbf{x}^{(k+1)} - \mathbf{x}^{(k)}$ e $\mathbf{y} = \mathbf{F}(\mathbf{x}^{(k+1)}) - \mathbf{F}(\mathbf{x}^{(k)})$. A fórmula de Shermann-Morrison que avalia a inversa de J_k é dada por,

$$J_{k+1}^{-1} = J_k^{-1} + \frac{(\mathbf{s} - J_k^{-1} \mathbf{y}) \mathbf{s}^T J_k^{-1}}{\mathbf{s}^T J_k^{-1} \mathbf{y}}.$$

Para mais detalhes veja [1] e [6].

Sobre a resolução do sistema:

- Fatoração LU: pode ser utilizada no método de Newton Modificado, ou quando usamos uma matriz Jacobiana fixa por algumas iterações.

- Métodos de Newton Inexato: Quando usamos métodos iterativos podemos adotar um número fixo de iterações (para cada iteração do método de Newton), em vez de aguardar a convergência completa. Este procedimento pode ser econômico e eficiente. Alguns autores apresentam como critério de parada:

$$\|J(\mathbf{x}^{(k)})\mathbf{s} + \mathbf{F}(\mathbf{x}^{(k)})\| \leq \theta_k \|\mathbf{F}(\mathbf{x}^{(k)})\|,$$

com $0 < \theta_k < 1$, garantindo convergência linear para o método de Newton Inexato.

4.5 Exercícios

1. Aplicar o método de Newton para a resolução do sistema não linear:

$$\begin{cases} x_1 + x_2 = 3 \\ x_1^2 + x_2^2 = 9 \end{cases}$$

cujas soluções são $\mathbf{x}^* = (3, 0)$ e $\mathbf{x}^* = (0, 3)$, usando a aproximação inicial $\mathbf{x}^0 = (1, 5)$.

2. Use o método de Newton com critério de parada $\max_{1 \leq i \leq n} |x_i^k - x_i^{k-1}| < 10^{-2}$:

$$\begin{cases} x_1^2 + x_2 = 37 \\ x_1 - x_2^2 - 5 = 0 \\ x_1 + x_2 + x_3 - 3 = 0 \end{cases}$$

3. O método de Newton pode ser aplicado para resolver um sistema linear $Ax = b$. Quantas iterações serão realizadas?
4. Considere o sistema não linear:

$$\begin{cases} e^{x_1} - 1 = 0 \\ e^{x_2} - 1 = 0 \end{cases}$$

A solução é $x_1 = 0$ e $x_2 = 0$.

- (a) Verifique se a matriz é inversível na solução.
- (b) Faça três iterações do Método de Newton partindo de $x_1^{(0)} = x_2^{(0)} = 1$. Analise os resultados obtidos.
5. Use o método de Newton com $\mathbf{x}^{(0)} = \mathbf{0}$ para determinar $\mathbf{x}^{(2)}$ para cada um dos seguintes sistemas não lineares.

$$(a) \begin{cases} 4x_1^2 - 20x_1 + \frac{1}{4}x_2^2 + 8 = 0 \\ \frac{1}{2}x_1x_2^2 + 2x_1 - 5x_2 + 8 = 0 \end{cases} \quad (b) \begin{cases} \sin(4\pi x_1x_2) - 2x_2 - x_1 = 0 \\ \frac{1}{2}x_1x_2^2 + 2x_1 - 5x_2 + 8 = 0 \end{cases}$$

6. Elabore um algoritmo para o método de Newton Inexato para a solução de um sistema não linear com n equações e n incógnitas.
7. Implemente o método de Newton, Newton Modificado e Newton Discreto para verificar as soluções dos sistemas não lineares desta lista.
8. Faça duas iterações do método de Newton para obter a aproximação $\mathbf{x}^{(2)}$ do sistema não linear

$$\begin{cases} 3x_1 - \cos(x_2x_3) - \frac{1}{2} = 0 \\ x_1^2 - 81(x_2 + 0.1)^2 + \sin(x_3) + 1.06 = 0 \\ e^{-x_1x_2} + 20x_3 + \frac{10\pi - 3}{3} = 0 \end{cases}$$

partindo da solução aproximada $\mathbf{x}^{(0)} = (0.1, 0.1, -0.1)$, cuja solução aproximada é $\mathbf{x} = (0.5, 0, -0.52359877)$.

9. Considere o sistema de equações

$$\begin{cases} x_1^2 + x_2^2 = 4 \\ 2x_1 - x_2^2 = 0 \end{cases}$$

- (a) Descreva os passos de uma iteração do método de Newton.
- (b) Realize uma iteração do método de Newton, partindo de $x_1 = 1$ e $x_2 = 1$.
- (c) Descreva uma forma de analisar a convergência do método, através de um critério de parada.

UNIDADE 5

APROXIMAÇÃO DE FUNÇÕES E DADOS TABELADOS

Nesta unidade vamos estudar métodos numéricos para aproximar funções e para aproximar dados tabelados. O problema de aproximar funções é denominado problema contínuo. Dada $f(x)$ com $x \in [a, b]$, queremos obter uma função aproximada $g(x)$ para $f(x)$. O problema de aproximar dados tabelados é denominado problema discreto. Dada uma tabela (x_i, y_i) , com $i = 1, \dots, m$, queremos determinar uma função aproximadora $g(x)$ que aproxime a tabela de dados. Veremos duas maneiras de fazer estas aproximações:

1. Método dos Mínimos Quadrados (MMQ): nosso objetivo é minimizar o resíduo entre os dados e uma função aproximadora.
2. Interpolação Polinomial: nesse caso exigimos que o polinômio aproximador "passe" pelos dados a serem aproximados.

5.1 Motivação

A seguir serão apresentados dois problemas de motivação que envolvem tabelas de dados medidos experimentalmente. Nos dois problemas queremos aproximar uma função $f(x)$ por outra função $g(x)$ previamente escolhida, satisfazendo algumas propriedades. A função $g(x)$ substitui $f(x)$ e é usada para estimar valores para determinados x . Quando é necessário aproximar?

- quando são apenas os valores de uma função para um conjunto de pontos e precisamos avaliar f em um ponto não tabelado.
- quando a função em estudo tem uma expressão tal que as operações de diferenciação e integração são difíceis de serem realizadas.

Problema 1:

A seguinte tabela relaciona o calor específico da água e temperatura:

Temperatura ($^{\circ}\text{C}$)	20	25	30	35	40	45	50
Calor específico	0.99907	0.99852	0.99826	0.99818	0.99828	0.99849	0.99878

Suponha que você queira estimar o calor específico da água a 32.5°C . A aproximação de dados via interpolação polinomial ou Método dos Mínimos quadrados lhe ajudará na resolução deste problema.

Problema 2:

Em um artigo tratando da eficiência da utilização de energia das larvas de mariposa, utilizou-se os seguintes dados para determinar a relação entre W , o peso das larvas vivas em gramas e R o consumo de oxigênio das larvas em mililitros por hora. Por razões biológicas existe uma relação entre R e W dada por $R = bW^a$, onde a e b são parâmetros desconhecidos [1].

Como determinar os parâmetros a e b ? Com base nos dados:

W	R	W	R	W	R	W	R
0.017	0.154	0.025	0.23	0.020	0.181	0.025	0.234
0.087	0.296	0.111	0.357	0.085	0.260	0.119	0.299
0.174	0.363	0.212	0.366	0.171	0.334	0.783	1.47
1.11	0.531	0.999	0.771	1.29	0.87	1.32	1.15
1.35	2.48	1.74	2.23	3.02	2.01	3.04	3.59

5.2 Método dos Mínimos Quadrados

O objetivo deste método é minimizar o erro cometido.

Problema: Dada uma tabela de dados (x_i, y_i) com $i = 1, 2, \dots, N$ ou uma função $f(x)$, com $x \in [a, b]$, queremos obter uma função aproximadora $g(x)$ que aproxima y_i ou $f(x)$.

Vamos tratar dois casos:

- **Domínio discreto:** quando a função é tabelada. Temos como dados de entrada N pontos (x_i, y_i) .
- **Domínio Contínuo:** quando $f(x)$ está definida em um intervalo $[a, b]$.

Exemplos:

- Queremos extrair informação de um conjunto de dados de censos demográficos. Como estimar a população em um ano em que não ocorreu o censo?

De forma geral, uma função aproximadora $g(x)$ pode ser escrita como uma combinação linear de uma família de funções,

$$g(x) = \sum_{k=0}^m a_k g_k(x),$$

onde $\{g_k(x)\}$ é uma família de funções previamente escolhida e os parâmetros a_k serão determinados.

Por exemplo, se $g(x)$ é uma função quadrática, temos

$$g(x) = a_0 + a_1x + a_2x^2,$$

sendo a família de funções $\{1, x, x^2\}$, ou seja, $g_0(x) = 1$, $g_1(x) = x$ e $g_2(x) = x^2$.

A escolha da família de funções deve levar em consideração:

- Características da função aproximadora. Por exemplo, polinômios são facilmente avaliados integráveis, diferenciáveis e operações com polinômios resultam em polinômios.
- O comportamento da função a ser aproximada. Por exemplo, o crescimento e a periodicidade.

Para a dedução do MMQ, vamos considerar $g(x) = a_0 + a_1x$ (uma reta), problema conhecido como **Regressão Linear**. Depois, vamos generalizar para uma função aproximadora, linear nos parâmetros, dada por,

$$g(x) = \sum_{k=0}^m a_k g_k(x).$$

Para aproximar uma função tabelada (x_i, y_i) com $i = 1, 2, \dots, N$, a função resíduo é definida por

$$r(\mathbf{a}) = \sum_{i=1}^N [f(x_i) - g(x_i, \mathbf{a})]^2,$$

onde f é a função aproximada e g é a função aproximadora, $g(x, \mathbf{a}) = \sum_{k=0}^m a_k g_k(x)$, com $\mathbf{a} = (a_0, a_1, \dots, a_m)$.

O nosso objetivo é minimizar a função resíduo $r(\mathbf{a})$.

Ou seja, determinar os parâmetros $\mathbf{a}$ que forneçam o valor $r(\mathbf{a})$ mínimo.

5.2.1 Regressão linear

Considere $g(x) = a_0 + a_1x$ a função aproximadora e a função tabelada

x	x_1	x_2	$\dots$	x_N
y	y_1	y_2	$\dots$	y_N

Queremos obter os parâmetros a_0 e a_1 que minimizam a função: $r(a_0, a_1) = \sum_{i=1}^N [y_i - (a_0 + a_1x_i)]^2$.

Para obtermos o mínimo de $r(a_0, a_1)$ é necessário que: $\frac{\partial r}{\partial a_0} = 0$ e $\frac{\partial r}{\partial a_1} = 0$.

Derivando a função resíduo (regra da cadeia) e igualando a zero obtemos:

$$\frac{\partial r}{\partial a_0} = 2 \sum_{i=1}^N (y_i - a_0 - a_1x_i)(-1) = 0, \quad (5.1)$$

$$\frac{\partial r}{\partial a_1} = 2 \sum_{i=1}^N (y_i - a_0 - a_1x_i)(-x_i) = 0. \quad (5.2)$$

Obs.: Note que a função $r(a_0, a_1)$ é convexa (“com concavidade voltada para cima”), garantindo que o ponto crítico $(\tilde{a}_0, \tilde{a}_1)$ é um ponto de mínimo. Para mais detalhes veja [2].

Reescrevendo (5.1) e (5.2) obtemos um sistema linear com duas equações e duas incógnitas a_0 e a_1 ,

$$\left(\sum_{i=1}^N 1 \right) a_0 + \left(\sum_{i=1}^N x_i \right) a_1 = \sum_{i=1}^N y_i, \quad (5.3)$$

$$\left(\sum_{i=1}^N x_i \right) a_0 + \left(\sum_{i=1}^N x_i^2 \right) a_1 = \sum_{i=1}^N x_i y_i. \quad (5.4)$$

Na notação matricial,

$$\begin{pmatrix} \sum_{i=1}^N 1 & \sum_{i=1}^N x_i \\ \sum_{i=1}^N x_i & \sum_{i=1}^N x_i^2 \end{pmatrix} \begin{pmatrix} a_0 \\ a_1 \end{pmatrix} = \begin{pmatrix} \sum_{i=1}^N y_i \\ \sum_{i=1}^N x_i y_i \end{pmatrix}$$

Este sistema é chamado **sistema normal**. Note que a matriz é simétrica.

Para facilitar a generalização do problema para o caso contínuo, vamos usar a notação de produto escalar (ou produto interno).

Considere $\mathbf{1}, \mathbf{x}$ e $\mathbf{y} \in \mathbb{R}^N$, ou seja, $\mathbf{1} = (1, 1, \dots, 1)$, $\mathbf{x} = (x_1, x_2, \dots, x_N)$ e $\mathbf{y} = (y_1, y_2, \dots, y_N)$. O produto escalar de dois vetores é dado por,

$$\langle \mathbf{x}, \mathbf{y} \rangle = x_1y_1 + x_2y_2 + \dots + x_Ny_N = \sum_{i=1}^N x_iy_i.$$

Assim, podemos reescrever:

$$\sum_{i=1}^N 1 = \langle \mathbf{1}, \mathbf{1} \rangle, \sum_{i=1}^N x_i = \langle \mathbf{1}, \mathbf{x} \rangle = \langle \mathbf{x}, \mathbf{1} \rangle, \sum_{i=1}^N x_i^2 = \langle \mathbf{x}, \mathbf{x} \rangle \text{ e } \sum_{i=1}^N y_i = \langle \mathbf{1}, \mathbf{y} \rangle.$$

O sistema normal se torna:

$$\begin{pmatrix} \langle \mathbf{1}, \mathbf{1} \rangle & \langle \mathbf{1}, \mathbf{x} \rangle \\ \langle \mathbf{x}, \mathbf{1} \rangle & \langle \mathbf{x}, \mathbf{x} \rangle \end{pmatrix} \begin{pmatrix} a_0 \\ a_1 \end{pmatrix} = \begin{pmatrix} \langle \mathbf{1}, \mathbf{y} \rangle \\ \langle \mathbf{x}, \mathbf{y} \rangle \end{pmatrix}$$

Resolvendo o sistema normal 2×2 , da regressão linear

$$\langle \mathbf{1}, \mathbf{1} \rangle a_0 + \langle \mathbf{1}, \mathbf{x} \rangle a_1 = \langle \mathbf{1}, \mathbf{y} \rangle \quad (5.5)$$

$$\langle \mathbf{x}, \mathbf{1} \rangle a_0 + \langle \mathbf{x}, \mathbf{x} \rangle a_1 = \langle \mathbf{x}, \mathbf{y} \rangle \quad (5.6)$$

usando as seguintes operações $\langle \mathbf{x}, \mathbf{x} \rangle$ (5.5) – $\langle \mathbf{1}, \mathbf{x} \rangle$ (5.6) obtemos,

$$a_0 = \frac{\langle \mathbf{1}, \mathbf{y} \rangle \langle \mathbf{x}, \mathbf{x} \rangle - \langle \mathbf{1}, \mathbf{x} \rangle \langle \mathbf{x}, \mathbf{y} \rangle}{\langle \mathbf{1}, \mathbf{1} \rangle \langle \mathbf{x}, \mathbf{x} \rangle - \langle \mathbf{1}, \mathbf{x} \rangle^2},$$

e fazendo $\langle \mathbf{1}, \mathbf{1} \rangle$ (5.6) – $\langle \mathbf{1}, \mathbf{x} \rangle$ (5.5) obtemos,

$$a_1 = \frac{\langle \mathbf{1}, \mathbf{1} \rangle \langle \mathbf{x}, \mathbf{y} \rangle - \langle \mathbf{1}, \mathbf{x} \rangle \langle \mathbf{1}, \mathbf{y} \rangle}{\langle \mathbf{1}, \mathbf{1} \rangle \langle \mathbf{x}, \mathbf{x} \rangle - \langle \mathbf{1}, \mathbf{x} \rangle^2}.$$

O que é equivalente, a solução de um sistema 2×2 via Regra de Cramer, o método de custo computacional proibitivo apresentado na Unidade 3.

Exemplo 30 Aproxime os dados da tabela usando MMQ com a função aproximadora $g(x) = a_0 + a_1x$.

x	1	2	3	4	5	6	7	8
y	0.5	0.6	0.9	0.8	1.2	1.5	1.7	2

Solução.

$$\langle \mathbf{1}, \mathbf{1} \rangle = \sum_{i=1}^8 1 = 8$$

$$\langle \mathbf{1}, \mathbf{x} \rangle = \langle \mathbf{x}, \mathbf{1} \rangle = \sum_{i=1}^8 x_i = 1 + 2 + 3 + 4 + 5 + 6 + 7 + 8 = 36$$

$$\langle \mathbf{x}, \mathbf{x} \rangle = \sum_{i=1}^8 x_i^2 = 1^2 + 2^2 + 3^2 + 4^2 + 5^2 + 6^2 + 7^2 + 8^2 = 204$$

$$\langle \mathbf{1}, \mathbf{y} \rangle = \sum_{i=1}^8 y_i = 0.5 + 0.6 + 0.9 + 0.8 + 1.2 + 1.5 + 1.7 + 2 = 9.2$$

$$\langle \mathbf{x}, \mathbf{y} \rangle = \sum_{i=1}^8 x_i y_i = 1 \times 0.5 + 2 \times 0.6 + 3 \times 0.9 + 4 \times 0.8 + 5 \times 1.2 + 6 \times 1.5 + 7 \times 1.7 + 8 \times 2 = 50.5$$

Portanto, na forma matricial:

$$\begin{pmatrix} 8 & 36 \\ 36 & 204 \end{pmatrix} \begin{pmatrix} a_0 \\ a_1 \end{pmatrix} = \begin{pmatrix} 9.2 \\ 50.5 \end{pmatrix}$$

Usando a solução deduzida para o sistema 2×2 temos:

$$a_0 = \frac{9.2 \times 204 - 36 \times 50.5}{8 \times 204 - 36^2} = \frac{58.8}{336} = 0.175,$$

$$a_1 = \frac{8 \times 50.5 - 9.2 \times 36}{8 \times 204 - 36^2} = \frac{72.8}{336} = 0.216667.$$

Logo a reta que melhor aproxima a tabela de dados é $g(x) = 0.175 + 0.216667x$.

Exercício: Refaça o exemplo ajustando a tabela com $g(x) = a_0 + a_1x + a_2x^2$.

5.2.2 Caso geral

Agora vamos considerar a função aproximadora:

$$g(x) = \sum_{k=0}^m a_k g_k(x),$$

linear nos parâmetros.

Para o caso discreto, queremos determinar $a_0, a_1, \dots, a_m$ que minimizam o resíduo

$$r(\mathbf{a}) = \sum_{i=1}^n [f(x_i) - g(x_i, \mathbf{a})]^2 = \sum_{i=1}^n [f(x_i) - a_0 g_0(x_i) - a_1 g_1(x_i) - \dots - a_m g_m(x_i)]^2$$

Para isso é necessário derivar r em relação a cada um dos parâmetros a_k e igualar a expressão a zero. Assim, teremos,

$$\frac{\partial r}{\partial a_k} = 2 \sum_{i=1}^n [f(x_i) - a_0 g_0(x_i) - \dots - a_m g_m(x_i)] [-g_k(x_i)] = 0, \text{ com } k = 0, 1, \dots, m. \quad (5.7)$$

Reescrevendo (5.7) obtemos

$$a_0 \sum_{i=1}^n g_0(x_i) g_k(x_i) + \dots + a_m \sum_{i=1}^n g_m(x_i) g_k(x_i) = \sum_{i=1}^n f(x_i) g_k(x_i), k = 0, 1, \dots, m. \quad (5.8)$$

Assim temos $m + 1$ equações com $m + 1$ incógnitas a_k . O sistema normal na forma matricial é dado por:

$$\begin{pmatrix} \langle g_0, g_0 \rangle & \langle g_0, g_1 \rangle & \dots & \langle g_0, g_m \rangle \\ \langle g_1, g_0 \rangle & \langle g_1, g_1 \rangle & \dots & \langle g_1, g_m \rangle \\ \vdots & \vdots & \ddots & \vdots \\ \langle g_m, g_0 \rangle & \langle g_m, g_1 \rangle & \dots & \langle g_m, g_m \rangle \end{pmatrix} \begin{pmatrix} a_0 \\ a_1 \\ \vdots \\ a_m \end{pmatrix} = \begin{pmatrix} \langle g_0, f \rangle \\ \langle g_1, f \rangle \\ \vdots \\ \langle g_m, f \rangle \end{pmatrix}$$

Note que a matriz é simétrica, ou seja, $a_{ij} = a_{ji}$.

Exemplo 31 Observando um sinal no osciloscópio verifica-se que ele corresponde a superposição de dois efeitos, um oscilatório e outro crescente. Aproxime os dados da tabela por uma função $g(x) = a_0x + a_1 \cos(x)$.

x	0	1.5	3	4.5	6
y	1	1.57	2	4.3	7

Solução: Temos $g_0(x) = x$ e $g_1(x) = \cos(x)$. Assim,

$$\langle \mathbf{x}, \mathbf{x} \rangle = \sum_{i=1}^5 x_i^2 = 0^2 + 1.5^2 + 3^2 + 4.5^2 + 6^2 = 67.5$$

$$\langle \mathbf{x}, \cos(\mathbf{x}) \rangle = \sum_{i=1}^5 x_i \cos(x_i) = 0 \times \cos(0) + 1.5 \times \cos(1.5) + 3 \cos(3) + 4.5 \cos(4.5) + 6 \cos(6) = 1.94857$$

$$\langle \cos(\mathbf{x}), \cos(\mathbf{x}) \rangle = \sum_{i=1}^5 \cos(x_i)^2 = \cos^2(0) + \cos^2(1.5) + \cos^2(3) + \cos^2(4.5) + \cos^2(6) = 2.95145$$

$$\langle \mathbf{x}, \mathbf{y} \rangle = \sum_{i=1}^5 x_i y_i = 0 \times 1 + 1.5 \times 1.57 + 3 \times 2 + 4.5 \times 4.3 + 6 \times 7 = 69.705$$

$$\langle \cos(\mathbf{x}), \mathbf{y} \rangle = \sum_{i=1}^5 \cos(x_i) y_i = \cos(0) \times 1 + \cos(1.5) \times 1.57 + \cos(3) \times 2 + \cos(4.5) \times 4.3 + \cos(6) \times 7 = 4.94584$$

Portanto, na forma matricial:

$$\begin{pmatrix} 67.5 & 1.94857 \\ 1.94857 & 2.95145 \end{pmatrix} \begin{pmatrix} a_0 \\ a_1 \end{pmatrix} = \begin{pmatrix} 69.705 \\ 4.94584 \end{pmatrix} \implies \begin{matrix} a_0 = 1.0034159 \\ a_1 = 1.01327032 \end{matrix}$$

Portanto, $g(x) = 1.0034159x + 1.01327032 \cos(x)$.

5.2.3 Domínio Contínuo

No caso contínuo, o problema de ajuste de curvas consiste em: dada uma função $f(x)$ contínua em um intervalo $[a, b]$ e escolhidas as funções $g_0(x), g_1(x), \dots, g_n(x)$ todas contínuas em $[a, b]$, queremos determinar $a_0, a_1, \dots, a_n$ tais que a função $g(x) = \sum_{k=0}^n a_k g_k(x)$ seja a melhor aproximação de $f(x)$ no intervalo $[a, b]$.

Determinar a **melhor aproximação**, como no caso discreto, significa minimizar a função resíduo dada por,

$$r(\mathbf{a}) = \int_a^b [f(x) - \sum_{k=0}^n a_k g_k(x)]^2 dx.$$

No caso discreto, o resíduo era definido com uma soma finita, já o caso contínuo a definição do resíduo é feita por meio de uma integral em $[a, b]$. Para facilitar a notação, é comum utilizar a notação de produto escalar de duas funções.

1. Caso discreto $\langle f, g \rangle = \sum_{i=0}^m f(x_i)g(x_i)$.
2. Caso contínuo $\langle f, g \rangle = \int_a^b f(x)g(x)dx$.

Importante, lembrar que o produto escalar entre funções satisfaz as propriedades:

1. Linearidade: $\langle ag_1 + a_2g_2, f \rangle = a_1 \langle g_1, f \rangle + a_2 \langle g_2, f \rangle$.
2. Comutatividade: $\langle f, g \rangle = \langle g, f \rangle$.
3. Não negatividade: $\langle g, g \rangle \geq 0$ e $\langle g, g \rangle = 0 \Leftrightarrow g \equiv 0$.

Exercício: Verifique estas propriedades para os produtos escalares definidos para o caso discreto e para o caso contínuo.

Como fizemos para o caso discreto, queremos determinar os parâmetros $a_0, a_1, \dots, a_n$ que minimizam o resíduo, ou seja, $\frac{\partial r}{\partial a_j} = 0$, com $j = 0, 1, \dots, n$. Assim, para cada j temos uma equação da forma,

$$\int_a^b 2[f(x) - \sum_{k=0}^n a_k g_k(x)]g_j(x)dx = 0, \text{ com } j = 0, \dots, n.$$

Pelas propriedades de produto escalar, temos

$$\int_a^b f(x)g_j(x)dx - \sum_{k=0}^n a_k \int_a^b g_k(x)g_j(x)dx = 0,$$

que implica em,

$$a_0 \int_a^b g_0(x)g_j(x)dx + a_1 \int_a^b g_1(x)g_j(x)dx + \dots + a_n \int_a^b g_n(x)g_j(x)dx = \int_a^b f(x)g_j(x)dx.$$

Dessa forma obtemos o sistema normal,

$$\begin{pmatrix} \langle g_0, g_0 \rangle & \langle g_1, g_0 \rangle & \dots & \langle g_n, g_0 \rangle \\ \langle g_0, g_1 \rangle & \langle g_1, g_1 \rangle & \dots & \langle g_n, g_1 \rangle \\ \vdots & & \ddots & \vdots \\ \langle g_0, g_n \rangle & \langle g_1, g_n \rangle & \dots & \langle g_n, g_n \rangle \end{pmatrix} \begin{pmatrix} a_0 \\ a_1 \\ \vdots \\ a_n \end{pmatrix} = \begin{pmatrix} \langle f, g_0 \rangle \\ \langle f, g_1 \rangle \\ \vdots \\ \langle f, g_n \rangle \end{pmatrix},$$

sendo $\langle g, f \rangle = \int_a^b g(x)f(x)dx$.

Exemplo 32 Queremos substituir a função $f(x) = \sin\left(\frac{\pi}{4}x\right)$ por um polinômio de grau 3, no intervalo $[0, 1]$.

Solução.

Como a função $\sin\left(\frac{\pi}{4}x\right)$ é uma função ímpar, ou seja, $f(-x) = -f(x)$, vamos escolher um polinômio ímpar para o ajuste, $g(x) = a_0x + a_1x^3$. Isso significa, que $g_0(x) = x$ e $g_1(x) = x^3$. Assim, precisamos minimizar a função

$$r(a_0, a_1) = \int_0^1 \left(\sin \frac{\pi}{4}x - a_0x - a_1x^3\right)^2 dx.$$

Assim, o sistema normal é dado por,

$$\begin{pmatrix} \int_0^1 x^2 dx & \int_0^1 x^4 dx \\ \int_0^1 x^4 dx & \int_0^1 x^6 dx \end{pmatrix} \begin{pmatrix} a_0 \\ a_1 \end{pmatrix} = \begin{pmatrix} \int_0^1 x \sin(\frac{\pi}{4}x) dx \\ \int_0^1 x^3 \sin(\frac{\pi}{4}x) dx \end{pmatrix},$$

Calculando as integrais (algumas por partes: $\int u dv = uv - \int v du$) obtemos:

$$\begin{aligned} \int_0^1 x \sin(\frac{\pi}{4}x) dx &= -x \frac{4}{\pi} \cos(\frac{\pi}{4}x) \Big|_0^1 + \frac{4}{\pi} \int_0^1 \cos(\frac{\pi}{4}x) dx \\ &= -\frac{4}{\pi} \cos(\frac{\pi}{4}) + \frac{16}{\pi^2} \sin(\frac{\pi}{4}) \\ &\approx 0.2460020203444062 \end{aligned}$$

$$\begin{aligned} \int_0^1 x^3 \sin(\frac{\pi}{4}x) dx &= -x^3 \frac{4}{\pi} \cos(\frac{\pi}{4}x) \Big|_0^1 + \frac{12}{\pi} \int_0^1 x^2 \cos(\frac{\pi}{4}x) dx \\ &= -\frac{4}{\pi} \cos(\frac{\pi}{4}) + \frac{12}{\pi} \left[\frac{4}{\pi} x^2 \sin(\frac{\pi}{4}x) \Big|_0^1 - \frac{8}{\pi} \int_0^1 x \sin(\frac{\pi}{4}x) dx \right] \\ &\approx 0.14581796889606857 \end{aligned}$$

$$\int_0^1 x^2 dx = \frac{x^3}{3} \Big|_0^1 = \frac{1}{3}$$

$$\int_0^1 x^4 dx = \frac{x^5}{5} \Big|_0^1 = \frac{1}{5}$$

$$\int_0^1 x^6 dx = \frac{x^7}{7} \Big|_0^1 = \frac{1}{7}$$

Assim,

$$\begin{pmatrix} \frac{1}{3} & \frac{1}{5} \\ \frac{1}{5} & \frac{1}{7} \end{pmatrix} \begin{pmatrix} a_0 \\ a_1 \end{pmatrix} = \begin{pmatrix} 0.2460020203444062 \\ 0.14581796889606857 \end{pmatrix}$$

cuja solução é $a_0 = 0.7848162$ e $a_1 = -0.07801689$. Portanto, a função aproximadora é $g(x) = 0.7848162x - 0.07801689x^3$.

5.2.4 Mínimos quadrados com peso

A formulação do Método dos Mínimos Quadrados (MMQ) usando a definição de produto escalar de funções nos permite:

- Atribuir diferentes graus de importância no intervalo de aproximação. Isso é feito quando incluímos uma função peso, $w(x)$ no produto escalar,

1. Discreto: $\langle f, g \rangle = \sum_{i=1}^m w(x_i) f(x_i) g(x_i),$
2. Contínuo: $\langle f, g \rangle = \int_a^b w(x) f(x) g(x) dx,$

sendo $w(x)$ uma função contínua e $w(x) > 0$ em $[a, b]$.

Exemplo 33 A tabela a seguir apresenta os preços R_i de um ativo financeiro nos últimos seis meses $t_i = i$, com $i = 1, 2, \dots, 6$.

t_i	1	2	3	4	5	6
R_i	21.3	21.8	21.2	21.3	20.5	21.5

Deseja-se estimar o comportamento dos preços segundo uma função linear $R(t) = a_0 + a_1 t$. Entretanto, será dado um peso maior aos meses mais recentes por meio de $w = (0.5, 0.6, 0.7, 0.8, 0.9, 1)$.

(a) Apresente o sistema linear obtido pelo MMQ.

(b) Faça uma estimativa do valor para o sétimo mês.

5.2.5 Funções Ortogonais

O conceito de ortogonalidade em um conjunto de funções, se origina do conceito de ortogonalidade entre vetores, caracterizado pelo produto escalar nulo.

Uma família de funções, $g_i(x)$, com $i = 0, 1, \dots$ é ortogonal em relação ao produto escalar associado ao peso $w(x)$, se $\langle g_i, g_j \rangle = 0$ para todo $i \neq j$.

Se as funções $g_i(x)$ que compõem a função aproximadora $g(x) = \sum_{k=0}^n g_k(x)$ são ortogonais, o sistema normal se torna diagonal. Ou seja, apenas a diagonal da matriz é não nula. Portanto, a solução do sistema resulta em

$$a_j = \frac{\langle f, g_j \rangle}{\langle g_j, g_j \rangle}, j = 0, 1, \dots, n.$$

Exemplos de famílias de funções ortogonais:

- As funções trigonométricas, que dão origem à série de Fourier (Análise Harmônica).
- Os polinômios ortogonais: polinômios de Legendre, Chebyshev, entre outros, que cada vez mais aparecem em problemas que envolvem aproximações.

Polinômios de Legendre: são ortogonais em $(-1, 1)$ com a função peso $w(x) = 1$. Os seis primeiros polinômios são:

$$\begin{aligned} p_0(x) &= 1 & p_3(x) &= x^3 - \frac{3}{5}x \\ p_1(x) &= x & p_4(x) &= x^4 - \frac{6}{7}x^2 + \frac{3}{35} \\ p_2(x) &= x^2 - \frac{1}{3} & p_5(x) &= x^5 - \frac{10}{9}x^3 + \frac{5}{21}x \end{aligned}$$

Polinômios de Chebyshev: são ortogonais em $(-1, 1)$ com a função peso $w(x) = (1 - x^2)^{-\frac{1}{2}}$. Os cinco primeiros polinômios são:

$$\begin{aligned} p_0(x) &= 1 & p_3(x) &= 4x^3 - 3x \\ p_1(x) &= x & p_4(x) &= 8x^4 - 8x^2 + 1 \\ p_2(x) &= 2x^2 - 1 \end{aligned}$$

Atenção ao intervalo em que os polinômios são ortogonais. Pode ser necessário fazer uma mudança de variável: $x \in [a, b]$ para $t \in [-1, 1]$,

$$x = \frac{(b-a)t + (a+b)}{2}.$$

Análise Harmônica

Família de funções trigonométricas: $\{1, \cos(x), \sin(x), \cos(2x), \sin(2x), \dots, \cos(nx), \sin(nx)\}$ que são ortogonais em um intervalo de tamanho 2π .

Função aproximadora: $g(x) = a_0 + \sum_{k=1}^n [a_k \cos(kx) + b_k \sin(kx)]$

Exemplo 34 Aproximar $f(x) = \begin{cases} 1, & 0 \leq x \leq \pi \\ -1, & \pi < x \leq 2\pi \end{cases}$ função periódica, $f(x+2\pi) = f(x)$, via método dos mínimos quadrados, com $g(x) = a_0 + \sum_{k=1}^3 [a_k \cos(kx) + b_k \sin(kx)]$.

5.2.6 Mínimos Quadrados não lineares

As funções usadas na aproximação são não lineares nos parâmetros. Por exemplo, funções racionais, hiperbólicas, exponenciais, como,

$$g(x) = a_1 \exp\left(-\frac{(a_2 - x)^2}{a_3}\right) + a_4 \exp\left(-\frac{(a_5 - x)^2}{a_6}\right).$$

A ideia continua a mesma, minimizar a soma dos quadrados dos resíduos. A diferença é que podemos ter dois caminhos:

- Se for possível, podemos linearizar a função aproximadora, resolver o problema linear e depois retornar aos parâmetros originais.
- Resolver um sistema não linear, obtido a partir do problema de minimizar a função resíduo.

Exemplo 35 Como fazer para aproximar uma função tabelada (x_i, y_i) , com $i = 1, \dots, n$, por uma função $g(x) = a_0 \exp(-a_1 x)$?

Solução: Note que aplicando $\ln$ em ambos os lados, $g(x) = a_0 \exp(-a_1 x) \implies \ln(g(x)) = \ln(a_0) - a_1 x$. Fazendo $\alpha_0 = \ln(a_0)$ e $\alpha_1 = -a_1$ temos um problema linear, um ajuste por uma reta, $\ln(y) \approx \alpha_0 + \alpha_1 x$. Obtidos α_0 e α_1 usamos a transformação para obter a_0 e a_1 .

A seguir um exemplo, de MMQ não linear com a resolução de um sistema não linear. Nosso objetivo, obter os parâmetros por meio do método dos mínimos quadrados, que minimizam a função,

$$r(\mathbf{a}) = \frac{1}{2} \sum_{i=1}^m r_i(\mathbf{a})^2,$$

sendo $\mathbf{a} = (a_0, a_1, \dots, a_m)$, o resíduo $r_i(\mathbf{a}) = f(x_i, \mathbf{a}) - y_i$, com (x_i, y_i) dados e m tamanho dos vetores x e y . O nosso objetivo é determinar $\mathbf{a}$ tal que o valor da função resíduo seja mínimo.

Algoritmo de Gauss-Newton:

Nesse método assume-se que $\mathbf{a}^k$ está próximo do mínimo e portanto, o resíduo $r_i(\mathbf{a})$ está próximo de zero. Para simplificar, vamos apresentar a dedução para uma função com dois parâmetros. Vamos aproximar a função resíduo $r(a_0, a_1)$ utilizando os três primeiros termos da série de Taylor. Os três primeiros termos da série em torno de (a_0, a_1) com incremento (p_0, p_1) são dados por:

$$r(a_0 + p_0, a_1 + p_1) \approx r(a_0, a_1) + p_0 \frac{\partial r}{\partial a_0}(a_0, a_1) + p_1 \frac{\partial r}{\partial a_1}(a_0, a_1) + \frac{1}{2} \left(p_0^2 \frac{\partial^2 r}{\partial a_0^2}(a_0, a_1) + 2p_0 p_1 \frac{\partial^2 r}{\partial a_0 \partial a_1}(a_0, a_1) + p_1^2 \frac{\partial^2 r}{\partial a_1^2}(a_0, a_1) \right).$$

As derivadas parciais em relação a a_0 e a_1 geram a matriz Jacobiana:

$$J = \begin{pmatrix} \frac{\partial r_1}{\partial a_0} & \frac{\partial r_1}{\partial a_1} \\ \frac{\partial r_2}{\partial a_0} & \frac{\partial r_2}{\partial a_1} \\ \vdots & \vdots \\ \frac{\partial r_n}{\partial a_0} & \frac{\partial r_n}{\partial a_1} \end{pmatrix}$$

Para obter os parâmetros a_0 e a_1 que minimizam $r(a_0, a_1)$ precisamos derivar e igualar a zero, obtendo:

$$\frac{\partial r}{\partial a_k} = \sum_{i=1}^n \frac{\partial r_i}{\partial a_k} \cdot r_i$$

Note que,

$$p_0 \frac{\partial r}{\partial a_0}(a_0, a_1) + p_1 \frac{\partial r}{\partial a_1}(a_0, a_1) = p^T J^T r(a)$$

Já os termos de associados as derivadas de segunda ordem são representados por,

$$\frac{\partial^2 r}{\partial a_k^2} = \sum_{i=1}^n \frac{\partial r_i}{\partial a_k} \cdot \frac{\partial r_i}{\partial a_k} + \sum_{i=1}^n r_i \frac{\partial^2 r_i}{\partial a_k^2}.$$

Assim,

$$r(\mathbf{a} + \mathbf{p}) = r(\mathbf{a}) + \mathbf{p}^T J^T r(\mathbf{a}) + \frac{1}{2} \mathbf{p}^T (J^T J + Q) \mathbf{p}.$$

No processo de minimizar r queremos determinar o incremento $\mathbf{p}$ que diminua a soma dos resíduos. Ou seja, $r(\mathbf{a} + \mathbf{p}) < r(\mathbf{a})$. No método de Gauss-Newton, admitimos que $\mathbf{a}^k$ está próximo do mínimo e portanto $r(\mathbf{a})$ está próximo de zero. Com esta hipótese é razoável argumentar que a matriz Q que contém as derivadas de segunda ordem pode ser desprezada. Nestas condições a cada iteração:

1. Avaliamos J e r .
2. Resolvemos $J^T J \mathbf{p} = -J^T r$
3. $\mathbf{a}^{k+1} = \mathbf{a}^k + \mathbf{p}$

Para mais detalhes veja [6] e [3]. A seguir apresentamos o Algoritmo de Gauss-Newton.

Algoritmo 15: Método de Gauss-Newton

Entrada: $r_i(\mathbf{a})$, J e $\mathbf{a}^0$.

$itmax = 100$

$tol = 10^{-6}$

$it = 1$

$diff = 1$

enquanto $diff > tol$ e $it < itmax$ **faça**

Calcule $r \leftarrow r(a^0)$

Calcule $J \leftarrow J(a^0)$

Calcule $(J^T)J$ e $(J^T)r$

Resolva o sistema $(J^T)Jp = -(J^T)r$

$a \leftarrow a^0 + p$

$diff \leftarrow max \mathbf{a}$

$a^0 \leftarrow a$

$it \leftarrow it + 1$

Saída: $\mathbf{a}$

Outra alternativa é o método de Levenberg-Marquardt onde a minimização da soma dos resíduos se baseia na solução do sistema:

$$(J_k^T J_k + \lambda_k I) p_k = -J_k^T r_k,$$

onde J^T é a transposta da matriz Jacobiana e I é a matriz identidade. Um dos métodos utilizado em `least_squares` do módulo `scipy`. https://docs.scipy.org/doc/scipy/reference/generated/scipy.optimize.least_squares.html

Exemplo 36 Uma população de bactérias foi medida ao longo das 6 primeiras horas de um dia.

t	0	1	2	3	4	5	6
$p(t)$	32	47	65	92	132	190	275

Utilize a função $g(x) = a_0 e^{a_1 x}$ para aproximar os dados pelo Método dos Mínimos Quadrados.

Exemplo 37 Para o ajuste da curva de polarização por meio da função não linear é necessário obter os parâmetros $\mathbf{a}$ da função,

$$f(x, \mathbf{a}) = a_0 - a_1 x - a_2 \ln\left(\frac{x}{a_3} + 1\right) - a_4 \exp(a_5 x).$$

Utilize esta função aproximadora para aproximar os dados de corrente e voltagem da tabela:

i	0	$4.75 \cdot 10^{-4}$	$8.27 \cdot 10^{-4}$	$1.69 \cdot 10^{-3}$	$2.5 \cdot 10^{-3}$	$3.01 \cdot 10^{-3}$	$3.19 \cdot 10^{-3}$	$3.86 \cdot 10^{-3}$
V	0.6795	0.4862	0.423	0.33975	0.25075	0.2062	0.1629	0.07715

5.3 Exercícios

- Determina os polinômios de grau 1, 2 e 3 que melhor ajustam a tabela abaixo, no sentido dos quadrados mínimos. Qual deles fornece o menor resíduo?

x	0	0.15	0.31	0.5	0.6	0.75
y	1	1.004	1.031	1.117	1.223	1.422

- Considere os seguintes dados tabelados:

x	-2	-1	0	1	2
y	6	3	-1	-2	-4

- Determine a e b tais que $y \approx ax + b$ pelo método dos Mínimos Quadrados.
 - Determine c e d tais que $x \approx cy + d$ pelo método dos Mínimos Quadrados.
 - Qual relação você esperaria entre os valores a, b, c e d ? Essa relação ocorre? Justifique.
- Um professor organizou uma tabela com dados de estudantes, relacionando horas semanais de estudo extra-classe e notas. Nessa tabela ele incluiu pesos e os dados são apresentados a seguir,

Estudantes	Horas	Notas	Peso
<i>A</i>	5	7.5	1
<i>B</i>	10	8.5	2
<i>C</i>	4	7	1
<i>D</i>	3	6.5	0.5
<i>E</i>	12	9.5	2
<i>F</i>	8	8	1.5
<i>G</i>	6	8	1.5

Obtenha a reta que melhor aproxima os dados, usando o método dos mínimos quadrados com peso.

4. Verifique que as funções não lineares a seguir podem ser linearizadas por transformações matemáticas. Explícite a relação entre a função original e a linearizada.

(a) $f(x) = \frac{a_1}{a_2x + a_3};$

(c) $f(x) = \ln(a_1 + a_2x^2);$

(b) $f(x) = 1 + \frac{a_1}{x^2 + a_2};$

(d) $f(x) = \frac{100}{1 + a_1e^{-a_2x}}.$

5. A tabela

r	2.7	2	1.61	1.2	1.02
θ	48°	67°	83°	108°	126°

foi gerada a partir de posições de um cometa em coordenadas polares convenientes. Sabendo-se que a órbita do cometa é descrita pela lei de Kepler

$$r = \frac{p}{1 - q \cos(\theta)},$$

estime p e q usando o método dos mínimos quadrados:

- (a) a partir do problema linearizado;

- (b) apresente os passos de uma iteração do método de Gauss-Newton para esse problema.

6. O número de bactérias por unidade de volume, existente em uma cultura após x horas é apresentado na tabela:

x (horas)	1	2	3	4	5	6
y (n° de bactérias/volume)	47	65	92	132	190	275

- (a) Obtenha uma linearização para a função aproximadora $g(x) = ab^x$.

- (b) Ajuste os dados da tabela $y \approx g(x)$ usando a linearização do item anterior.

7. Dados os polinômios de Legendre: $p_0(x) = 1$, $p_1(x) = x$ e $p_2(x) = \frac{1}{2}(3x^2 - 1)$ que obedecem a seguinte definição:

$$\langle p_i, p_j \rangle = \int_{-1}^1 p_i(x)p_j(x)dx = \begin{cases} 0, & i \neq j \\ \frac{2}{2i+1}, & i = j \end{cases}$$

- (a) Determine o polinômio de grau dois, usando os polinômios de Legendre, que melhor aproxima $f(x) = x^3 - 1$, no intervalo $[-1, 1]$.
- (b) Determine o polinômio de grau dois que melhor aproxima $f(x) = \sin(x)$ no intervalo $[0, \pi]$. Note que será necessária uma mudança de variáveis para a utilização dos polinômios de Legendre.

8. Aproxime a função

$$f(x) = \begin{cases} \frac{x}{\pi}, & 0 \leq x \leq \pi \\ -\frac{x}{\pi} + 2, & \pi < x \leq 2\pi \end{cases}$$

usando o método dos mínimos quadrados, usando o produto escalar

$$\langle f, g \rangle = \int_0^{2\pi} f(x)g(x)dx,$$

e as funções aproximadoras:

- (a) $g(x) = a_0 + a_1x + a_2x^2$; e
- (b) $h(x) = a_0 + a_1 \sin(x) + a_2 \cos(x)$.

9. Considere a função tabelada abaixo:

x	0	0.5	1	2.5	3
y	2	2.6	3.7	13.21	21

- (a) Obtenha uma linearização para a função aproximadora $g(x) = 1 + a \exp(bx)$.
- (b) Apresente o sistema normal (sistema linear) do problema linearizado.

5.4 Interpolação polinomial

5.5 Exercícios

REFERÊNCIAS

- [1] Burden, R.L., Faires, D.J., Burden, A.M.: Análise Numérica, vol. Tradução da 10ed, 3ed. São Paulo. Cengage Learning (2015)
- [2] de Castro Humes, A.F.P., de Melo, I.S.H., Yoshida, L.K., Martins, W.T.: Noções de cálculo numérico (1984)
- [3] Cunha, M.C.C.: Métodos Numéricos, vol. 2ed, Campinas - S. P. Unicamp (2000)
- [4] Morimoto, C.H., Hashimoto, R.F.: Introdução a Ciência da Computação em C. Instituto de Matemática e Estatística, USP, <https://www.ime.usp.br/~hitoshi/introducao/>
- [5] Morimoto, C.H., de Pinha Jr, J.C.: Introdução à Computação com Python: um curso interativo. Instituto de Matemática e Estatística, USP, <https://panda.ime.usp.br/cc110/static/cc110/index.html>
- [6] Peters, S., Szeremeta, J.: Cálculo numérico computacional (2017)
- [7] Szwarcfiter, J.L., Markezon, L.: Estruturas de Dados e seus Algoritmos. LCT, 3 edn. (2010)

APPENDIX A

PROGRAMAS