

UNIDADE 5

APROXIMAÇÃO DE FUNÇÕES E DADOS TABELADOS

Nesta unidade vamos estudar métodos numéricos para aproximar funções e para aproximar dados tabelados. O problema de aproximar funções é denominado problema contínuo. Dada $f(x)$ com $x \in [a, b]$, queremos obter uma função aproximada $g(x)$ para $f(x)$. O problema de aproximar dados tabelados é denominado problema discreto. Dada uma tabela (x_i, y_i) , com $i = 1, \dots, m$, queremos determinar uma função aproximadora $g(x)$ que aproxime a tabela de dados. Veremos duas maneiras de fazer estas aproximações:

1. Método dos Mínimos Quadrados (MMQ): nosso objetivo é minimizar o resíduo entre os dados e uma função aproximadora.
2. Interpolação Polinomial: nesse caso exigimos que o polinômio aproximador "passe" pelos dados a serem aproximados.

5.1 Motivação

A seguir serão apresentados dois problemas de motivação que envolvem tabelas de dados medidos experimentalmente. Nos dois problemas queremos aproximar uma função $f(x)$ por outra função $g(x)$ previamente escolhida, satisfazendo algumas propriedades. A função $g(x)$ substitui $f(x)$ e é usada para estimar valores para determinados x . Quando é necessário aproximar?

- quando são apenas os valores de uma função para um conjunto de pontos e precisamos avaliar f em um ponto não tabelado.
- quando a função em estudo tem uma expressão tal que as operações de diferenciação e integração são difíceis de serem realizadas.

Problema 1:

A seguinte tabela relaciona o calor específico da água e temperatura:

Temperatura ($^{\circ}\text{C}$)	20	25	30	35	40	45	50
Calor específico	0.99907	0.99852	0.99826	0.99818	0.99828	0.99849	0.99878

Suponha que você queira estimar o calor específico da água a 32.5°C . A aproximação de dados via interpolação polinomial ou Método dos Mínimos quadrados lhe ajudará na resolução deste problema.

Problema 2:

Em um artigo tratando da eficiência da utilização de energia das larvas de mariposa, utilizou-se os seguintes dados para determinar a relação entre W , o peso das larvas vivas em gramas e R o consumo de oxigênio das larvas em mililitros por hora. Por razões biológicas existe uma relação entre R e W dada por $R = bW^a$, onde a e b são parâmetros desconhecidos [1].

Como determinar os parâmetros a e b ? Com base nos dados:

W	R	W	R	W	R	W	R
0.017	0.154	0.025	0.23	0.020	0.181	0.025	0.234
0.087	0.296	0.111	0.357	0.085	0.260	0.119	0.299
0.174	0.363	0.212	0.366	0.171	0.334	0.783	1.47
1.11	0.531	0.999	0.771	1.29	0.87	1.32	1.15
1.35	2.48	1.74	2.23	3.02	2.01	3.04	3.59

5.2 Método dos Mínimos Quadrados

O objetivo deste método é minimizar o erro cometido.

Problema: Dada uma tabela de dados (x_i, y_i) com $i = 1, 2, \dots, N$ ou uma função $f(x)$, com $x \in [a, b]$, queremos obter uma função aproximadora $g(x)$ que aproxima y_i ou $f(x)$.

Vamos tratar dois casos:

- **Domínio discreto:** quando a função é tabelada. Temos como dados de entrada N pontos (x_i, y_i) .
- **Domínio Contínuo:** quando $f(x)$ está definida em um intervalo $[a, b]$.

Exemplos:

- Queremos extrair informação de um conjunto de dados de censos demográficos. Como estimar a população em um ano em que não ocorreu o censo?

De forma geral, uma função aproximadora $g(x)$ pode ser escrita como uma combinação linear de uma família de funções,

$$g(x) = \sum_{k=0}^m a_k g_k(x),$$

onde $\{g_k(x)\}$ é uma família de funções previamente escolhida e os parâmetros a_k serão determinados.

Por exemplo, se $g(x)$ é uma função quadrática, temos

$$g(x) = a_0 + a_1x + a_2x^2,$$

sendo a família de funções $\{1, x, x^2\}$, ou seja, $g_0(x) = 1$, $g_1(x) = x$ e $g_2(x) = x^2$.

A escolha da família de funções deve levar em consideração:

- Características da função aproximadora. Por exemplo, polinômios são facilmente avaliados integráveis, diferenciáveis e operações com polinômios resultam em polinômios.
- O comportamento da função a ser aproximada. Por exemplo, o crescimento e a periodicidade.

Para a dedução do MMQ, vamos considerar $g(x) = a_0 + a_1x$ (uma reta), problema conhecido como **Regressão Linear**. Depois, vamos generalizar para uma função aproximadora, linear nos parâmetros, dada por,

$$g(x) = \sum_{k=0}^m a_k g_k(x).$$

Para aproximar uma função tabelada (x_i, y_i) com $i = 1, 2, \dots, N$, a função resíduo é definida por

$$r(\mathbf{a}) = \sum_{i=1}^N [f(x_i) - g(x_i, \mathbf{a})]^2,$$

onde f é a função aproximada e g é a função aproximadora, $g(x, \mathbf{a}) = \sum_{k=0}^m a_k g_k(x)$, com $\mathbf{a} = (a_0, a_1, \dots, a_m)$.

O nosso objetivo é minimizar a função resíduo $r(\mathbf{a})$.

Ou seja, determinar os parâmetros $\mathbf{a}$ que forneçam o valor $r(\mathbf{a})$ mínimo.

5.2.1 Regressão linear

Considere $g(x) = a_0 + a_1x$ a função aproximadora e a função tabelada

x	x_1	x_2	$\dots$	x_N
y	y_1	y_2	$\dots$	y_N

Queremos obter os parâmetros a_0 e a_1 que minimizam a função: $r(a_0, a_1) = \sum_{i=1}^N [y_i - (a_0 + a_1x_i)]^2$.

Para obtermos o mínimo de $r(a_0, a_1)$ é necessário que: $\frac{\partial r}{\partial a_0} = 0$ e $\frac{\partial r}{\partial a_1} = 0$.

Derivando a função resíduo (regra da cadeia) e igualando a zero obtemos:

$$\frac{\partial r}{\partial a_0} = 2 \sum_{i=1}^N (y_i - a_0 - a_1x_i)(-1) = 0, \quad (5.1)$$

$$\frac{\partial r}{\partial a_1} = 2 \sum_{i=1}^N (y_i - a_0 - a_1x_i)(-x_i) = 0. \quad (5.2)$$

Obs.: Note que a função $r(a_0, a_1)$ é convexa (“com concavidade voltada para cima”), garantindo que o ponto crítico $(\tilde{a}_0, \tilde{a}_1)$ é um ponto de mínimo. Para mais detalhes veja [2].

Reescrevendo (5.1) e (5.2) obtemos um sistema linear com duas equações e duas incógnitas a_0 e a_1 ,

$$\left(\sum_{i=1}^N 1 \right) a_0 + \left(\sum_{i=1}^N x_i \right) a_1 = \sum_{i=1}^N y_i, \quad (5.3)$$

$$\left(\sum_{i=1}^N x_i \right) a_0 + \left(\sum_{i=1}^N x_i^2 \right) a_1 = \sum_{i=1}^N x_i y_i. \quad (5.4)$$

Na notação matricial,

$$\begin{pmatrix} \sum_{i=1}^N 1 & \sum_{i=1}^N x_i \\ \sum_{i=1}^N x_i & \sum_{i=1}^N x_i^2 \end{pmatrix} \begin{pmatrix} a_0 \\ a_1 \end{pmatrix} = \begin{pmatrix} \sum_{i=1}^N y_i \\ \sum_{i=1}^N x_i y_i \end{pmatrix}$$

Este sistema é chamado **sistema normal**. Note que a matriz é simétrica.

Para facilitar a generalização do problema para o caso contínuo, vamos usar a notação de produto escalar (ou produto interno).

Considere $\mathbf{1}, \mathbf{x}$ e $\mathbf{y} \in \mathbb{R}^N$, ou seja, $\mathbf{1} = (1, 1, \dots, 1)$, $\mathbf{x} = (x_1, x_2, \dots, x_N)$ e $\mathbf{y} = (y_1, y_2, \dots, y_N)$. O produto escalar de dois vetores é dado por,

$$\langle \mathbf{x}, \mathbf{y} \rangle = x_1y_1 + x_2y_2 + \dots + x_Ny_N = \sum_{i=1}^N x_iy_i.$$

Assim, podemos reescrever:

$$\sum_{i=1}^N 1 = \langle \mathbf{1}, \mathbf{1} \rangle, \sum_{i=1}^N x_i = \langle \mathbf{1}, \mathbf{x} \rangle = \langle \mathbf{x}, \mathbf{1} \rangle, \sum_{i=1}^N x_i^2 = \langle \mathbf{x}, \mathbf{x} \rangle \text{ e } \sum_{i=1}^N y_i = \langle \mathbf{1}, \mathbf{y} \rangle.$$

O sistema normal se torna:

$$\begin{pmatrix} \langle \mathbf{1}, \mathbf{1} \rangle & \langle \mathbf{1}, \mathbf{x} \rangle \\ \langle \mathbf{x}, \mathbf{1} \rangle & \langle \mathbf{x}, \mathbf{x} \rangle \end{pmatrix} \begin{pmatrix} a_0 \\ a_1 \end{pmatrix} = \begin{pmatrix} \langle \mathbf{1}, \mathbf{y} \rangle \\ \langle \mathbf{x}, \mathbf{y} \rangle \end{pmatrix}$$

Resolvendo o sistema normal 2×2 , da regressão linear

$$\langle \mathbf{1}, \mathbf{1} \rangle a_0 + \langle \mathbf{1}, \mathbf{x} \rangle a_1 = \langle \mathbf{1}, \mathbf{y} \rangle \quad (5.5)$$

$$\langle \mathbf{x}, \mathbf{1} \rangle a_0 + \langle \mathbf{x}, \mathbf{x} \rangle a_1 = \langle \mathbf{x}, \mathbf{y} \rangle \quad (5.6)$$

usando as seguintes operações $\langle \mathbf{x}, \mathbf{x} \rangle$ (5.5) – $\langle \mathbf{1}, \mathbf{x} \rangle$ (5.6) obtemos,

$$a_0 = \frac{\langle \mathbf{1}, \mathbf{y} \rangle \langle \mathbf{x}, \mathbf{x} \rangle - \langle \mathbf{1}, \mathbf{x} \rangle \langle \mathbf{x}, \mathbf{y} \rangle}{\langle \mathbf{1}, \mathbf{1} \rangle \langle \mathbf{x}, \mathbf{x} \rangle - \langle \mathbf{1}, \mathbf{x} \rangle^2},$$

e fazendo $\langle \mathbf{1}, \mathbf{1} \rangle$ (5.6) – $\langle \mathbf{1}, \mathbf{x} \rangle$ (5.5) obtemos,

$$a_1 = \frac{\langle \mathbf{1}, \mathbf{1} \rangle \langle \mathbf{x}, \mathbf{y} \rangle - \langle \mathbf{1}, \mathbf{x} \rangle \langle \mathbf{1}, \mathbf{y} \rangle}{\langle \mathbf{1}, \mathbf{1} \rangle \langle \mathbf{x}, \mathbf{x} \rangle - \langle \mathbf{1}, \mathbf{x} \rangle^2}.$$

O que é equivalente, a solução de um sistema 2×2 via Regra de Cramer, o método de custo computacional proibitivo apresentado na Unidade 3.

Exemplo 30 Aproxime os dados da tabela usando MMQ com a função aproximadora $g(x) = a_0 + a_1x$.

x	1	2	3	4	5	6	7	8
y	0.5	0.6	0.9	0.8	1.2	1.5	1.7	2

Solução.

$$\langle \mathbf{1}, \mathbf{1} \rangle = \sum_{i=1}^8 1 = 8$$

$$\langle \mathbf{1}, \mathbf{x} \rangle = \langle \mathbf{x}, \mathbf{1} \rangle = \sum_{i=1}^8 x_i = 1 + 2 + 3 + 4 + 5 + 6 + 7 + 8 = 36$$

$$\langle \mathbf{x}, \mathbf{x} \rangle = \sum_{i=1}^8 x_i^2 = 1^2 + 2^2 + 3^2 + 4^2 + 5^2 + 6^2 + 7^2 + 8^2 = 204$$

$$\langle \mathbf{1}, \mathbf{y} \rangle = \sum_{i=1}^8 y_i = 0.5 + 0.6 + 0.9 + 0.8 + 1.2 + 1.5 + 1.7 + 2 = 9.2$$

$$\begin{aligned} \langle \mathbf{x}, \mathbf{y} \rangle = \sum_{i=1}^8 x_i y_i = & 1 \times 0.5 + 2 \times 0.6 + 3 \times 0.9 + 4 \times 0.8 + 5 \times 1.2 + \\ & 6 \times 1.5 + 7 \times 1.7 + 8 \times 2 = 50.5 \end{aligned}$$

Portanto, na forma matricial:

$$\begin{pmatrix} 8 & 36 \\ 36 & 204 \end{pmatrix} \begin{pmatrix} a_0 \\ a_1 \end{pmatrix} = \begin{pmatrix} 9.2 \\ 50.5 \end{pmatrix}$$

Usando a solução deduzida para o sistema 2×2 temos:

$$a_0 = \frac{9.2 \times 204 - 36 \times 50.5}{8 \times 204 - 36^2} = \frac{58.8}{336} = 0.175,$$

$$a_1 = \frac{8 \times 50.5 - 9.2 \times 36}{8 \times 204 - 36^2} = \frac{72.8}{336} = 0.216667.$$

Logo a reta que melhor aproxima a tabela de dados é $g(x) = 0.175 + 0.216667x$.

Exercício: Refaça o exemplo ajustando a tabela com $g(x) = a_0 + a_1x + a_2x^2$.

5.2.2 Caso geral

Agora vamos considerar a função aproximadora:

$$g(x) = \sum_{k=0}^m a_k g_k(x),$$

linear nos parâmetros.

Para o caso discreto, queremos determinar $a_0, a_1, \dots, a_m$ que minimizam o resíduo

$$r(\mathbf{a}) = \sum_{i=1}^n [f(x_i) - g(x_i, \mathbf{a})]^2 = \sum_{i=1}^n [f(x_i) - a_0 g_0(x_i) - a_1 g_1(x_i) - \dots - a_m g_m(x_i)]^2$$

Para isso é necessário derivar r em relação a cada um dos parâmetros a_k e igualar a expressão a zero. Assim, teremos,

$$\frac{\partial r}{\partial a_k} = 2 \sum_{i=1}^n [f(x_i) - a_0 g_0(x_i) - \dots - a_m g_m(x_i)] [-g_k(x_i)] = 0, \text{ com } k = 0, 1, \dots, m. \quad (5.7)$$

Reescrevendo (5.7) obtemos

$$a_0 \sum_{i=1}^n g_0(x_i) g_k(x_i) + \dots + a_m \sum_{i=1}^n g_m(x_i) g_k(x_i) = \sum_{i=1}^n f(x_i) g_k(x_i), k = 0, 1, \dots, m. \quad (5.8)$$

Assim temos $m + 1$ equações com $m + 1$ incógnitas a_k . O sistema normal na forma matricial é dado por:

$$\begin{pmatrix} \langle g_0, g_0 \rangle & \langle g_0, g_1 \rangle & \dots & \langle g_0, g_m \rangle \\ \langle g_1, g_0 \rangle & \langle g_1, g_1 \rangle & \dots & \langle g_1, g_m \rangle \\ \vdots & \vdots & \ddots & \vdots \\ \langle g_m, g_0 \rangle & \langle g_m, g_1 \rangle & \dots & \langle g_m, g_m \rangle \end{pmatrix} \begin{pmatrix} a_0 \\ a_1 \\ \vdots \\ a_m \end{pmatrix} = \begin{pmatrix} \langle g_0, f \rangle \\ \langle g_1, f \rangle \\ \vdots \\ \langle g_m, f \rangle \end{pmatrix}$$

Note que a matriz é simétrica, ou seja, $a_{ij} = a_{ji}$.

Exemplo 31 Observando um sinal no osciloscópio verifica-se que ele corresponde a superposição de dois efeitos, um oscilatório e outro crescente. Aproxime os dados da tabela por uma função $g(x) = a_0x + a_1 \cos(x)$.

x	0	1.5	3	4.5	6
y	1	1.57	2	4.3	7

Solução: Temos $g_0(x) = x$ e $g_1(x) = \cos(x)$. Assim,

$$\langle \mathbf{x}, \mathbf{x} \rangle = \sum_{i=1}^5 x_i^2 = 0^2 + 1.5^2 + 3^2 + 4.5^2 + 6^2 = 67.5$$

$$\langle \mathbf{x}, \cos(\mathbf{x}) \rangle = \sum_{i=1}^5 x_i \cos(x_i) = 0 \times \cos(0) + 1.5 \times \cos(1.5) + 3 \cos(3) + 4.5 \cos(4.5) + 6 \cos(6) = 1.94857$$

$$\langle \cos(\mathbf{x}), \cos(\mathbf{x}) \rangle = \sum_{i=1}^5 \cos(x_i)^2 = \cos^2(0) + \cos^2(1.5) + \cos^2(3) + \cos^2(4.5) + \cos^2(6) = 2.95145$$

$$\langle \mathbf{x}, \mathbf{y} \rangle = \sum_{i=1}^5 x_i y_i = 0 \times 1 + 1.5 \times 1.57 + 3 \times 2 + 4.5 \times 4.3 + 6 \times 7 = 69.705$$

$$\langle \cos(\mathbf{x}), \mathbf{y} \rangle = \sum_{i=1}^5 \cos(x_i) y_i = \cos(0) \times 1 + \cos(1.5) \times 1.57 + \cos(3) \times 2 + \cos(4.5) \times 4.3 + \cos(6) \times 7 = 4.94584$$

Portanto, na forma matricial:

$$\begin{pmatrix} 67.5 & 1.94857 \\ 1.94857 & 2.95145 \end{pmatrix} \begin{pmatrix} a_0 \\ a_1 \end{pmatrix} = \begin{pmatrix} 69.705 \\ 4.94584 \end{pmatrix} \Rightarrow \begin{matrix} a_0 = 1.0034159 \\ a_1 = 1.01327032 \end{matrix}$$

Portanto, $g(x) = 1.0034159x + 1.01327032 \cos(x)$.

5.2.3 Domínio Contínuo

No caso contínuo, o problema de ajuste de curvas consiste em: dada uma função $f(x)$ contínua em um intervalo $[a, b]$ e escolhidas as funções $g_0(x), g_1(x), \dots, g_n(x)$ todas contínuas em $[a, b]$, queremos determinar $a_0, a_1, \dots, a_n$ tais que a função $g(x) = \sum_{k=0}^n a_k g_k(x)$ seja a melhor aproximação de $f(x)$ no intervalo $[a, b]$.

Determinar a **melhor aproximação**, como no caso discreto, significa minimizar a função resíduo dada por,

$$r(\mathbf{a}) = \int_a^b [f(x) - \sum_{k=0}^n a_k g_k(x)]^2 dx.$$

No caso discreto, o resíduo era definido com uma soma finita, já o caso contínuo a definição do resíduo é feita por meio de uma integral em $[a, b]$. Para facilitar a notação, é comum utilizar a notação de produto escalar de duas funções.

1. Caso discreto $\langle f, g \rangle = \sum_{i=0}^m f(x_i)g(x_i)$.
2. Caso contínuo $\langle f, g \rangle = \int_a^b f(x)g(x)dx$.

Importante, lembrar que o produto escalar entre funções satisfaz as propriedades:

1. Linearidade: $\langle ag_1 + a_2g_2, f \rangle = a_1 \langle g_1, f \rangle + a_2 \langle g_2, f \rangle$.
2. Comutatividade: $\langle f, g \rangle = \langle g, f \rangle$.
3. Não negatividade: $\langle g, g \rangle \geq 0$ e $\langle g, g \rangle = 0 \Leftrightarrow g \equiv 0$.

Exercício: Verifique estas propriedades para os produtos escalares definidos para o caso discreto e para o caso contínuo.

Como fizemos para o caso discreto, queremos determinar os parâmetros $a_0, a_1, \dots, a_n$ que minimizam o resíduo, ou seja, $\frac{\partial r}{\partial a_j} = 0$, com $j = 0, 1, \dots, n$. Assim, para cada j temos uma equação da forma,

$$\int_a^b 2[f(x) - \sum_{k=0}^n a_k g_k(x)]g_j(x)dx = 0, \text{ com } j = 0, \dots, n.$$

Pelas propriedades de produto escalar, temos

$$\int_a^b f(x)g_j(x)dx - \sum_{k=0}^n a_k \int_a^b g_k(x)g_j(x)dx = 0,$$

que implica em,

$$a_0 \int_a^b g_0(x)g_j(x)dx + a_1 \int_a^b g_1(x)g_j(x)dx + \dots + a_n \int_a^b g_n(x)g_j(x)dx = \int_a^b f(x)g_j(x)dx.$$

Dessa forma obtemos o sistema normal,

$$\begin{pmatrix} \langle g_0, g_0 \rangle & \langle g_1, g_0 \rangle & \dots & \langle g_n, g_0 \rangle \\ \langle g_0, g_1 \rangle & \langle g_1, g_1 \rangle & \dots & \langle g_n, g_1 \rangle \\ \vdots & & \ddots & \vdots \\ \langle g_0, g_n \rangle & \langle g_1, g_n \rangle & \dots & \langle g_n, g_n \rangle \end{pmatrix} \begin{pmatrix} a_0 \\ a_1 \\ \vdots \\ a_n \end{pmatrix} = \begin{pmatrix} \langle f, g_0 \rangle \\ \langle f, g_1 \rangle \\ \vdots \\ \langle f, g_n \rangle \end{pmatrix},$$

sendo $\langle g, f \rangle = \int_a^b g(x)f(x)dx$.

Exemplo 32 Queremos substituir a função $f(x) = \sin\left(\frac{\pi}{4}x\right)$ por um polinômio de grau 3, no intervalo $[0, 1]$.

Solução.

Como a função $\sin\left(\frac{\pi}{4}x\right)$ é uma função ímpar, ou seja, $f(-x) = -f(x)$, vamos escolher um polinômio ímpar para o ajuste, $g(x) = a_0x + a_1x^3$. Isso significa, que $g_0(x) = x$ e $g_1(x) = x^3$. Assim, precisamos minimizar a função

$$r(a_0, a_1) = \int_0^1 \left(\sin \frac{\pi}{4}x - a_0x - a_1x^3\right)^2 dx.$$

Assim, o sistema normal é dado por,

$$\begin{pmatrix} \int_0^1 x^2 dx & \int_0^1 x^4 dx \\ \int_0^1 x^4 dx & \int_0^1 x^6 dx \end{pmatrix} \begin{pmatrix} a_0 \\ a_1 \end{pmatrix} = \begin{pmatrix} \int_0^1 x \sin(\frac{\pi}{4}x) dx \\ \int_0^1 x^3 \sin(\frac{\pi}{4}x) dx \end{pmatrix},$$

Calculando as integrais (algumas por partes: $\int u dv = uv - \int v du$) obtemos:

$$\begin{aligned} \int_0^1 x \sin(\frac{\pi}{4}x) dx &= -x \frac{4}{\pi} \cos(\frac{\pi}{4}x) \Big|_0^1 + \frac{4}{\pi} \int_0^1 \cos(\frac{\pi}{4}x) dx \\ &= -\frac{4}{\pi} \cos(\frac{\pi}{4}) + \frac{16}{\pi^2} \sin(\frac{\pi}{4}) \\ &\approx 0.2460020203444062 \end{aligned}$$

$$\begin{aligned} \int_0^1 x^3 \sin(\frac{\pi}{4}x) dx &= -x^3 \frac{4}{\pi} \cos(\frac{\pi}{4}x) \Big|_0^1 + \frac{12}{\pi} \int_0^1 x^2 \cos(\frac{\pi}{4}x) dx \\ &= -\frac{4}{\pi} \cos(\frac{\pi}{4}) + \frac{12}{\pi} \left[\frac{4}{\pi} x^2 \sin(\frac{\pi}{4}x) \Big|_0^1 - \frac{8}{\pi} \int_0^1 x \sin(\frac{\pi}{4}x) dx \right] \\ &\approx 0.14581796889606857 \end{aligned}$$

$$\int_0^1 x^2 dx = \frac{x^3}{3} \Big|_0^1 = \frac{1}{3}$$

$$\int_0^1 x^4 dx = \frac{x^5}{5} \Big|_0^1 = \frac{1}{5}$$

$$\int_0^1 x^6 dx = \frac{x^7}{7} \Big|_0^1 = \frac{1}{7}$$

Assim,

$$\begin{pmatrix} \frac{1}{3} & \frac{1}{5} \\ \frac{1}{5} & \frac{1}{7} \end{pmatrix} \begin{pmatrix} a_0 \\ a_1 \end{pmatrix} = \begin{pmatrix} 0.2460020203444062 \\ 0.14581796889606857 \end{pmatrix}$$

cuja solução é $a_0 = 0.7848162$ e $a_1 = -0.07801689$. Portanto, a função aproximadora é $g(x) = 0.7848162x - 0.07801689x^3$.

5.2.4 Mínimos quadrados com peso

A formulação do Método dos Mínimos Quadrados (MMQ) usando a definição de produto escalar de funções nos permite:

- Atribuir diferentes graus de importância no intervalo de aproximação. Isso é feito quando incluímos uma função peso, $w(x)$ no produto escalar,

1. Discreto: $\langle f, g \rangle = \sum_{i=1}^m w(x_i) f(x_i) g(x_i),$
2. Contínuo: $\langle f, g \rangle = \int_a^b w(x) f(x) g(x) dx,$

sendo $w(x)$ uma função contínua e $w(x) > 0$ em $[a, b]$.

Exemplo 33 A tabela a seguir apresenta os preços R_i de um ativo financeiro nos últimos seis meses $t_i = i$, com $i = 1, 2, \dots, 6$.

t_i	1	2	3	4	5	6
R_i	21.3	21.8	21.2	21.3	20.5	21.5

Deseja-se estimar o comportamento dos preços segundo uma função linear $R(t) = a_0 + a_1 t$. Entretanto, será dado um peso maior aos meses mais recentes por meio de $w = (0.5, 0.6, 0.7, 0.8, 0.9, 1)$.

(a) Apresente o sistema linear obtido pelo MMQ.

(b) Faça uma estimativa do valor para o sétimo mês.

5.2.5 Funções Ortogonais

O conceito de ortogonalidade em um conjunto de funções, se origina do conceito de ortogonalidade entre vetores, caracterizado pelo produto escalar nulo.

Uma família de funções, $g_i(x)$, com $i = 0, 1, \dots$ é ortogonal em relação ao produto escalar associado ao peso $w(x)$, se $\langle g_i, g_j \rangle = 0$ para todo $i \neq j$.

Se as funções $g_i(x)$ que compõem a função aproximadora $g(x) = \sum_{k=0}^n g_k(x)$ são ortogonais, o sistema normal se torna diagonal. Ou seja, apenas a diagonal da matriz é não nula. Portanto, a solução do sistema resulta em

$$a_j = \frac{\langle f, g_j \rangle}{\langle g_j, g_j \rangle}, j = 0, 1, \dots, n.$$

Exemplos de famílias de funções ortogonais:

- As funções trigonométricas, que dão origem à série de Fourier (Análise Harmônica).
- Os polinômios ortogonais: polinômios de Legendre, Chebyshev, entre outros, que cada vez mais aparecem em problemas que envolvem aproximações.

Polinômios de Legendre: são ortogonais em $(-1, 1)$ com a função peso $w(x) = 1$. Os seis primeiros polinômios são:

$$\begin{aligned} p_0(x) &= 1 & p_3(x) &= x^3 - \frac{3}{5}x \\ p_1(x) &= x & p_4(x) &= x^4 - \frac{6}{7}x^2 + \frac{3}{35} \\ p_2(x) &= x^2 - \frac{1}{3} & p_5(x) &= x^5 - \frac{10}{9}x^3 + \frac{5}{21}x \end{aligned}$$

Polinômios de Chebyshev: são ortogonais em $(-1, 1)$ com a função peso $w(x) = (1 - x^2)^{-\frac{1}{2}}$. Os cinco primeiros polinômios são:

$$\begin{aligned} p_0(x) &= 1 & p_3(x) &= 4x^3 - 3x \\ p_1(x) &= x & p_4(x) &= 8x^4 - 8x^2 + 1 \\ p_2(x) &= 2x^2 - 1 \end{aligned}$$

Atenção ao intervalo em que os polinômios são ortogonais. Pode ser necessário fazer uma mudança de variável: $x \in [a, b]$ para $t \in [-1, 1]$,

$$x = \frac{(b-a)t + (a+b)}{2}.$$

Análise Harmônica

Família de funções trigonométricas: $\{1, \cos(x), \sin(x), \cos(2x), \sin(2x), \dots, \cos(nx), \sin(nx)\}$ que são ortogonais em um intervalo de tamanho 2π .

Função aproximadora: $g(x) = a_0 + \sum_{k=1}^n [a_k \cos(kx) + b_k \sin(kx)]$

Exemplo 34 Aproximar $f(x) = \begin{cases} 1, & 0 \leq x \leq \pi \\ -1, & \pi < x \leq 2\pi \end{cases}$ função periódica, $f(x+2\pi) = f(x)$, via método dos mínimos quadrados, com $g(x) = a_0 + \sum_{k=1}^3 [a_k \cos(kx) + b_k \sin(kx)]$.

5.2.6 Mínimos Quadrados não lineares

As funções usadas na aproximação são não lineares nos parâmetros. Por exemplo, funções racionais, hiperbólicas, exponenciais, como,

$$g(x) = a_1 \exp\left(-\frac{(a_2 - x)^2}{a_3}\right) + a_4 \exp\left(-\frac{(a_5 - x)^2}{a_6}\right).$$

A ideia continua a mesma, minimizar a soma dos quadrados dos resíduos. A diferença é que podemos ter dois caminhos:

- Se for possível, podemos linearizar a função aproximadora, resolver o problema linear e depois retornar aos parâmetros originais.
- Resolver um sistema não linear, obtido a partir do problema de minimizar a função resíduo.

Exemplo 35 Como fazer para aproximar uma função tabelada (x_i, y_i) , com $i = 1, \dots, n$, por uma função $g(x) = a_0 \exp(-a_1 x)$?

Solução: Note que aplicando $\ln$ em ambos os lados, $g(x) = a_0 \exp(-a_1 x) \implies \ln(g(x)) = \ln(a_0) - a_1 x$. Fazendo $\alpha_0 = \ln(a_0)$ e $\alpha_1 = -a_1$ temos um problema linear, um ajuste por uma reta, $\ln(y) \approx \alpha_0 + \alpha_1 x$. Obtidos α_0 e α_1 usamos a transformação para obter a_0 e a_1 .

A seguir um exemplo, de MMQ não linear com a resolução de um sistema não linear. Nosso objetivo, obter os parâmetros por meio do método dos mínimos quadrados, que minimizam a função,

$$r(\mathbf{a}) = \frac{1}{2} \sum_{i=1}^m r_i(\mathbf{a})^2,$$

sendo $\mathbf{a} = (a_0, a_1, \dots, a_m)$, o resíduo $r_i(\mathbf{a}) = f(x_i, \mathbf{a}) - y_i$, com (x_i, y_i) dados e m tamanho dos vetores x e y . O nosso objetivo é determinar $\mathbf{a}$ tal que o valor da função resíduo seja mínimo.

Algoritmo de Gauss-Newton:

Nesse método assume-se que $\mathbf{a}^k$ está próximo do mínimo e portanto, o resíduo $r_i(\mathbf{a})$ está próximo de zero. Para simplificar, vamos apresentar a dedução para uma função com dois parâmetros. Vamos aproximar a função resíduo $r(a_0, a_1)$ utilizando os três primeiros termos da série de Taylor. Os três primeiros termos da série em torno de (a_0, a_1) com incremento (p_0, p_1) são dados por:

$$r(a_0 + p_0, a_1 + p_1) \approx r(a_0, a_1) + p_0 \frac{\partial r}{\partial a_0}(a_0, a_1) + p_1 \frac{\partial r}{\partial a_1}(a_0, a_1) + \frac{1}{2} \left(p_0^2 \frac{\partial^2 r}{\partial a_0^2}(a_0, a_1) + 2p_0 p_1 \frac{\partial^2 r}{\partial a_0 \partial a_1}(a_0, a_1) + p_1^2 \frac{\partial^2 r}{\partial a_1^2}(a_0, a_1) \right).$$

As derivadas parciais em relação a a_0 e a_1 geram a matriz Jacobiana:

$$J = \begin{pmatrix} \frac{\partial r_1}{\partial a_0} & \frac{\partial r_1}{\partial a_1} \\ \frac{\partial r_2}{\partial a_0} & \frac{\partial r_2}{\partial a_1} \\ \vdots & \vdots \\ \frac{\partial r_n}{\partial a_0} & \frac{\partial r_n}{\partial a_1} \end{pmatrix}$$

Para obter os parâmetros a_0 e a_1 que minimizam $r(a_0, a_1)$ precisamos derivar e igualar a zero, obtendo:

$$\frac{\partial r}{\partial a_k} = \sum_{i=1}^n \frac{\partial r_i}{\partial a_k} \cdot r_i$$

Note que,

$$p_0 \frac{\partial r}{\partial a_0}(a_0, a_1) + p_1 \frac{\partial r}{\partial a_1}(a_0, a_1) = p^T J^T r(a)$$

Já os termos de associados as derivadas de segunda ordem são representados por,

$$\frac{\partial^2 r}{\partial a_k^2} = \sum_{i=1}^n \frac{\partial r_i}{\partial a_k} \cdot \frac{\partial r_i}{\partial a_k} + \sum_{i=1}^n r_i \frac{\partial^2 r_i}{\partial a_k^2}.$$

Assim,

$$r(\mathbf{a} + \mathbf{p}) = r(\mathbf{a}) + \mathbf{p}^T J^T r(\mathbf{a}) + \frac{1}{2} \mathbf{p}^T (J^T J + Q) \mathbf{p}.$$

No processo de minimizar r queremos determinar o incremento $\mathbf{p}$ que diminua a soma dos resíduos. Ou seja, $r(\mathbf{a} + \mathbf{p}) < r(\mathbf{a})$. No método de Gauss-Newton, admitimos que $\mathbf{a}^k$ está próximo do mínimo e portanto $r(\mathbf{a})$ está próximo de zero. Com esta hipótese é razoável argumentar que a matriz Q que contém as derivadas de segunda ordem pode ser desprezada. Nestas condições a cada iteração:

1. Avaliamos J e r .
2. Resolvemos $J^T J \mathbf{p} = -J^T r$
3. $\mathbf{a}^{k+1} = \mathbf{a}^k + \mathbf{p}$

Para mais detalhes veja [6] e [3]. A seguir apresentamos o Algoritmo de Gauss-Newton.

Algoritmo 15: Método de Gauss-Newton

Entrada: $r_i(\mathbf{a})$, J e $\mathbf{a}^0$.

$itmax = 100$

$tol = 10^{-6}$

$it = 1$

$diff = 1$

enquanto $diff > tol$ e $it < itmax$ **faça**

Calcule $r \leftarrow r(\mathbf{a}^0)$

Calcule $J \leftarrow J(\mathbf{a}^0)$

Calcule $(J^T)J$ e $(J^T)r$

Resolva o sistema $(J^T)Jp = -(J^T)r$

$\mathbf{a} \leftarrow \mathbf{a}^0 + p$

$diff \leftarrow max \mathbf{a}$

$\mathbf{a}^0 \leftarrow \mathbf{a}$

$it \leftarrow it + 1$

Saída: $\mathbf{a}$

Outra alternativa é o método de Levenberg-Marquardt onde a minimização da soma dos resíduos se baseia na solução do sistema:

$$(J_k^T J_k + \lambda_k I) p_k = -J_k^T r_k,$$

onde J^T é a transposta da matriz Jacobiana e I é a matriz identidade. Um dos métodos utilizado em `least_squares` do módulo `scipy`. https://docs.scipy.org/doc/scipy/reference/generated/scipy.optimize.least_squares.html

Exemplo 36 Uma população de bactérias foi medida ao longo das 6 primeiras horas de um dia.

t	0	1	2	3	4	5	6
$p(t)$	32	47	65	92	132	190	275

Utilize a função $g(x) = a_0 e^{a_1 x}$ para aproximar os dados pelo Método dos Mínimos Quadrados.

Exemplo 37 Para o ajuste da curva de polarização por meio da função não linear é necessário obter os parâmetros $\mathbf{a}$ da função,

$$f(x, \mathbf{a}) = a_0 - a_1 x - a_2 \ln\left(\frac{x}{a_3} + 1\right) - a_4 \exp(a_5 x).$$

Utilize esta função aproximadora para aproximar os dados de corrente e voltagem da tabela:

i	0	$4.75 \cdot 10^{-4}$	$8.27 \cdot 10^{-4}$	$1.69 \cdot 10^{-3}$	$2.5 \cdot 10^{-3}$	$3.01 \cdot 10^{-3}$	$3.19 \cdot 10^{-3}$	$3.86 \cdot 10^{-3}$
V	0.6795	0.4862	0.423	0.33975	0.25075	0.2062	0.1629	0.07715

5.3 Exercícios

- Determina os polinômios de grau 1, 2 e 3 que melhor ajustam a tabela abaixo, no sentido dos quadrados mínimos. Qual deles fornece o menor resíduo?

x	0	0.15	0.31	0.5	0.6	0.75
y	1	1.004	1.031	1.117	1.223	1.422

- Considere os seguintes dados tabelados:

x	-2	-1	0	1	2
y	6	3	-1	-2	-4

- Determine a e b tais que $y \approx ax + b$ pelo método dos Mínimos Quadrados.
 - Determine c e d tais que $x \approx cy + d$ pelo método dos Mínimos Quadrados.
 - Qual relação você esperaria entre os valores a, b, c e d ? Essa relação ocorre? Justifique.
- Um professor organizou uma tabela com dados de estudantes, relacionando horas semanais de estudo extra-classe e notas. Nessa tabela ele incluiu pesos e os dados são apresentados a seguir,

Estudantes	Horas	Notas	Peso
<i>A</i>	5	7.5	1
<i>B</i>	10	8.5	2
<i>C</i>	4	7	1
<i>D</i>	3	6.5	0.5
<i>E</i>	12	9.5	2
<i>F</i>	8	8	1.5
<i>G</i>	6	8	1.5

Obtenha a reta que melhor aproxima os dados, usando o método dos mínimos quadrados com peso.

4. Verifique que as funções não lineares a seguir podem ser linearizadas por transformações matemáticas. Explícite a relação entre a função original e a linearizada.

(a) $f(x) = \frac{a_1}{a_2x + a_3};$

(c) $f(x) = \ln(a_1 + a_2x^2);$

(b) $f(x) = 1 + \frac{a_1}{x^2 + a_2};$

(d) $f(x) = \frac{100}{1 + a_1e^{-a_2x}}.$

5. A tabela

r	2.7	2	1.61	1.2	1.02
θ	48°	67°	83°	108°	126°

foi gerada a partir de posições de um cometa em coordenadas polares convenientes. Sabendo-se que a órbita do cometa é descrita pela lei de Kepler

$$r = \frac{p}{1 - q \cos(\theta)},$$

estime p e q usando o método dos mínimos quadrados:

- (a) a partir do problema linearizado;
 (b) apresente os passos de uma iteração do método de Gauss-Newton para esse problema.
6. O número de bactérias por unidade de volume, existente em uma cultura após x horas é apresentado na tabela:

x (horas)	1	2	3	4	5	6
y (n° de bactérias/volume)	47	65	92	132	190	275

- (a) Obtenha uma linearização para a função aproximadora $g(x) = ab^x$.
 (b) Ajuste os dados da tabela $y \approx g(x)$ usando a linearização do item anterior.
7. Dados os polinômios de Legendre: $p_0(x) = 1$, $p_1(x) = x$ e $p_2(x) = \frac{1}{2}(3x^2 - 1)$ que obedecem a seguinte definição:

$$\langle p_i, p_j \rangle = \int_{-1}^1 p_i(x)p_j(x)dx = \begin{cases} 0, & i \neq j \\ \frac{2}{2i+1}, & i = j \end{cases}$$

- (a) Determine o polinômio de grau dois, usando os polinômios de Legendre, que melhor aproxima $f(x) = x^3 - 1$, no intervalo $[-1, 1]$.
- (b) Determine o polinômio de grau dois que melhor aproxima $f(x) = \sin(x)$ no intervalo $[0, \pi]$. Note que será necessária uma mudança de variáveis para a utilização dos polinômios de Legendre.

8. Aproxime a função

$$f(x) = \begin{cases} \frac{x}{\pi}, & 0 \leq x \leq \pi \\ -\frac{x}{\pi} + 2, & \pi < x \leq 2\pi \end{cases}$$

usando o método dos mínimos quadrados, usando o produto escalar

$$\langle f, g \rangle = \int_0^{2\pi} f(x)g(x)dx,$$

e as funções aproximadoras:

- (a) $g(x) = a_0 + a_1x + a_2x^2$; e
- (b) $h(x) = a_0 + a_1 \sin(x) + a_2 \cos(x)$.

9. Considere a função tabelada abaixo:

x	0	0.5	1	2.5	3
y	2	2.6	3.7	13.21	21

- (a) Obtenha uma linearização para a função aproximadora $g(x) = 1 + a \exp(bx)$.
- (b) Apresente o sistema normal (sistema linear) do problema linearizado.

5.4 Interpolação polinomial

5.5 Exercícios

